



人工智能数学基础

数值分析

刘昌鑫

华东理工大学

信息科学与工程学院 自动化系

能源化工过程智能制造教育部重点实验室

目录

4

数值分析

4-1 函数插值



4-2 函数拟合

4-3 函数逼近



4-1

函数插值





• 连续函数空间的定义

连续函数空间是指所有连续函数的集合，在区间 $[a, b]$ 上的连续函数空间则是指定义域为 $[a, b]$ 并且连续的函数构成的集合，记为 $C^0[a, b]$

• 范数的基本定义

设 $f \in C^0[a, b]$ ，若存在唯一实数 $\|\cdot\|$ ，满足以下条件：

- 非负性： $\|f\| \geq 0$ ，当且仅当 $f = 0$ 时， $\|f\| \triangleq 0$
- 齐次性： $\|af\| = |a|\|f\|$ ， $a \in \mathbb{R}$
- 三角不等式： $\|f + g\| \leq \|f\| + \|g\|$ ， $\forall f, g \in C^0[a, b]$

则称 $\|\cdot\|$ 为连续函数空间 $C^0[a, b]$ 上的范数

■ 连续函数的范数

对连续函数空间 $C^0[a, b]$ 上的函数 $f(x)$ ，通常有三种范数：

- ∞ -范数： $\|f\|_{\infty} = \max_{a \leq x \leq b} |f(x)|$



• 范数的基本定义

■ 连续函数的范数

➤ 1-范数: $\|f\|_1 = \int_a^b |f(x)| dx$

➤ 2-范数: $\|f\|_2 = \left[\int_a^b f^2(x) dx \right]^{\frac{1}{2}}$

■ 函数范数的性质

➤ 函数的内积: $\langle f(x), g(x) \rangle = \int_a^b f(x)g(x)dx, f(x), g(x) \in C^0[a, b]$

➤ 函数正交: $\langle f(x), g(x) \rangle = 0$

➤ Cauchy-Schwarz不等式: $|\langle f, g \rangle| \leq \|f\| \cdot \|g\|$

➤ 三角不等式: $\|f + g\| \leq \|f\| + \|g\|$

➤ 勾股定理: 若 $\langle f(x), g(x) \rangle = 0$, 则 $\|f + g\|^2 \leq \|f\|^2 + \|g\|^2$

p -范数

$$\|f\|_p = \left[\int_a^b |f^p(x)| dx \right]^{\frac{1}{p}}$$



范数的基本定义

向量的范数

在 $\mathbb{R}^n$ 上, 向量 $\mathbf{x} = (x_1, \dots, x_n)$ 的常用范数如下:

- ∞ -范数: $\|\mathbf{x}\|_{\infty} = \max_{1 \leq i \leq n} |x_i| = \max(x_1, \dots, x_n)$
- 1-范数: $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i| = |x_1| + |x_2| + \dots + |x_n|$
- 2-范数: $\|\mathbf{x}\|_2 = (\sum_{i=1}^n x_i^2)^{\frac{1}{2}} = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$


$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

矩阵的范数

对于任意 $\mathbf{A} \in \mathbb{R}^{m \times n}$, 则矩阵 $\mathbf{A}$ 的范数如下:

➤ 1-范数

$$\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$



又称列和范数, 表示矩阵列向量中绝对值之和的最大值



• 范数的基本定义

■ 矩阵的范数

➤ ∞ -范数

$$\|\mathbf{A}\|_{\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

又称行和范数，表示矩阵行向量中绝对值之和的最大值

➤ 2-范数：又称谱函数，取值为 $\mathbf{A}^T \mathbf{A}$ 矩阵的最大特征值的开方

$$\|\mathbf{A}\|_2 = \sqrt{\max(\lambda_i(\mathbf{A}^T \mathbf{A}))}$$

➤ F -范数

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$$

取值为矩阵元素绝对值的平方和的开方

$$\|\mathbf{A}\|_{\max} = \max_{i,j \in \{1, \dots, n\}} |a_{ij}|$$



函数空间与范数

• 范数的基本定义

■ 机器学习中的范数

- **L1-范数**：表示向量各个元素绝对值之和

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$$

- **L2-范数**：表示指向量各元素的平方和然后求平方根

$$\|\mathbf{x}\|_2 = \left(\sum_{i=1}^n |x_i|^2 \right)^{\frac{1}{2}}$$

- **L0-范数**：表示向量中非零元素的个数，

$$\|\mathbf{x}\|_0 = \sum_{i=1}^n [x_i \neq 0]$$

*注意：但并非通常意义上的范数（不满足三角不等式或次可加性）



• 函数插值

■ 函数插值 (Function Interpolation) 的定义

设函数 $y = f(x)$ 在区间 $[a, b]$ 上有定义, 且已知在点 $a \leq x_0 < x < \dots < x_n \leq b$ 上的对应的函数值 $y_0, y_1, \dots, y_n$, 若存在一简单函数 $g(x_i)$, 使所有 $i = 1, \dots, n$,

$$g(x_i) = y_i$$

都成立, 且误差的绝对值

$$r(x) = |f(x) - g(x)|$$

在整个区间 $[a, b]$ 上比较小, 则这样的问题称为 **插值问题**

- $g(x)$ 为 $f(x)$ 关于点 $x_0, x_1, \dots, x_n$ 的 **插值函数**, $f(x)$ 为 **被插值函数**
- 点 $x_0, x_1, \dots, x_n$ 称为 **插值节点**, 点 $y_0, y_1, \dots, y_n$ 称为 **插值点**, 包含节点的区间 $[a, b]$ 称为 **插值区间**
- 如果在插值区间内部用 $g(x)$ 来代替 $f(x)$ 的方法称为 **内插值法**; 在插值区间外, 用 $g(x)$ 来代替 $f(x)$ 的方法称为 **外插值法**




插值问题

函数插值

➤ 例如，假设天文学家开普勒观察火星运行之后记录：

- 周一，火星距离太阳3万公里
- 周二，火星距离太阳6万公里
- 周三，雾霾，没有观测数据
- 周四，火星距离太阳5万公里
- 周五，火星距离太阳7万公里



$$x_1 = 1, y_1 = 3$$



$$x_2 = 2, y_2 = 6$$

$$x_3 = 3, y_3 = ?$$

$$x_4 = 4, y_4 = 5$$

$$x_5 = 5, y_5 = 7$$

假设火星形成的连续运动轨迹经过 y_1, y_2, y_3, y_4 这4个点，再构想一条可能的运动轨迹，该轨迹给出 $x_3 = 3$ 处对应的值 $y_3 = 6.94$






• 函数插值

■ 函数插值的性质

- $(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)$ 可视为带有标签的训练样本数据
- 插值是离散函数逼近的重要方法，通过函数在有限个点处的取值状况，估算出函数在其他点处的近似值
- 图像处理：用插值法来填充图像变换时像素之间的空隙
- 图像插值：插值算法是指通过在图像原有的像素周围插入新像素来加大图像的尺寸，插入像素后还要给这些像素赋值，从而恢复图像内容，达到提高图像分辨率的效果



将左图进行最近邻插值后，出现很多锯齿和马赛克





• 函数插值

■ 函数插值的性质

- 插值法是数据处理和编制函数表的常用工具，又是数值积分、数值微分、非线性方程求根和微分方程数值解法的重要基础

■ 基函数 (Primary Function)

是函数空间一组特殊的基的元素

- 对于函数空间中的连续函数都可以表示成一系列基函数的线性组合，就像是在向量空间中每个向量都可以表示成基向量的线性组合一样
- 在数值分析和逼近理论中，基函数也称为混合函数 (**Blending Function**)，因为把基函数混合起来可作为插值函数

■ 函数插值的方法

- 在由简单函数构成的带有 $n+1$ 个参数 $c_0, c_1, \dots, c_n$ 的函数类 $\mathbb{G}(c_0, \dots, c_n)$ 中找出满足 $g(x_i) = f(x_i)$ 的函数 $g(x)$ ，作为 $f(x)$ 的估值







• 函数插值

■ 函数插值的方法

➢ 设 $\varphi_0(x), \varphi_1(x), \varphi_2(x), \dots, \varphi_n(x)$ 为函数空间 $\mathbb{C}[a, b]$ 上的一组基函数,

$$g(x) = \sum_{i=0}^n c_i \varphi_i(x)$$

➢ 采用基函数不同, 可分为: 线性插值, 多项式插值 (拉格朗日插值多项式, 牛顿插值多项式), 埃尔米特插值, 分段插值, 样条曲线插值, 三角函数插值, 有理函数插值, 小波插值





• 插值函数的存在唯一性

■ 哈尔 (Haar) 条件

设 $\varphi_0(x), \varphi_1(x), \varphi_2(x), \dots, \varphi_n(x)$ 为函数空间 $\mathbb{C}[a, b]$ 上的一组基函数, 若这些基函数满足 $\varphi_i(x)$ 在区间 $[a, b]$ 上都连续并且由 $[a, b]$ 上 $n+1$ 个相异的点形成的行列式

$$\begin{vmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \cdots & \varphi_n(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \cdots & \varphi_n(x_1) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_0(x_n) & \varphi_1(x_n) & \cdots & \varphi_n(x_n) \end{vmatrix}$$

都不等于零, 则称这组基满足哈尔条件

■ 插值函数唯一性定理

若 $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$ 满足哈尔条件, 则在函数空间 $\mathbb{C}[a, b]$ 中存在唯一函数 $g(x) = \sum_{i=0}^n c_i \varphi_i(x)$ 满足插值条件



• 线性函数插值

■ 线性函数插值 (Linear Function Interpolation) 的定义

将每两个相邻的插值点用直线连起来, 所形成的一条折线就是分段线性插值函数, 记作 $g(x)$, 满足 $g(x_i) = y_i$, 且 $g(x)$ 在每个区间 $[x_i, x_{i+1}]$ ($i = 0, 1, \dots, n-1$) 上是线性函数

■ 线性函数插值的方法

假设已知函数 $y = f(x)$ 在两点 x_0, x_1 上的值分别为 y_0, y_1 , 求多项式


$$y = g(x) = c_0 + c_1 x$$

使其满足

$$g(x_0) = y_0, \quad g(x_1) = y_1$$

➢ 由解析几何可知

$$y = g(x) = y_0 + \frac{y_1 - y_0}{x_1 - x_0}(x - x_0)$$





• 线性函数插值

■ 线性函数插值的方法

➢ 因此，可得

$$g(x) = y_0 + \frac{y_1 - y_0}{x_1 - x_0} (x - x_0)$$

➢ 如果按照 y_0, y_1 整理，则有

$$g(x) = \frac{x - x_1}{x_0 - x_1} y_0 + \frac{x - x_0}{x_1 - x_0} y_1$$


从而得到在区间 $[x_0, x_1]$ 上函数 $f(x)$ 的线性插值函数 $g(x)$

➢ 范例

将周二、周四的数据 $(2, 6)$, $(4, 5)$ 代入式中，可得

$$y_3 = g(x_3) = \frac{3-2}{4-2} \times 5 + \frac{3-4}{2-4} \times 6 = 5.5$$

- 注意线性插值是最粗糙的插值方法，此例中不需要周一和周五的数据 $(1, 3)$, $(5, 7)$ 就能得到结果





• 线性函数插值

■ 线性函数插值的余项

若 $f(x)$ 在 $[x_0, x_1]$ 二阶连续可导, 对于任意 $x \in [x_0, x_1]$, 插值多项式 $g(x)$ 的误差/余项为

$$r(x) = |f(x) - g(x)|$$

根据罗尔定理, 可知

$$r(x) \leq \frac{(x_1 - x_0)^2}{8} \max_{x_0 \leq x \leq x_1} |f''(x)|$$

➢ 函数上两点之间的近似随着所近似的函数的二阶导数的增大而逐渐变差, 即函数的曲率越大, 简单线性插值近似的误差也越大

■ 线性函数插值的几何意义

利用过点 (x_0, y_0) 和 (x_1, y_1) 的直线 $g(x)$ 来近似原函数 $f(x)$



• 多项式函数插值

- 多项式函数插值 (Polynomial Function Interpolation) 的定义

给定 $n + 1$ 个插值点 $\{(x_i, y_i)\}_{i=0}^n$, 令多项式 $g(x)$ 的形式为

$$g(x) = c_n x^n + \dots + c_1 x + c_0$$

其中, 对于 $i = 0, 1, \dots, n$, 满足条件 $y_i = g(x_i)$, 即多项式 $y = g(x)$ 的曲线要经过给定的 $n + 1$ 个点

- 多项式函数插值的唯一性: 如果节点 x_i 各不同, 则存在**唯一**一个次数不超过 n 的多项式 $y = g(x)$, 使得 $y_i = g(x_i)$ ($i = 0, \dots, n$) 成立
 - 根据 (**哈尔条件**) 插值函数唯一性定理, 取基函数为 $1, x, x^2, \dots, x^n$, 因行列式满足

$$\begin{vmatrix} 1 & x_0 & \cdots & x_0^n \\ 1 & x_1 & \cdots & x_1^n \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_n^n \end{vmatrix} = \prod_{j>i} (x_j - x_i) \neq 0$$

所以在函数空间中存在唯一的多项式 $g(x) = \sum_{i=0}^n c_i x^i$



• 多项式函数插值

■ 多项式函数插值的唯一性

- 尽管无论用什么形式的多项式或什么方法构造插值函数（例如基函数的次数可以不连续），都可化为统一的形式，即多项式插值唯一存在的，但是选取不同的基函数，则会产生不同的系数 c_i

• 多项式函数插值

■ 多项式函数插值的法

常用的多项式插值的解法有**直接法**、**拉格朗日插值法**和**牛顿插值法**

➢ 直接法

由定义可知，假设插值多项式为

$$g(x) = c_n x^n + \dots + c_1 x + c_0$$

由插值条件 $y_i = g(x_i)$, $i = 1, \dots, n$, 可计算多项式插值函数的系数 $c_0, c_1, \dots, c_n$ 的



• 多项式函数插值

■ 多项式函数插值的方法

➤ 直接法

因此，得到关于系数 c_i 的线性方程组

$$\begin{bmatrix} x_0^n & x_0^{n-1} & \cdots & x_0 & 1 \\ x_1^n & x_1^{n-1} & \cdots & x_1 & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{n-1}^n & x_{n-1}^{n-1} & \cdots & x_{n-1} & 1 \\ x_n^n & x_n^{n-1} & \cdots & x_n & 1 \end{bmatrix} \begin{bmatrix} c_n \\ c_{n-1} \\ \vdots \\ c_1 \\ c_0 \end{bmatrix} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_{n-1} \\ y_n \end{bmatrix}$$

通过求解这个线性方程组，即得到插值多项式

- 缺点：待求解的线性方程组的系数矩阵为**范德蒙德 (Vandermonde) 矩阵**，是一个**病态矩阵**，这使得在实际求解方程组时将产生很大的误差

* 病态矩阵：矩阵的条件数 $\kappa(A) = \|A\| \cdot \|A^{-1}\|$ 扰动十分敏感



• 多项式函数插值方法

➤ 拉格朗日 (Lagrange) 插值法

若插值点为 $x_0, x_1, \dots, x_n$, 则选取如下拉格朗日基函数

$$\varphi_i(x) = \frac{(x - x_0) \cdots (x - x_{i-1})(x - x_{i+1}) \cdots (x - x_n)}{(x_i - x_0) \cdots (x_i - x_{i-1})(x_i - x_{i+1}) \cdots (x_i - x_n)}$$

则多项式插值函数为

$$g(x) = \sum_{i=0}^n c_i \varphi_i(x)$$

称为拉格朗日插值多项式, 其中多项式系数选取为 $c_i = f(x_i)$

- 范例: 若某个二次多项式函数 $f(x)$, 已知它的三个点上的取值为 $f(4) = 10$, $f(5) = 5.25$, $f(6) = 1$, 利用拉格朗日插值法求 $f(18)$

- 首先写出每个拉格朗日基函数

$$\varphi_0(x) = \frac{(x-5)(x-6)}{(4-5)(4-6)}, \varphi_1(x) = \frac{(x-4)(x-6)}{(5-4)(5-6)}, \varphi_2(x) = \frac{(x-4)(x-5)}{(6-4)(6-5)}$$



• 多项式函数插值方法

➤ 拉格朗日 (Lagrange) 插值法

• 范例

然后应用拉格朗日插值法,

$$g(x) = f(4)\varphi_0(x) + f(5)\varphi_1(x) + f(6)\varphi_2(x) = \frac{1}{4}(x^2 - 28x + 136)$$

■ 最后代入函数值, 求得 $f(18) = g(18) = -11$

• 拉格朗日插值的余项

若 $f(x)$ 在 $[a, b]$ 上 $n+1$ 次可微, 则存在 $\xi \in [a, b]$, 使得对 $\forall x \in [a, b]$ 满足

$$r(x) = |f(x) - g(x)| = \left| \frac{f^{n+1}(\xi)}{(n+1)!} \omega_{n+1}(x) \right|$$

其中 $r(x)$ 为插值多项式的 $g(x)$ 误差/余项, $\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i)$, 其在 $[a, b]$ 上至少有 $n+1$ 个零点,




• 多项式函数插值方法

➤ 拉格朗日 (Lagrange) 插值法

• 龙格 (Runge) 现象

一般情况下，多项式的次数越多，需要的数据就越多，而预测也就越准确，但有些情况下，插值次数越高，插值结果越偏离原函数的现象称为龙格现象

∴ 由于插值节点增多导致插值多项式的次数增高，而高次多项式的振荡次数增多有可能使插值多项式在非节点处的误差变得很大





• 多项式函数插值方法

➤ 拉格朗日 (Lagrange) 插值法

• 龙格 (Runge) 现象

- 范例：函数 $f(x) = \frac{5}{1+x^2}$ 在 $[-5,5]$ 上构造 $n+1$ 个等距节点

$$x_i = -5 + \frac{10}{n}i, \quad i = 0, \dots, n$$

因此，用如下拉格朗日插值多项式 $g(x)$ 逼近 $f(x)$,

$$g(x) = \sum_{i=0}^n \left[\left(\frac{1}{1+x_i^2} \prod_{j=1, j \neq i}^n \left(\frac{x-x_j}{x_i-x_j} \right) \right) \right]$$

分别取 $n=6$ 、 $n=8$ 和 $n=10$ 搭建相应阶数的拉格朗日插值多项式

$$g_6(x) = c_6x^6 + \dots + c_1x + c_0$$

$$g_8(x) = c_8x^8 + \dots + c_1x + c_0$$

$$g_{10}(x) = c_{10}x^{10} + \dots + c_1x + c_0$$




• 多项式函数插值方法

➤ 拉格朗日 (Lagrange) 插值法

• 龙格 (Runge) 现象

■ 范例

- ◆ 右部初始段拟合效果不错，但是当取一些非插值点的时候，插值函数的值与原函数值的误差变得非常大
- ◆ 龙格现象在机器学习、深度学习中对应的问题就是**过拟合**，因为拟合次数太高，导致函数太复杂
- ◆ 插值问题一味增加数据只会导致更严重的Runge问题，使得插值函数不收敛
- ◆ **缺点：**每新增一个插值节点，所有的插值基函数都要重新构造





• 多项式函数插值方法

➤ 牛顿 (Newton) 插值法

• 差商 (Differential Quotient, 均差)

给定互异插值点 $x_0, x_1, \dots, x_n$ 及函数值 $f(x_0), f(x_1), \dots, f(x_n)$, 称

■ $f[x_i, x_j] = \frac{f(x_i) - f(x_j)}{x_i - x_j}$ 为 $f(x)$ 关于插值点 x_i, x_j 的 **一阶差商**

■ $f[x_i, x_j, x_k] = \frac{f[x_k, x_j] - f[x_j, x_i]}{x_k - x_i}$ 为 $f(x)$ 关于插值点 x_i, x_j, x_k 的 **二阶差商**

■ 以此类推, $f(x)$ 关于插值点 $x_0, x_1, \dots, x_n$ 的 n 阶差商

$$f[x_0, x_1, \dots, x_n] := \frac{f[x_n, x_{n-1}, x_2, x_1] - f[x_{n-1}, x_{n-2}, \dots, x_1, x_0]}{x_n - x_0}$$

◆ **零阶差商** 定义为 $f[x_i] = f(x_i)$

◆ 一阶差商反映了函数在区间的 **平均变化率**

◆ 差商具有对称性, 任意调换节点的次序, 差商的值不变



• 多项式函数插值方法

➤ 牛顿 (Newton) 插值法

若插值点为 $x_0, x_1, \dots, x_n$, 取多项式基函数

$$\begin{cases} \varphi_0(x) = 1 \\ \varphi_1(x) = (x - x_0) \\ \varphi_2(x) = (x - x_0)(x - x_1) \\ \vdots \\ \varphi_n(x) = (x - x_0)(x - x_1) \cdots (x - x_{n-1}) \end{cases}$$

则多项式插值函数为

$$g(x) = \sum_{i=0}^n c_i \varphi_i(x)$$

称为牛顿插值多项式, 其中多项式系数 c_i 为 $f(x)$ 关于节点 $x_0, x_1, \dots, x_i$ 的 i 阶 **差商** 或 **均差** $f[x_0, x_1, \dots, x_i]$



• 多项式函数插值方法

➤ 牛顿 (Newton) 插值法

因此, 牛顿插值多项式函数为

$$g(x) = \sum_{i=0}^n c_i \varphi_i(x)$$

的系数 c_i 为

x_i	$f(x_i)$	一阶差商	二阶差商	三阶差商	四阶差商
x_0	$f(x_0)$				
x_1	$f(x_1)$	$f[x_0, x_1]$			
x_2	$f(x_2)$	$f[x_1, x_2]$	$f[x_0, x_1, x_2]$		
x_3	$f(x_3)$	$f[x_2, x_3]$	$f[x_1, x_2, x_3]$	$f[x_0, x_1, x_2, x_3]$	
x_4	$f(x_4)$	$f[x_3, x_4]$	$f[x_2, x_3, x_4]$	$f[x_1, x_2, x_3, x_4]$	$f[x_0, x_1, x_2, x_3, x_4]$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

c_0

c_1

c_2

c_3

c_4



• 多项式函数插值方法

➤ 牛顿 (Newton) 插值法

• 牛顿插值法余项

由于插值多项式具有唯一性, 所以

$$r(x) = |f(x) - g(x)| = \left| \frac{f^{n+1}(\xi)}{(n+1)!} \omega_{n+1}(x) \right|$$

• 范例: 函数 $f(x)$ 相关数据如下图

x_i	$f(x_k)$	一阶均差	二阶均差	三阶均差	四阶均差
0.40	0.41075				
0.55	0.57815	1.11600			
0.65	0.69675	1.18600	0.28000		
0.80	0.88811	1.27573	0.35893	0.19733	
0.90	1.02652	1.38410	0.43348	0.21300	0.03134

C_0
 C_1
 C_2
 C_3
 C_4



- 多项式函数插值方法

- 牛顿 (Newton) 插值法

- 范例

由于五阶差商较小近似零，可按四次牛顿插值公式带入数据，计算得

$$\begin{aligned} g(x) = & 0.41075 + 1.116(x - 0.4) \\ & + 0.28(x - 0.4)(x - 0.55) \\ & + 0.19733(x - 0.4)(x - 0.55)(x - 0.65) \\ & + 0.03134(x - 0.4)(x - 0.55)(x - 0.65)(x - 0.8) \end{aligned}$$

- 范例：如果给定数据样本为

$$\begin{aligned} & (0,0), (1, 0.8415), (2, 0.9093), \\ & (3, 0.1411), (4, -0.7568), \\ & (5, -0.9589), (6, -0.2794) \end{aligned}$$



• 多项式函数插值方法

➤ 牛顿 (Newton) 插值法

- 范例：用拉格朗日插值法或牛顿法分别计算出多项式插值函数为

$$g(x) = -0.0001521x^6 - 0.003130x^5 + 0.07321x^4 \\ -0.3577x^3 + 0.2255x^2 + 0.9038x$$

- 优缺点

- 共同点：拉格朗日插值多项式函数和牛顿插值多项式函数方法不同，但插值函数的结果相同，验证了多项式插值函数的唯一性
- 优点：比拉格朗日多项式插值的计算量少，当新增一个插值点时，拉格朗日插值需要重新计算全部的基函数，而牛顿插值只需计算均差表中新的一行的值即可
- 缺点：和拉格朗日插值方法相同，插值曲线在节点处有尖点，不光滑，节点处不可导



• 样条曲线插值

■ 样条插值 (Spline Interpolation) 的定义

设在区间 $[a, b]$ 上取 $n + 1$ 个节点 $a \leq x_0 < x_1 < x_2 < \dots < x_n \leq b$, 函数 $y = f(x)$ 在各节点处的函数值为 $y_i = f(x_i), (i = 0, 1, \dots, n)$, 若函数 $g(x)$ 满足:

- $g(x_i) = y_i, i = 0, 1, \dots, n$
- 在区间 $[a, b]$ 上, $g(x)$ 具有**连续的二阶导数**
- 在区间 $[x_i, x_{i+1}](i = 0, 1, \dots, n - 1)$ 上, $g(x)$ 是关于 x 的**三次多项式**

则称 $g(x)$ 是函数 $y = f(x)$ 在区间 $[a, b]$ 上的**三次样条插值函数**

- 分段性: 把区间 $[a, b]$ 分成 n 个区间, $[x_0, x_1], \dots, [x_i, x_{i+1}]$, 共有 $n + 1$ 个点, **分段**三次样条就是每个小区间的曲线是一个三次方程
- 虽然每个子区间上的多项式可以各不相同, 但其在相邻子区间的连接处是光滑的, 故样条插值也称为**分段光滑插值**



• 样条曲线插值

■ 三次样条插值的解法

$g(x)$ 在每个小区间 $[x_i, x_{i+1}]$ 上的表达式记为 $g_i(x)$, 即

$$g(x) = \begin{cases} g_0(x), & x \in [x_0, x_1] \\ g_1(x), & x \in [x_1, x_2] \\ \vdots & \\ g_{n-1}(x), & x \in [x_{n-1}, x_n] \end{cases}$$

其中, 在区间 $[x_i, x_{i+1}]$ 上, $g_i(x)$ 为三次多项式, 因而有 4 个待定系数, 共有 n 个小区间, 故总共应有 $4n$ 个待定系统, 需 $4n$ 个方程

➤ 首先, 根据 $g(x)$ 在 $[a, b]$ 上的二阶导数连续, 即

$$g(x) \in C^2[a, b]$$



• 样条曲线插值

■ 三次样条插值的解法

- 因此，在所有 $i = 1, 2, \dots, n-1$ 的节点 x_i 处满足连续性条件：

$$\begin{aligned}g(x_i - 0) &= g(x_i + 0) \\g'(x_i - 0) &= g'(x_i + 0) \\g''(x_i - 0) &= g''(x_i + 0)\end{aligned}$$

故共有 $3n - 3$ 个条件



- 其次，对于 $i = 0, 1, \dots, n$ ，有 $n + 1$ 个插值条件 $g(x_i) = y_i$ ，因此共计有 $4n - 2$ 个已知条件，还需要 2 条件才能确定 $g(x)$
- 实际问题中，通常会对样条函数 $g(x)$ 在两个端点 $x = a$ 和 $x = b$ 处的状态有一定的要求，即在区间端点上各加一个边界条件，该条件可根据实际问题的要求给定，通常有以下几种：



• 样条曲线插值

■ 三次样条插值的解法

➤ 边界条件:

① 第一类边界: 指定函数在两端点处的一阶导数, 即

$$g'(x_0) = f'_0, \quad g'(x_n) = f'_n$$

* 固定边界 (Clamped Spline):


$$g'(a) = A, \quad g'(b) = B$$

② 第二类边界: 已知端点的二阶导数, 即

$$g''(x_0) = f''_0, \quad g''(x_n) = f''_n$$

* 自然边界 (Natural Spline):

$$g''(x_0) = g''(x_n) = 0$$





• 样条曲线插值

■ 三次样条插值的解法

- ③ 第三类边界：强制第一个插值点的三阶导数值等于第二个点的三阶导数值，最后一个点的三阶导数值等于倒数第二个点的三阶导数值，也称**非扭结边界 (Not-A-Knot Spline)**，即

$$g'''(x_0) = g'''(x_1), \quad g'''(x_{n-1}) = g'''(x_n)$$

- ④ 第四类边界：当 $f(x)$ 是以 $x_n - x_0$ 为周期的函数时，则要求 $g(x)$ 也是周期函数，这时边界条件应满足

$$\begin{aligned} g(x_0) &= g(x_n) \\ g'(x_0 + 0) &= g'(x_n - 0) \\ g''(x_0 + 0) &= g''(x_n - 0) \end{aligned}$$

此时 $y_0 = y_n$ ，这样确定的样条函数 $g(x)$ 称为**周期样条函数**



• 样条曲线插值

■ 三次样条插值的计算

由于 $g(x)$ 二阶可导，所以对于 $i = 0, 1, 2, \dots, n$ 可设

$$g''(x_i) = m_i$$

下面用 m_i 参数化表示 $g(x)$

➤ 考虑 $g(x)$ 在区间 $[x_i, x_{i+1}]$ 上的表达式为 $g_i(x)$ ，满足

$$g_i''(x_i) = m_i, \quad g_i''(x_{i+1}) = m_{i+1}$$

因 $g_i(x)$ 是三次多项式，故 $g_i''(x)$ 为线性函数，所以由线性插值公式

$$g_i''(x) = \frac{x_{i+1} - x}{h_i} m_i + \frac{x - x_i}{h_i} m_{i+1}$$

其中

$$h_i = x_{i+1} - x_i$$



• 样条曲线插值

■ 三次样条插值的计算

➤ 两边在区间 $[x_i, x_{i+1}]$ 上对 $g_i''(x)$ 上积分两次后可得

$$g_i(x) = \frac{(x_{i+1} - x)^3}{6h_i} m_i + \frac{(x - x_i)^3}{6h_i} m_{i+1} + c_1 x + c_2$$

其中 c_1, c_2 为积分常数, 将 $g_i(x_i) = y_i$, $g_i(x_{i+1}) = y_{i+1}$ 代入后可得

$$c_1 = \frac{1}{h_i} (y_{i+1} - y_i) - \frac{h_i}{6} (m_{i+1} - m_i) = \frac{1}{h_i} \left[\left(y_{i+1} - \frac{m_{i+1} h_i^2}{6} \right) - \left(y_i - \frac{m_i h_i^2}{6} \right) \right]$$

$$c_2 = y_i - \frac{m_i h_i^2}{6} - c_1 x_i = \frac{x_{i+1}}{h_i} \left(y_i - \frac{m_i h_i^2}{6} \right) - \frac{x_i}{h_i} \left(y_{i+1} - \frac{m_{i+1} h_i^2}{6} \right)$$



• 样条曲线插值

■ 三次样条插值的计算

➤ 运用 c_1, c_2 表达式以及 $x_{i+1} = x_i + h_i$ 可得

$$g_i(x) = \frac{m_{i+1} - m_i}{6h_i}(x - x_i)^3 + \frac{m_i}{2}(x - x_i)^2 + \left(\frac{y_{i+1} - y_i}{h_i} - \frac{h_i(m_{i+1} + 2m_i)}{6}\right)(x - x_i) + y_i$$

➤ 由于 $g(x) \in C^2[a, b]$, 所以在节点处的一阶导数也存在, 故

$$g'(x_i^-) = g'(x_i^+), \quad i = 1, 2, \dots, n-1$$

也即

$$g'_{i-1}(x_i^-) = g'_i(x_i^+)$$

所以可得方程

$$\frac{h_{i-1}}{6}m_{i-1} + \frac{h_{i-1} + h_i}{3}m_i + \frac{h_i}{6}m_{i+1} = \frac{y_{i+1} - y_i}{h_i} - \frac{y_i - y_{i-1}}{h_{i-1}}$$



• 样条曲线插值

■ 三次样条插值的计算

➤ 记

$$\mu_i = \frac{h_{i-1}}{h_{i-1} + h_i}, \quad \lambda_i = \frac{h_i}{h_{i-1} + h_i}$$

$$\epsilon_i = \frac{6(f[x_i, x_{i+1}] - f[x_{i-1}, x_i])}{h_{i-1} + h_i} = 6f[x_{i-1}, x_i, x_{i+1}]$$

则对于 $i = 1, 2, \dots, n-1$ 有方程组

$$\mu_i m_{i-1} + 2m_i + \lambda_i m_{i+1} = \epsilon_i$$

其中 $\mu_i + \lambda_i = 1$ ，并且上述方程组也可写成

$$h_{i-1}m_{i-1} + 2(h_{i-1} + h_i)m_i + h_i m_{i+1} = 6(f[x_i, x_{i+1}] - f[x_{i-1}, x_i])$$

此处有 $n+1$ 个变量，但只有 $n-1$ 个方程，需增加两个边界条件



• 样条曲线插值

■ 三次样条插值的计算

1) 第一类边界条件时, 给出函数在两端点处的一阶导数:

$$g'(x_0) = f'_0, \quad g'(x_n) = f'_n$$

即 $g'_0(x_0^+) = f'_0$, $g'_n(x_n^-) = f'_n$, 令

$$\epsilon_0 = \frac{6}{h_0} (f[x_0, x_1] - f'(x_0)), \quad \epsilon_n = \frac{6}{h_{n-1}} (f'(x_n) - f[x_{n-1}, x_n])$$

则

$$\begin{bmatrix} 2 & 1 & & & \\ \mu_1 & 2 & \lambda_1 & & \\ & \ddots & \ddots & \ddots & \\ & & \mu_{n-1} & 2 & \lambda_{n-1} \\ & & & 1 & 2 \end{bmatrix} \begin{bmatrix} m_0 \\ m_1 \\ \vdots \\ m_{n-1} \\ m_n \end{bmatrix} = \begin{bmatrix} \epsilon_0 \\ \epsilon_1 \\ \vdots \\ \epsilon_{n-1} \\ \epsilon_n \end{bmatrix}$$

且系数矩阵严格对角占优, 因此存在唯一解



• 样条曲线插值

■ 三次样条插值的计算

2) 第二类边界条件时, 给出函数在两端点处的二阶导数:

$$g''(x_0) = f_0'', \quad g''(x_n) = f_n''$$

即 $m_0 = f_0''$, $m_n = f_n''$, 则可得方程组

$$\begin{bmatrix} 2 & \lambda_1 & & & \\ \mu_2 & 2 & \lambda_2 & & \\ & \ddots & \ddots & \ddots & \\ & & \mu_{n-2} & 2 & \lambda_{n-2} \\ & & & \mu_{n-1} & 2 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ \vdots \\ m_{n-2} \\ m_{n-1} \end{bmatrix} = \begin{bmatrix} \epsilon_1 - \mu_1 f_0'' \\ \epsilon_2 \\ \vdots \\ \epsilon_{n-2} \\ \epsilon_{n-1} - \lambda_{n-1} f_n'' \end{bmatrix}$$

此为 $(n-1) \times (n-1)$ 的线性方程组, 系数矩阵严格对角占优, 则存在唯一解, 因此也可使用高斯消去法或追赶法来求解



• 样条曲线插值

■ 三次样条插值的计算

3) 第四类边界条件时, 要求 $g(x)$ 是周期函数, 满足

$$g'(x_0^+) = g'(x_n^-), \quad g''(x_0^+) = g''(x_n^-)$$

即 $g'_0(x_0^+) = g'_n(x_n^-)$, $g''_0(x_0^+) = g''_n(x_n^-)$, 则可得方程组

$$\begin{bmatrix} 2 & \lambda_1 & & & \\ \mu_2 & 2 & \lambda_2 & & \\ & \ddots & \ddots & \ddots & \\ & & \mu_{n-1} & 2 & \lambda_{n-1} \\ & & & \mu_n & 2 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ \vdots \\ m_{n-1} \\ m_n \end{bmatrix} = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_{n-1} \\ \epsilon_n \end{bmatrix}$$

此为 $(n) \times (n)$ 的线性方程组, 系数矩阵严格对角占优, 则存在唯一解, 因此也可使用高斯消去法或追赶法来求解



• 样条曲线插值

■ 三次样条插值的解法

➤ 算法总结

假定有 $n + 1$ 个数据点

$$(x_0, y_0), (x_1, y_1), (x_2, y_2) \cdots (x_{n-1}, y_{n-1}), (x_n, y_n)$$

1. 计算步长 $h_i = x_{i+1} - x_i$
2. 根据给定的插值条件和边界条件带入关于 $m_0, m_1, \cdots, m_n$ 的线性方程
3. 解决线性方程组, 得到 $m_0, m_1, \cdots, m_n$
4. 将 m_i 代入 $g_i(x)$ 的表达式

$$g_i(x) = \frac{m_{i+1} - m_i}{6h_i} (x - x_i)^3 + \frac{m_i}{2} (x - x_i)^2 + \left(\frac{y_{i+1} - y_i}{h_i} - \frac{h_i(m_{i+1} + 2m_i)}{6} \right) (x - x_i) + y_i$$

5. 最终, 可得到 $g(x)$ 在插值区间 $[a, b]$ 上的分段表达式



• 样条曲线插值

■ 三次样条插值的解法

➤ 范例：函数 $f(x)$ 定义在 $[27.7, 30]$ 上，插值节点及函数值如下表，

x	27.7	28	29	30
$f(x)$	4.1	4.3	4.1	3.0

且三次样条插值多项式 $g(x)$ 满足边界条件 $g'(27.7) = 3.0$, $g'(30) = -4.0$ ，则首先做差商表

x_i	y_i	一阶差商	二阶差商
27.7	4.1		
28	4.3	$2/3$	
29	4.1	-0.2	$-2/3$
30	3.0	-1.1	$-9/20$



• 样条曲线插值

■ 三次样条插值的解法

➤ 范例：并可知 $h_0 = 0.3$, $h_1 = 1$, $h_2 = 1$, 所以可计算得

$$\mu_1 = \frac{h_0}{h_0 + h_1} = \frac{3}{13}, \quad \lambda_1 = 1 - \mu_1 = \frac{10}{13},$$

$$\mu_2 = \frac{h_1}{h_1 + h_2} = \frac{1}{2}, \quad \lambda_2 = 1 - \mu_2 = \frac{1}{2}$$

$$\epsilon_0 = \frac{6}{h_0} (f[x_0, x_1] - f'_0) = 20 \left(\frac{2}{3} - 3 \right) = -\frac{140}{3}$$

$$\epsilon_1 = 6f[x_0, x_1, x_2] = -4, \quad \epsilon_2 = 6f[x_1, x_2, x_3] = -2.7$$

$$\epsilon_3 = \frac{6}{h_2} (f'_3 - f[x_2, x_3]) = 6(-4 + 1.1) = -17.4$$



• 样条曲线插值

■ 三次样条插值的解法

➤ 范例：可得线性方程组

$$\begin{bmatrix} 2 & 1 & 0 & 0 \\ 3/13 & 2 & 10/13 & 0 \\ 0 & 1/2 & 2 & 1/2 \\ 0 & 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} m_0 \\ m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} -140/3 \\ -4 \\ -2.7 \\ -17.4 \end{bmatrix}$$

利用追赶法，可解得

$$m_0 = -\frac{7130}{303} \approx -23.531, \quad m_1 = \frac{40}{101} \approx 0.396$$

$$m_2 = \frac{419}{505} \approx 0.830, \quad m_3 = -\frac{4603}{505} \approx -9.115$$

代入 $g(x)$ 的表达式可得

$$g(x) = \begin{cases} -13.293(x-27.7)^3 - 11.766(x-27.7)^2 + 3(x-27.7) + 4.1, & x \in [27.7, 28] \\ 0.072(x-28)^3 + 0.198(x-28)^2 + 0.47(x-28) + 4.3, & x \in [28, 29] \\ -1.657(x-29)^3 + 0.415(x-29)^2 + 0.143(x-29) + 4.1, & x \in [29, 30] \end{cases}$$



• 径向基函数插值

■ 径向基函数（Radial Basis Function）的定义

是某种沿径向对称的标量函数，通常定义为样本空间中任一点 x 到数据中心 c 之间径向距离（通常是欧氏距离）的单调函数（由于距离是径向同性的），当样本 x 远离数据中心 c 时函数取值近零

➤ 径向基函数在支持向量机分类中用作核函数

■ 径向基函数的类别

给定 $r = ||x - x_i||$ ，常见的径向基函数包括

➤ 高斯函数（Gauss Function）

$$\phi(r) = e^{-(\epsilon r)^2}$$

➤ 多二次函数（Multi-quadric Function）

$$\phi(r) = 1 + (\epsilon r)^2$$



• 径向基函数插值

■ 径向基函数的类别

- 逆二次函数 (Inverse Quadric Function)

$$\phi(r) = \sqrt{1 + (\epsilon r)^2}$$

- 逆多二次函数 (Inverse Multi-quadric Function)

$$\phi(r) = \frac{1}{\sqrt{1 + (\epsilon r)^2}}$$

- 多重调和样条函数 (Polyharmonic Spline Function)

$$\phi(r) = r^k, \quad k = 1, 3, 5, \dots$$

$$\phi(r) = r^k \ln(r), \quad k = 2, 4, 6, \dots$$

- 薄板样条 (Thin-plate Spline Function, 为多重调和样条的特例)

$$\phi(r) = r^2 \ln(r)$$



• 径向基函数插值

■ 径向基函数插值的定义

给定 $n + 1$ 个不同的插值点 $\{(x_i, y_i)\}_{i=0}^n$ ，定义插值函数形式为

$$g(x) = \sum_{i=0}^n c_i \varphi_i(x)$$

其中， c_i 为未知系数，基函数 $\varphi_i(x)$ 为径向基函数 $\phi(\|x - x_i\|)$ ， $\|x - x_i\|$ 表示 x 与中心点 x_i 之间的欧几里得距离

■ 径向基函数插值的解法

假设有 $n + 1$ 个插值节点，即 $(x_0, y_0), (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ ，插值函数 $g(x)$ 满足插值条件

$$g(x_i) = y_i = f(x_i)$$

将 $\{(x_i, y_i)\}_{i=0}^n$ 带入方程 $g(x) = \sum_{i=1}^n c_i \phi(\|x - x_i\|)$ ，可得



• 径向基函数插值

■ 径向基函数插值的解法

关于参数变量 $c_0, c_1, \dots, c_n$ 的线性方程组

$$\underbrace{\begin{bmatrix} \phi(\|x_0 - x_0\|) & \cdots & \phi(\|x_0 - x_n\|) \\ \phi(\|x_1 - x_0\|) & \cdots & \phi(\|x_1 - x_n\|) \\ \vdots & \ddots & \vdots \\ \phi(\|x_n - x_1\|) & \cdots & \phi(\|x_n - x_n\|) \end{bmatrix}}_{\Phi} \underbrace{\begin{bmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{bmatrix}}_{\mathbf{c}} = \underbrace{\begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{bmatrix}}_{\mathbf{y}},$$

其中矩阵 Φ 为插值矩阵,

➤ 插值矩阵 Φ 为对称矩阵:

$$\phi(\|x_j - x_i\|) = \phi(\|x_i - x_j\|)$$

➤ 对于高斯核函数而言, 插值矩阵的对角线元素值为

$$\phi(\|x_i - x_i\|) = 1$$



• 径向基函数插值

■ 径向基函数插值的解法

将线性方程组记为



$$\Phi c = y$$

其中 c 是未知参数向量, Φ 是数据集得到的值, y 是数据集对应的输出值向量, 该方程组的第 i 行为:

$$g(x_i) = y_i = \sum_j^n c_j \phi(\|x_i - x_j\|)$$

因此, 可求出径向基插值函数的系数为

$$W = \phi^{-1}y$$





• 径向基函数插值

■ 径向基函数插值的解法

- 例题：假设有三个数据点：(1, 1), (3, 0.2), (3.5, 0.1)，选择如下高斯径向作为向基函数

$$\varphi(r) = e^{-r^2}$$

下面通过求解线性方程组，计算参数 c_0, c_1, c_2

$$\begin{bmatrix} \varphi(0) & \varphi(2) & \varphi(2.5) \\ \varphi(2) & \varphi(0) & \varphi(0.5) \\ \varphi(2.5) & \varphi(0.5) & \varphi(0) \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} y_0 \\ y_1 \\ y_3 \end{bmatrix}$$



$$\begin{bmatrix} 1 & 0.02 & 0.002 \\ 0.02 & 1 & 0.78 \\ 0.002 & 0.78 & 1 \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 0.2 \\ 0.1 \end{bmatrix}$$

因此，解得 $c_0 = 0.995$, $c_1 = 0.268$, $c_2 = -0.111$



• 径向基函数插值


■ 径向基函数插值的解法

➤ 例题

因此，最终解得径向基插值函数为



$$g(x) = 0.995\varphi(|x - 1|) + 0.268\varphi(|x - 3|) - 0.111\varphi(|x - 3.5|)$$

该插值函数的曲线如图所示，
虚线绘制的三个函数代表每个数据点的在插值函数中的贡献值，在 x 的任何值处，对这些函数求和即得到此时插值的函数值



4-2

函数拟合





• 曲线拟合基础

曲线拟合又称函数拟合，是一种用连续的函数（解析表达式或曲线）或更加密集的离散方程近似地刻画平面上离点组所表示的坐标之间函数关系的数据处理方法

■ 曲线拟合（Curve Fitting）的定义

在科学实验或社会活动中，构建解析表达式

$$y = g(x, c)$$

用于反映对象输入量与输出量之间的依赖关系，并要求在某种准则下“最佳”地逼近已知的实验或观测数据对

$$(x_0, y_0), (x_1, y_1), (x_2, y_2), \dots, (x_{n-1}, y_{n-1}), (x_n, y_n)$$

其中， x_i 一般两两不同的，解析表达式 $y = g(x, c)$ 称作拟合模型， $\{c_0, c_1, \dots, c_m\}$ 为待定参数



➢ 机器学习中的方法如神经网络、深度学习，本质就是拟合问题



• 曲线拟合基础

■ 曲线拟合（Curve Fitting）的定义

- 插值是找到一个（或几个分段/分片光滑的）连续曲线/曲面穿过样本数据点
- 拟合找到一个已知形式未知参数的连续曲线/曲面来最大限度地逼近已知样本数据点；两者都属于函数逼近，有时候将用较简单的函数近似代替复杂的连续函数称为逼近





• 拟合模型

当 $\mathbf{c}$ 在拟合模型 $g(\cdot, \mathbf{c})$ 中以线性组合的形式出现时, 称为**线性模型**, 否则称为**非线性模型**

■ 线性拟合 (Linear Fitting)

➤ 直线形式

$$y = c_0 + c_1 x$$

➤ 多项式形式

$$y = c_0 + c_1 x + c_2 x^2$$

$$y = c_0 + c_1 x + c_2 x^2 + c_3 x^3$$

➤ 对数形式或指数形式

$$y = c_0 + c_1 e^x + c_2 e^{x^2}$$

$$y = c_0 + c_1 \log x + c_2 \log x^2$$

* 只要给定与未知参数 c_i 个数相等的任何限制, 例如相异采样点 (x_i, y_i) 、角度或曲率 (即半径的倒数)



• 拟合模型

■ 非线性拟合 (Non-Linear Fitting)

即采用非线性的拟合模型，参数与输出量之间关系为非线性

➤ 例如

$$y = c_0 x^{c_1}$$

➤ 一般来说，非线性模型的自变量对应的参数不止一个

➤ 区分是否为线性模型，主要是看一个乘法式子中自变量 x 的相关系数 c ，如果 x 只被一个参数 c 影响，那么此模型为线性模型，例如

$$y = \frac{1}{1 + e^{c_0 + c_1 x + c_2 x^2}}$$

应变变量 y 和自变量 x 为曲线关系，但是它是线性模型，因为在 $c_1 x$ 中可以观察到 x 只被一个 c_1 影响；在 $c_2 x^2$ 中也可以观察到 x^2 只被一个 c_2 影响



• 拟合模型

■ 非线性拟合（Non-Linear Fitting）的定义


➢ 再例如

$$y = \frac{1}{1 + c_3 e^{c_0 + c_1 x + c_2 x^2}}$$

是非线性模型，因为乘积项 $c_1 x$ 不仅仅被参数 c_1 影响，还被 c_3 影响，如果自变量 x 被两个及两个以上的参数影响，那么此模型是非线性的

■ 常见拟合的模型

线性拟合、多项式拟合、指数或对数拟合、高斯拟合等





• 拟合准则性

■ 线性最小二乘法 (Ordinary Least Square Methods) 的定义

根据定义，令拟合函数为

$$g(x, \mathbf{c}) = \sum_{k=0}^m c_k \varphi_k(x)$$

其中， $\{\varphi_0(x), \dots, \varphi_m(x)\}$ 为事先选定的一组 **线性无关的基函数**， c_k 是待定系数 ($k = 0, \dots, m, m < n$)，如果“最佳”逼近准则是使计算值 $g(x_i, \mathbf{c})$, ($i = 0, \dots, n$) 与测量值 y_i 之间 **距离的平方和最小**，即

$$\min_{\mathbf{c} \in R^{m+1}} L(\mathbf{c}) = \min_{\mathbf{c} \in R^{m+1}} \sum_{i=0}^n [g(x_i, \mathbf{c}) - y_i]^2$$

则该准则称为 **最小二乘准则**，使用最小二乘准则计算线性组合待定参数的方法称为 **线性最小二乘法**

➤ 在机器学习中， $L(\mathbf{c})$ 也称为 **损失函数**



• 拟合准则性

■ 线性最小二乘法的解法

将 $g(x, \mathbf{c})$ 代入损失函数 $L(\mathbf{c})$, 根据极值的充要条件, 令损失函数关于参数 c_k 的偏导数为 0,

$$\frac{\partial L}{\partial c_k} = 0$$

得到关于 $c_0, c_1, \dots, c_m$ 的线性方程组

$$\sum_{i=0}^n \varphi_j(x_i) \left(\sum_{k=0}^m c_k \varphi_k(x_i) - y_i \right) = 0, \quad j = 0, \dots, m$$

整理得:

$$\sum_{k=0}^m c_k \sum_{i=0}^n \varphi_j(x_i) \varphi_k(x_i) = \sum_{i=0}^n \varphi_j(x_i) y_i, \quad j = 0, \dots, m$$



• 拟合准则性

■ 线性最小二乘法的解法

令

$$\Psi = \begin{bmatrix} \varphi_0(x_0) & \cdots & \varphi_m(x_0) \\ \vdots & \ddots & \vdots \\ \varphi_0(x_n) & \cdots & \varphi_m(x_n) \end{bmatrix}_{(n+1) \times (m+1)}$$

$$\mathbf{c} = [c_0, \cdots, c_m]^T$$

$$\mathbf{y} = [y_0, \cdots, y_n]^T$$

因此，线性方程组可表示为如下**正规方程**（法方程，正则方程）

$$\Psi^T \Psi \mathbf{c} = \Psi^T \mathbf{y}$$

由于 $\{\varphi_0(x), \cdots, \varphi_m(x)\}$ 线性无关， $\Psi^T \Psi$ 可逆，方程组有唯一解：

$$\mathbf{c}^* := (c_0^*, \cdots, c_m^*)^T = (\Psi^T \Psi)^{-1} \Psi^T \mathbf{y}$$



• 拟合准则性

■ 线性最小二乘法的解法

➢ 函数拟合的余项

$$r(x) = ||\mathbf{y}||_2^2 - \sum_{i=0}^m c_i^* \left(\sum_{j=0}^n y_j \varphi_i(x_j) \right)$$

- 常见的线性无关基函数组为 $\{1, x\}$ 、 $\{1, x, \dots, x^m\}$ ，前者表示直线拟合，后者表示一般的二次以上的多项式拟合

■ 多项式数据拟合

多项式拟合函数的基函数 $\{1, x, \dots, x^m\}$ ，这里 $m \leq n$ ，一般为不超过 m 次的多项式集合，并且此时

$$\sum_{j=0}^n y_j \varphi_i(x_j) = \sum_{j=0}^n y_j x_j^i$$



• 拟合准则性

■ 多项式数据拟合

因此，正规方程变为

$$\begin{bmatrix} n+1 & \sum_{i=0}^n x_i & \cdots & \sum_{i=0}^n x_i^m \\ \sum_{i=0}^n x_i & \sum_{i=0}^n x_i^2 & \cdots & \sum_{i=0}^n x_i^{m+1} \\ \sum_{i=0}^n x_i^2 & \sum_{i=0}^n x_i^3 & \cdots & \sum_{i=0}^n x_i^{m+2} \\ \vdots & \vdots & \vdots & \vdots \\ \sum_{i=0}^n x_i^m & \sum_{i=0}^n x_i^{m+1} & \cdots & \sum_{i=0}^n x_i^{2m} \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \\ \vdots \\ c_m \end{bmatrix} = \begin{bmatrix} \sum_{i=0}^n y_i \\ \sum_{i=0}^n y_i x_i \\ \sum_{i=0}^n y_i x_i^2 \\ \vdots \\ \sum_{i=0}^n y_i x_i^m \end{bmatrix}$$



• 拟合准则性

■ 多项式数据拟合

➤ 范例：设有如下数据

x	1	3	4	5	6	7	8	9	10
y	10	5	4	2	1	1	2	3	4

利用最小二乘法选取多项式拟合曲线

$$g(x) = c_0 + c_1x + c_2x^2$$

并且正规方程为

$$\begin{bmatrix} 9 & 53 & 381 \\ 53 & 381 & 3017 \\ 381 & 3017 & 25317 \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 32 \\ 147 \\ 1025 \end{bmatrix}$$

其中矩阵与向量元素由下表计算所得



• 拟合准则性

■ 多项式数据拟合

i	x_i	y_i	x_i^2	x_i^3	x_i^4	$x_i y_i$	$x_i^2 y_i$
0	1	10	1	1	1	10	10
1	3	5	9	27	81	15	45
2	4	4	16	64	256	16	64
3	5	2	25	125	625	10	50
4	6	1	36	216	1296	6	36
5	7	1	49	343	2401	7	49
6	8	2	64	512	4096	16	128
7	9	3	81	729	6561	27	243
8	10	4	100	1000	10000	40	400
求和	53	32	381	3017	25317	147	1025



• 拟合准则性

■ 多项式数据拟合


➤ 接上，解得

$$c_0 = 13.4597, \quad c_1 = -3.6053, \quad c_2 = 0.2676$$

因此，所求得的二次多项式拟合曲线方程为

$$g(x) = 13.4597 - 3.6053x + 0.2676x^2$$

所对应的曲线图





• 拟合准则性

■ 非线性最小二乘曲线拟合的定义

对于以误差的平方和最小为准则来估计非线性静态模型参数的参数估计方法，其中拟合模型 $y = g(x, c)$ 为关于参数 c 的非线性函数

■ 非线性最小二乘曲线拟合的解法

对于某些数据可做适当的变换，转化为线性拟合问题

曲线拟合方程	变量转换关系	变换后的线性拟合关系
$y = ax^b$	$Y = \ln y, X = \ln x, A = \ln a$	$Y = A + bX$
$y = ax^b + c$	$Y = y, X = x^b$	$Y = aX + c$
$y = ae^{bx}$	$Y = \ln y, X = x, A = \ln a$	$Y = A + bX$
$y = a + b \ln x$	$Y = y, X = \ln x$	$Y = aX + b$
$y = \frac{x}{ax + b}$	$Y = \frac{1}{y}, X = \frac{1}{x}$	$Y = aX + b$
$y = \frac{e^{a+bx}}{1 + e^{a+bx}}$	$Y = \ln \frac{y}{1-y}, X = x$	$Y = aX + b$



• 拟合准则性

■ 非线性最小二乘曲线拟合的解法

- 范例：给定数据如下表所示，求一个形如 $y = ae^{bx}$ 的经验公式
(a, b 为常数)

x_i	1	2	3	4	5	6	7	8
y_i	15.3	20.5	27.4	36.6	49.1	65.6	87.8	117.6

两边取对数有 $\ln y = \ln a + bx$ ，令 $Y = \ln y$ ， $A = \ln a$ ，则有

$$Y = A + bx$$

因此，可得正规方程为

$$\begin{bmatrix} 8 & 36 \\ 36 & 204 \end{bmatrix} \begin{bmatrix} A \\ b \end{bmatrix} = \begin{bmatrix} 29.9787 \\ 147.1354 \end{bmatrix}$$

其中方程组系数由下表获得



• 拟合准则性

■ 非线性最小二乘曲线拟合的解法

➤ 范例：

j	x_i	y_i	Y_i	x_i^2	$x_i Y_i$
0	1	15.3	2.7279	1	2.7279
1	2	20.5	3.0204	4	6.0408
2	3	27.4	3.3105	9	9.9315
3	4	36.6	3.6000	16	14.4000
4	5	49.1	3.8939	25	19.4695
5	6	65.6	4.1836	36	25.1016
6	7	87.8	4.4751	49	31.3257
7	8	117.6	4.7673	64	38.1384
总和	36	—	29.9787	204	147.1354



拟合准则性

非线性最小二乘曲线拟合的解法

范例：因此，解之有


$$A = 2.4368, b = 0.2912$$

故 $a = e^A = 11.4369$

拟合的经验公式为

$$y = 11.4369e^{0.2912x}$$

因此，通过拟合函数可得相应的拟合值，记 $\tilde{y}_i$ ，并可计算拟合误差 r_i



x_i	1	2	3	4	5	6	7	8
y_i	15.3	20.5	27.4	36.6	49.1	65.6	87.8	117.6
$\tilde{y}_i$	15.30	20.48	27.40	36.66	49.05	65.64	87.83	117.52
$ r_i $	0.0034	0.0232	0.0010	0.0614	0.0451	0.0381	0.0273	0.0824