



人工智能数学基础

线性代数

刘昌鑫

华东理工大学

信息科学与工程学院 自动化系

能源化工过程智能制造教育部重点实验室

目录

2

线性代数

2-1 向量

2-2 矩阵

2-3 行列式



2-4 线性方程组

2-5 二次型

2-6 矩阵分解

2-1

向量






- **向量 (Vector) 与标量 (Scalar) 的定义**

由 n 个数 $x_1, \dots, x_n$ 构成的具有大小和方向的 n 元数组

$$\mathbf{x} = [x_1, \dots, x_n]^T$$

分量



- **向量的几何意义**

可用有向线段来表示：有向线段的长度表示向量的大小，也就是向量的长度，长度为 **0** 的向量叫做零向量，记作长度等于 **1** 个单位的向量，叫做单位向量，箭头所指的方向表示向量的方向


- **向量与数据**

- 在机器学习中，把对事件或对象的描述称为**样本**，反映样本某方面的表现或性质的事项称为**特征**或**属性**，特征的取值称为**特征值**，由样本组成的集合称为数据集；
- 样本数据通常用向量的形式表示，称为特征向量 (Feature Vector)



■ 鸢/yuān/尾花 (Iris) 数据集

- 是模式识别、机器学习等领域里被使用最多的一个数据集之一
- 收集了Setosa 鸢尾花、Versicolour 鸢尾花、 Virginica 鸢尾花，每一类50条样本记录，共计150条
- 数据集包括4个属性：花萼的长、花萼的宽、花瓣的长和花瓣的宽
- 用四维行向量表示四个特征值组成的一个样本



萼长和萼宽属性的散布图


	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa
...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	virginica
146	6.3	2.5	5.0	1.9	virginica
147	6.5	3.0	5.2	2.0	virginica
148	6.2	3.4	5.4	2.3	virginica
149	5.9	3.0	5.1	1.8	virginica



• 向量的基本操作

对于向量 $\mathbf{x} = [x_1, \dots, x_n]^T$, $\mathbf{y} = [y_1, \dots, y_n]^T$

- 转置运算 (Transpose): $\mathbf{x}^T$
- 向量的加减法: $\mathbf{x} \pm \mathbf{y}$
- 向量的数 (标) 乘法: $a\mathbf{x}$, $a \in \mathbb{R}$



• 案例

设 $\mathbf{x}_1 = [1, 2, -1]^T$, $\mathbf{x}_2 = [2, -3, 1]^T$, $\mathbf{x}_3 = [4, 1, -1]^T$, 计算 $2\mathbf{x}_1 + \mathbf{x}_2 - \mathbf{x}_3$

■ Python程序

```
from numpy import*  
import numpy as np  
x1=np.array([1,2,-1])  
x2=np.array([2,-3,1])  
x3=np.array([4,1,-1])  
print(2*x1+x2-x3)
```

■ 输出结果

[0 0 0]



• 线性相关

■ 线性组合 (Linear Combination) 的定义

对于一组 n 维向量 $x_1, \dots, x_n$, 并存在一组实数 $a_1, \dots, a_n$, 使得

$$x = a_1 x_1 + \dots + a_n x_n$$

则称向量 x 可由向量组 $x_1, \dots, x_n$ 线性表达, $a_1, \dots, a_n$ 为组合系数

■ 线性相关 (Linear Dependent) 与线性独立 (Linear Independent)

对于向量组 $x_1, \dots, x_n$, 如果存在一组 **不全为0** 的实数 $a_1, \dots, a_n$, 使

$$a_1 x_1 + \dots + a_n x_n = 0$$

则称向量组 $x_1, \dots, x_n$ 线性相关; 如果不存在一组 **不全为0** 的数使得上式成立, 则称这组向量线性无关

- 向量组线性相关则存在冗余, 至少有一个向量可用其他向量线性表示
- 向量组 $x_1, \dots, x_m$ 线性相关 (**无关**) 的充要条件: 其中至少有一个 (**每个**) 向量 (**都不**) 可以由其余向量线性表示



• 线性相关

■ 向量组等价

若向量组 $x_1, \dots, x_n$ 中的每个向量均可由向量组 $y_1, \dots, y_m$ 线性表示, 则称向量组 $x_1, \dots, x_n$ 可由向量组 $y_1, \dots, y_m$ 线性表示; 若向量组 $y_1, \dots, y_m$ 也可由向量组 $x_1, \dots, x_n$ 线性表示, 则称这两个向量组等价

■ 向量组等价的性质

- 自身性: 向量组与其本身等价
- 对称性: 若向量组 $x_1, \dots, x_n$ 与向量组 $y_1, \dots, y_m$ 等价, 则向量组 $y_1, \dots, y_m$ 与向量组 $x_1, \dots, x_n$ 等价
- 传递性: 若向量组 $x_1, \dots, x_n$ 与向量组 $y_1, \dots, y_m$ 等价, 向量组 $y_1, \dots, y_m$ 与向量组 $z_1, \dots, z_n$ 等价, 则向量组 $x_1, \dots, x_n$ 与向量组 $z_1, \dots, z_n$ 等价



• 线性相关

■ 极大线性无关组

向量组数量最大的线性无关向量子集称为极大线性无关组，即若向量组 $x_1, x_2, \dots, x_n$ 中部分向量组 $x_1, x_2, \dots, x_m$, ($m \leq n$) 满足

① 向量组 $x_1, x_2, \dots, x_m$ 线性无关 (**线性独立**)

② 向量组 $x_1, x_2, \dots, x_n$ 中的任意一个向量均可由向量组 $x_1, x_2, \dots, x_m$ 线性表示；或者说，向量组 $x_1, x_2, \dots, x_n$ 中的任意 $m+1$ 个向量都线性相关

则称向量组 $x_1, x_2, \dots, x_m$ 是向量组 $x_1, x_2, \dots, x_n$ 的一个**极大线性无关向量组**

■ 极大线性无关组合的性质

➤ **极大线性无关组可能不唯一**

➤ 若向量组 $x_1, x_2, \dots, x_n$ 本身线性无关，则该向量组就是极大无关组

➤ 只含零向量的向量组没有极大无关组



• 线性相关

■ 极大线性无关组合的性质

- 向量组与其任何一个极大无关组等价，即一个向量组的任意两个极大线性无关组等价
- 若向量组中有多个极大无关组，则所有极大无关组含有向量的个数相同

■ 向量组的秩 (Rank)

向量组 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 的极大线性无关组所含向量的个数称为向量组的秩，记为 $\text{rank}(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$

- 若一个向量组中只含有零向量，则它的秩为零
- 若 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 线性无关，则 $\text{rank}(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n) = n$ ；反之亦然
- 利用向量组作为矩阵的列来构建矩阵，利用**高斯消元法**（即利用矩阵初等变换化为阶梯形矩阵），非零行的个数就是向量组的秩，非零行第一个元素所在列对就的原来向量组中的向量构成极大线性无关组



• 向量空间

■ 向量空间 (Vector Space) 的定义

在欧几里得空间中也称线性空间 (Linear Space)，是对向量加法与标乘法 ($0 \in X$) 闭合的集合，即运算结果仍属于此集合的

$$\forall x \in X, y \in X, \quad \longrightarrow \quad x + y \in X, \quad ax \in X$$

■ 向量子空间

在欧几里得空间中也称线性子空间，是向量空间的中部分向量组成的向量空间；设 S 是域（例如实数域 $\mathbb{R}$ ）上的向量空间 X 的一个非空子集，若

$$0 \in S$$

且 S 对于加法和数乘运算都封闭，即

$$\begin{aligned} \forall x, y \in S &\longrightarrow x + y \in S; \\ \forall x \in S \text{ 及 } a \in \mathbb{R} &\longrightarrow ax \in S \end{aligned}$$

$$0 \in S$$



• 向量空间

■ 向量子空间

► 范例，三维实向量空间 $X = \{[x_1, x_2, x_3] | \mathbf{x} \in \mathbb{R}^3\}$,

$$S_1 = \{\mathbf{x} \in \mathbb{R}^3, x_3 = 0\} \subset X \quad \checkmark,$$

$$S_2 = \{\mathbf{x} \in \mathbb{R}^3, x_i > 0, i = 1, 2, 3\} \quad \times$$

$$S_3 = \{\mathbf{x} \in \mathbb{R}^3, x_1 + x_2 + x_3 = 0\} \quad \checkmark$$

若给定 $\mathbf{y} = [-y_2 - y_3, y_2, y_3]^T$, $\mathbf{z} = [-z_2 - z_3, z_2, z_3]^T$, 显然
 $\mathbf{y}, \mathbf{z} \in S_3$

因为

$$\mathbf{y} + \mathbf{z} \in S_3$$

且对于任意的实数 a

$$a\mathbf{y} \in S_3, \quad a\mathbf{z} \in S_3$$

因此, S_3 对于加法和数乘运算都封闭




• 向量空间

■ 向量子空间

➤ 范例，三维实向量空间 $X = \{[x_1, x_2, x_3] | \mathbf{x} \in \mathbb{R}^3\}$,

$$S_4 = \{\mathbf{x} \in \mathbb{R}^3, x_1 + x_2 + x_3 = 1\} \quad \text{✗}$$



给定 $\mathbf{y} = [1 - y_2 - y_3, y_2, y_3]^T$, $\mathbf{y} = [1 - z_2 - z_3, z_2, z_3]^T$, 显然
 $\mathbf{y}, \mathbf{z} \in S_3$

因为

$$\mathbf{y} + \mathbf{z} \notin S_3$$

且存在某实数 a

$$a\mathbf{y} \notin S_3, \quad az \notin S_3$$

因此, S_3 对于加法和数乘运算不是封闭的

单纯型 (Simplex) : $\{\mathbf{x} \in \mathbb{R}^n : x_1 + \cdots + x_n = 1, x_i \geq 0\}$



• 向量空间

■ 向量子空间的性质

- 由单个的零向量所组成的子集合是一个线性子空间，它叫做**零子空间**
- 线性空间 X 自身与单独一个零向量都是 X 的线性子空间，被称为 X 的平凡子空间；除平凡子空间外的线性子空间称为 X 的非平凡子空间
- 如果 $S_1, S_2 \subseteq X$ ，则

$$S_1 \cap S_2 := \{x \in X | x_1 \in S_1, \text{ 且 } x_2 \in S_2\} \subseteq X,$$

$$S_1 + S_2 := \{x + y \in X | x \in S_1, y \in S_2\} \subseteq X;$$

下列三个论断等价

$$S_1 \subset S_2 \quad \longleftrightarrow \quad S_1 \cap S_2 = S_1 \quad \longleftrightarrow \quad S_1 + S_2 = S_2$$

- 如果 $S_1, S_2, S_3 \subseteq X$ ，则

$$S_3 \subset S_1, \quad S_3 \subset S_2 \quad \longrightarrow \quad S_3 \subset (S_1 \cap S_2)$$

$$S_1 \subset S_3, \quad S_2 \subset S_3 \quad \longrightarrow \quad S_1 + S_2 \subset S_3$$



• 向量空间

■ 向量空间的基 (Basis)

向量空间的极大线性无关组称为空间的**基**，基所包含的向量数称为空间的**维数**

➤ 如果 $x_1, \dots, x_n$ 是向量空间 X 的一组基，空间中任意向量 x 均可表示

$$x = a_1 x_1 + \dots + a_n x_n$$

实数 $a_1, \dots, a_n$ 称为向量 x 在基 $x_1, \dots, x_n$ 下的**坐标**

➤ 如果基向量 $x_1, \dots, x_n$ 是相互正交，即 $x_i^T x_j = 0, \forall i \neq j$ ，则称基向量 $x_1, \dots, x_n$ 为**正交基 (Orthogonal Basis)**

➤ 如果基向量相互正交且长度均为1， $x_i^T x_i = 1$ ，则称**标准正交基**

➤ 4 维空间 $X = \mathbb{R}^4$ 的一组标准正交基

$$e_1 = (1, 0, 0, 0)^T, e_2 = (0, 1, 0, 0)^T, e_3 = (0, 0, 1, 0)^T, e_4 = (0, 0, 0, 1)^T$$



• 向量空间

■ 向量空间的基 (Basis)

- 空间的基和 (标准) 正交基 **不是唯一的**, 例如, 4 维空间 $X = \mathbb{R}^4$ 的另一组标准正交基

$$\mathbf{e}_1 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}, 0, 0\right)^T, \mathbf{e}_2 = \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}, 0, 0\right)^T,$$

$$\mathbf{e}_3 = \left(0, 0, \frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)^T, \mathbf{e}_4 = \left(0, 0, \frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}}\right)^T$$

- 如果向量子空间 $S_1, S_2 \subseteq X$, 则有维数公式

$$\dim(S_1 + S_2) = \dim(S_1) + \dim(S_2) - \dim(S_1 \cap S_2)$$

- ✓ 例如: $S_1 = \{[3, 1, 0, 0, 0]^T, [0, 2, 1, 0, 0]^T\}$, $S_2 = \{[1, 1, 2, 0, 0]^T, [0, 2, 1, 0, 0]^T\}$

$$\dim(S_1 + S_2) = 2 + 2 - 1 = 3$$

因为 $\dim(S_1 \cap S_2) = 1$



• 向量空间

■ 向量空间的基 (Basis)

➤ 证明

设 $\dim(S_1) = n_1$, $\dim(S_2) = n_2$, $\dim(S_1 \cap S_2) = m$, 任取 $S_1 \cap S_2$ 的一组基为

$$u_1, \dots, u_m$$

把它扩充为 S_1 和 S_2 的一个基:

$$u_1, \dots, u_m, \alpha_1, \dots, \alpha_{n_1-m} \text{ 和 } u_1, \dots, u_m, \beta_1, \dots, \beta_{n_2-m},$$

易知

$$\dim(S_1 + S_2) = m + n_1 - m + n_2 - m = n_1 + n_2 - m$$

因此,

$$\begin{aligned} \dim(S_1) + \dim(S_2) &= n_1 + n_2 = n_1 + n_2 - m + m \\ &= \dim(S_1 + S_2) + \dim(S_1 \cap S_2) \end{aligned}$$



• 向量范数 (Norm) 的定义

向量的范数是向量的**模概念**的推广，是具有“长度”概念的**函数**，向量的 p 范数（ p 为正整数）是一个标量，定义为

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

■ 常用的范数

➤ 1-范数 (Taxicab norm)

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$$

➤ 2-范数，也称向量的模（向量的长度）

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$$

即欧几里得范数(Euclidean Norm)，记为 $\|\mathbf{x}\|$ ， $\frac{\mathbf{x}}{\|\mathbf{x}\|}$ 是 $\mathbf{x}$ 方向的**单位向量**



向量的运算

- 范数 $\|\mathbf{x}\|_2$ 的性质
 - ◆ 单位向量 $\|\mathbf{x}\|_2 = 1$;
 - ◆ $\|k\mathbf{x}\| = |k| \cdot \|\mathbf{x}\|$
 - ◆ $\mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|_2^2$
- ∞ -范数

$$\|\mathbf{x}\|_\infty = \lim_{n \rightarrow \infty} (\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}} = \max |x_i|,$$



$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1 \leq \sqrt{n} \|\mathbf{x}\|_2 \leq n \|\mathbf{x}\|_\infty$$

例如, 3 维空间 $\mathbb{R}^3$ 中的向量 $\mathbf{x} = [x_1, x_2, x_3]^T$

$$\begin{aligned} \|\mathbf{x}\|_2^2 &= x_1^2 + x_2^2 + x_3^2 \leq \|\mathbf{x}\|_1^2 = (|x_1| + |x_2| + |x_3|)^2 \\ &= x_1^2 + x_2^2 + x_3^2 + 2|x_1||x_2| + 2|x_2||x_3| + 2|x_1||x_3| \end{aligned}$$





向量的运算

- 柯西-施瓦茨 (Cauchy-Schwarz) 不等式

$$|\mathbf{x}^T \mathbf{y}| \leq \|\mathbf{x}\|_2 \cdot \|\mathbf{y}\|_2$$

等式成立当且仅当向量 $\mathbf{x}$ 和向量 $\mathbf{y}$ 是线性相关的 (即两个向量平行)

- 三角不等式

$$\|\mathbf{x} + \mathbf{y}\|_p \leq \|\mathbf{x}\|_p + \|\mathbf{y}\|_p$$

- 多元函数 $f(\mathbf{x}) = \|\mathbf{x}\|_p$ 是凸函数, 因为

$$\begin{aligned} f(\alpha \mathbf{x}_1 + (1 - \alpha) \mathbf{x}_2) &= \|\alpha \mathbf{x}_1 + (1 - \alpha) \mathbf{x}_2\|_p \\ &\leq \alpha \|\mathbf{x}_1\|_p + (1 - \alpha) \|\mathbf{x}_2\|_p \\ &= \alpha f(\mathbf{x}_1) + (1 - \alpha) f(\mathbf{x}_2) \end{aligned}$$

- 向量之间的距离 (欧氏距离)

$$\|\mathbf{x} - \mathbf{y}\|_2 = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$



• 度量空间


■ 数据驱动的人工智能方法

- 按设定规则直接将待观测样本划分为不同的类别，保证类内样本相似度较高、类间样本相似度较低
- 从历史数据中总结发现规律，并将其应用于预测新观测样本，方法 k -邻近法 (k-nearest neighbor, KNN)、线性回归 (linear regression)

KNN: 表示“物以类聚，人以群分”，假设数据标签已给定的训练数据集，对于新的样本，找到与其 k 个最近邻的训练数据，这 k 个训练数据的多数属于某个类，就把新样本归为这个类

■ 相似性度量

特征向量之间的对比是发现不同样本间的差别，或者说是要评定不同样本的相似程度





• 度量空间

■ 度量或距离函数 (Metric Function)

空间内每一对元素之间的距离，即空间 X 上的度量定义为

$$\text{dist}(x_1, x_2): X \times X \rightarrow \mathbb{R}, \quad \text{且满足}$$

➤ 非负性/分离公理

$$\text{dist}(x_1, x_2) \geq 0$$

➤ 同一性/同时公理

$$\text{dist}(x_1, x_2) = 0 \text{ 当且仅当 } x_1 = x_2$$

➤ 对称性

$$\text{dist}(x_1, x_2) = \text{dist}(x_2, x_1)$$

➤ 次加性/三角不等式

$$\text{dist}(x_1, x_3) \leq \text{dist}(x_1, x_2) + \text{dist}(x_2, x_3)$$



• 度量空间

■ 度量或距离函数

空间 X 上的度量不是唯一，例如当 $X = \mathbb{R}$ ，存在如下两个距离函数

$$\text{dist}_1(x_1, x_2) := |x_1 - x_2|$$

$$\text{dist}_2(x_1, x_2) := \ln(1 + |x_1 - x_2|)$$

第二个距离会出现在微分几何和复代数几何中


■ 向量空间上的度量

➤ 欧式距离 (Euclidean Distance)

$$\text{dist}(x_1, x_2) := \|x_1 - x_2\|_2 = \sqrt{\sum_{i=1}^n (x_1^i - x_2^i)^2}$$

➤ 曼哈顿度量 (Manhattan Distance)

$$\text{dist}(x_1, x_2) := \sum_{i=1}^n |x_1^i - x_2^i| = \|x_1 - x_2\|_1$$





• 度量空间

■ 常用距离度量



➢ 欧式距离

- 不具备缩放不变性，所计算的距离可能会根据特征的单位发生倾斜，使用欧式距离度量之前，需要对数据进行归一化/标准化处理
- 不适用于高维数据，数据灾难

➢ 余弦相似度

$$\text{dist}(x_1, x_2) = \cos\theta = \frac{\langle x_1, x_2 \rangle}{\|x_1\| \cdot \|x_2\|}$$

- 忽略数值差异：考察向量的方向非长度
- 数据维度较高而且向量的长度并不重要
- 适用文本分析领域，不适用推荐系统





向量运算

度量空间

■ 常用距离度量

➤ 曼哈顿距离

$$\|x_1 - x_2\|_1$$

➤ 切比雪夫距离

$$\|x_1 - x_2\|_\infty$$

➤ 闵氏距离

$$\|x_1 - x_2\|_p$$










➤ 杰卡德相似系数

➤ 汉明距离

➤ 皮尔森距离

➤ 斯皮尔曼距离

➤ ...





• 度量空间

■ 度量或距离函数的性质

- 离散度量 (Discrete Metric) $\text{dist}(\mathbf{x}_1, \mathbf{x}_2): X \times X \rightarrow \{0, 1\}$

如果 $\mathbf{x}_1 = \mathbf{x}_2$, 则 $\text{dist}(\mathbf{x}_1, \mathbf{x}_2) = 0$, 否则 $\text{dist}(\mathbf{x}_1, \mathbf{x}_2) = 1$

- 平移不变 (Translation Invariance) 度量: 若

$$\text{dist}(\mathbf{x}_1 + \mathbf{a}, \mathbf{x}_2 + \mathbf{a}) = \text{dist}(\mathbf{x}_1, \mathbf{x}_2), \quad \forall \mathbf{x}_1, \mathbf{x}_2, \mathbf{a}$$

欧几里德度量是平移 (旋转) 不变, 曼哈顿度量是平移不变的; 更一般地, 任何由范数引发的度量是平移不变的

- 均匀 (uniformity) 度量: 若

$$\text{dist}(a\mathbf{x}_1, a\mathbf{x}_2) = |a|\text{dist}(\mathbf{x}_1, \mathbf{x}_2), \quad \forall \mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^n, a \in \mathbb{R}$$

- 如果在向量空间 X 上的度量满足平移不变性以及均匀性, 则可定义空间 X 上的范数为: $\|\mathbf{x}\| := \text{dist}(\mathbf{x}, \mathbf{0})$



• 向量的内积

■ 向量内积 (Inner Product) 的定义

在欧式空间中也被称为点积、标量积、数量积，定义为两个向量对应分量乘积之和

$$\langle \mathbf{x}, \mathbf{y} \rangle := \mathbf{x}^T \mathbf{y} = \sum_{i=1}^n x_i y_i$$

➤ 几何意义：


① 可以用来表征或计算两个向量之间的夹角

$$\cos \theta = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \cdot \|\mathbf{y}\|}$$

② 在 $\mathbf{x}$ 向量在 $\mathbf{y}$ 向量方向上的投影表示为

$$\text{proj}_{\mathbf{y}} \mathbf{x} := \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\langle \mathbf{y}, \mathbf{y} \rangle} \mathbf{y} = \frac{\|\mathbf{x}\| \cos \theta}{\|\mathbf{y}\|} \mathbf{y}$$

通过除以它们的标量长度来“标准化”





• 向量的内积

➤ 内积的性质

$$\langle x, x \rangle \geq 0,$$

$$\langle x, y \rangle = \langle y, x \rangle,$$

$$\langle kx, y \rangle = k \langle x, y \rangle,$$

$$\langle x + y, z \rangle = \langle x, z \rangle + \langle y, z \rangle,$$

$$\langle z, x + y \rangle = \langle z, x \rangle + \langle z, y \rangle$$

当 $x = 0$, $\langle x, x \rangle = 0$
当 $x \neq 0$, $\langle x, x \rangle > 0$

➤ 范例：已知 $\|x_1\| = 2$, $\|x_2\| = 3$, 若向量 x_1 与向量 x_2 垂直, 则

$$\langle x_1, x_2 \rangle = \|x_1\| \cdot \|x_2\| \cdot \cos 90^\circ = 0$$

$$\text{proj}_{x_2} x_1 := \frac{\langle x_1, x_2 \rangle}{\langle x_2, x_2 \rangle} x_2 = \frac{\|x_1\| \cos 90^\circ}{\|x_2\|} x_2 = 0$$

若向量 x_1 与向量 x_2 平行, 且 $x_2 = [1, 2, -2]^T$, 则

$$\langle x_1, x_2 \rangle = \quad, \quad \text{proj}_{x_2} x_1 =$$



• 向量的内积

➤ 内积的性质

$$\langle x, x \rangle \geq 0,$$

$$\langle x, y \rangle = \langle y, x \rangle,$$

$$\langle kx, y \rangle = k \langle x, y \rangle,$$

$$\langle x + y, z \rangle = \langle x, z \rangle + \langle y, z \rangle,$$

$$\langle z, x + y \rangle = \langle z, x \rangle + \langle z, y \rangle$$

当 $x = 0$, $\langle x, x \rangle = 0$
当 $x \neq 0$, $\langle x, x \rangle > 0$

➤ 范例：已知 $\|x_1\| = 2$, $\|x_2\| = 3$, 若向量 x_1 与向量 x_2 垂直, 则

$$\langle x_1, x_2 \rangle = \|x_1\| \cdot \|x_2\| \cdot \cos 90^\circ = 0$$

$$\text{proj}_{x_2} x_1 := \frac{\langle x_1, x_2 \rangle}{\langle x_2, x_2 \rangle} x_2 = \frac{\|x_1\| \cos 90^\circ}{\|x_2\|} x_2 = 0$$

若向量 x_1 与向量 x_2 平行, 且 $x_2 = [1, 2, -2]^T$, 则

$$\langle x_1, x_2 \rangle = \pm 6, \quad \text{proj}_{x_2} x_1 = \pm \frac{2}{3} [1, 2, -2]^T$$



• 向量的内积

■ 向量正交 (Orthogonal)

如果两个向量的内积为0, 则称为正交


$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^T \mathbf{y} = 0$$

■ 正交向量组 (Orthogonal Vector Group)

是一组非零的两两正交 (即内积为0) 的向量构成的向量组

■ 格拉姆-施密特 (Gram-Schmidt) 正交化

是利用投影原理在已有**线性无关向量组**的基础上构造一个新的正交基: 特别是给定一组非零且线性无关的向量组 $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^n$, 先构造出一组正交基 $\mathbf{u}_1, \dots, \mathbf{u}_n$, 然后将这组正交基进行标准化得到标准正交基 $\mathbf{e}_1, \dots, \mathbf{e}_n$





• 向量的内积

■ 格拉姆-施密特正交化

具体计算步骤如下：

① 选择向量 x_1 作为第一个正交基方向 $u_1 = x_1$

② 使得它与 u_1 正交，即

$$u_2 = x_2 - \alpha_{21} u_1$$


由于 u_2 与 u_1 正交 $\langle u_1, u_2 \rangle = 0$ ，因此有

$$\langle x_2 - \alpha_{21} u_1, u_1 \rangle = 0$$

因此，

$$\alpha_{21} = \frac{\langle x_2, u_1 \rangle}{\langle u_1, u_1 \rangle}$$

所以，

$$u_2 = x_2 - \frac{\langle x_2, u_1 \rangle}{\langle u_1, u_1 \rangle} u_1$$




• 向量的内积

■ 格拉姆-施密特正交化

具体计算步骤如下：

② 接着计算 $u_3 = x_3 - \alpha_{31}u_1 - \alpha_{32}u_2$ ，其中

$$\alpha_{31} = \frac{\langle x_3, u_1 \rangle}{\langle u_1, u_1 \rangle}, \quad \alpha_{32} = \frac{\langle x_3, u_2 \rangle}{\langle u_2, u_2 \rangle}$$

因此， $u_3 = x_3 - \frac{\langle x_3, u_1 \rangle}{\langle u_1, u_1 \rangle} u_1 - \frac{\langle x_3, u_2 \rangle}{\langle u_2, u_2 \rangle} u_2$ ，依次类推，



$$u_n = x_n - \text{proj}_{u_1} x_n - \text{proj}_{u_2} x_n - \cdots - \text{proj}_{u_{n-1}} x_n$$

③ 最后进行向量单位化

$$e_1 = \frac{u_1}{\|u_1\|}, \quad e_2 = \frac{u_2}{\|u_2\|}, \quad \cdots, \quad e_n = \frac{u_n}{\|u_n\|}$$

于是 $\{e_1, e_2, \dots, e_n\}$ 就是一组标准正交基



• 向量的内积

■ 格拉姆-施密特正交化

➤ 范例1: 给定 $x_1 = [3, 1]^T$, $x_2 = [2, 2]^T$, 选择 x_1 作为第一个正交基方向

$$u_1 = x_1 = [3, 1]^T$$

构造如下 u_2

$$u_2 = x_2 - \alpha_{21} u_1 = x_2 - \frac{\langle x_2, u_1 \rangle}{\langle u_1, u_1 \rangle} u_1 = \begin{bmatrix} -\frac{2}{5} \\ \frac{6}{5} \end{bmatrix}^T$$

下面验证 u_2 与 u_1 的正交

$$\langle u_1, u_2 \rangle = -\frac{6}{5} + \frac{6}{5} = 0$$

将这些向量单位化

$$e_1 = \frac{1}{\sqrt{10}} [3, 1]^T, \quad e_2 = \frac{\sqrt{5}}{2\sqrt{2}} \begin{bmatrix} -\frac{2}{5} \\ \frac{6}{5} \end{bmatrix}^T$$

于是 $\{e_1, e_2\}$ 就是一组标准正交基底

$$\begin{bmatrix} 2 \\ 2 \end{bmatrix} - \frac{4}{5} \cdot \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} -\frac{2}{5} \\ \frac{6}{5} \end{bmatrix}$$



• 向量的内积

■ 格拉姆-施密特正交化

➤ 范例2: 给定 $x_1 = [1, 0, 1]^T$, $x_2 = [1, 1, 0]^T$, $x_3 = [0, 1, 1]^T$, 则

$$u_1 = x_1 = [1, 0, 1]^T$$

构造 u_2 如下

$$\alpha_{21} = \frac{\langle x_2, u_1 \rangle}{\langle u_1, u_1 \rangle} = \frac{1 \times 1 + 0 \times 1 + 1 \times 0}{1^2 + 0^2 + 1^2} = \frac{1}{2}$$

因此,

$$u_2 = x_2 - \alpha_{21} u_1 = x_2 - \frac{1}{2} u_1 = [1, 1, 0]^T - \frac{1}{2} [1, 0, 1]^T = \left[\frac{1}{2}, 1, -\frac{1}{2} \right]^T$$

最后生成 $u_3 = x_3 - \alpha_{31} u_1 - \alpha_{32} u_2$, 其中

$$\alpha_{31} = \frac{\langle x_3, u_1 \rangle}{\langle u_1, u_1 \rangle} = \frac{1 \times 0 + 0 \times 1 + 1 \times 1}{1^2 + 0^2 + 1^2} = \frac{1}{2}$$

$\text{proj}_{u_1} x_3$

$\text{proj}_{u_1} x_2$



• 向量的内积

■ 格拉姆-施密特正交化

➤ 范例2:

$$\alpha_{32} = \frac{\langle \mathbf{x}_3, \mathbf{u}_2 \rangle}{\langle \mathbf{u}_2, \mathbf{u}_2 \rangle} = \frac{\frac{1}{2}(1 \times 0 + 2 \times 1 + (-1) \times 1)}{\frac{1}{4}(1^2 + 2^2 + (-1)^2)} = \frac{1}{3}$$

因此,

$$\mathbf{u}_3 = [0, 1, 1]^T - \frac{1}{2}[1, 0, 1]^T - \frac{1}{3} \times \frac{1}{2} \left[\frac{1}{2}, 1, -\frac{1}{2} \right]^T = \left[-\frac{2}{3}, \frac{2}{3}, \frac{2}{3} \right]^T$$



最后对 $\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_3$ 进行单位化,

$$\mathbf{e}_1 = \frac{1}{\sqrt{2}}[1, 0, 1]^T, \quad \mathbf{e}_2 = \frac{1}{\sqrt{6}}[1, 2, -1]^T$$

$$\mathbf{e}_3 = \frac{1}{\sqrt{3}}[-1, 1, 1]^T$$

2-2

矩阵





• 矩阵的定义

矩阵是二维数组，即一个 $m \times n$ 的矩阵记为

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix}$$

■ 性质

- 方阵、对称矩阵、零矩阵、单位矩阵、上三角矩阵，下三角矩阵
- 向量组 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 的格拉姆矩阵(Gram Matrix)为一个 $n \times n$ 的对称矩阵

$$G = \begin{bmatrix} \mathbf{x}_1^T \mathbf{x}_1 & \mathbf{x}_1^T \mathbf{x}_2 & \cdots & \mathbf{x}_1^T \mathbf{x}_n \\ \mathbf{x}_2^T \mathbf{x}_1 & \mathbf{x}_2^T \mathbf{x}_2 & \cdots & \mathbf{x}_2^T \mathbf{x}_n \\ \vdots & \ddots & \ddots & \vdots \\ \mathbf{x}_n^T \mathbf{x}_1 & \cdots & \cdots & \mathbf{x}_n^T \mathbf{x}_n \end{bmatrix}$$

- 常用于机器学习中的主成分分析 (PCA)、核主成分分析、线性判别分析、线性回归、logistic回归及支持向量机的推导与证明



• 矩阵的定义


■ 性质

- 向量组 $x_1, \dots, x_n$ 的格拉姆矩阵(Gram Matrix)为一个 $n \times n$ 的对称矩阵

$$G = \begin{bmatrix} \langle x_1, x_1 \rangle & \langle x_1, x_2 \rangle & \cdots & \langle x_1, x_n \rangle \\ \langle x_2, x_1 \rangle & \langle x_2, x_2 \rangle & \cdots & \langle x_2, x_n \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle x_n, x_1 \rangle & \cdots & \cdots & \langle x_n, x_n \rangle \end{bmatrix}$$

- 如果 $x_1, \dots, x_n$ 分别是随机向量，则格拉姆矩阵是协方差矩阵
- Gram矩阵可表示图像的风格特征：即特征之间的偏心协方差矩阵（即没有减去均值的协方差矩阵）

* 风格迁移指的是两个不同域中图像的转换，具体来说就是提供一张风格图像，将任意一张图像转化为这个风格，并尽可能保留原图像的内容




CSDN @Arwin (Haowen Yu)



• 矩阵的基本运算

- 转置: A^T
- 四则运算: $A + B$, $(A + B)^T = A^T + B^T$, $(AB)^T = B^T A^T$
- 简化线性方程组

$$Ax = b$$



$$x = A^{-1}b$$

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots a_{1n}x_n = b_1 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots a_{nn}x_n = b_n \end{cases}$$

增广矩阵为系统矩阵和常数向量合并, 记 $[A \ b]$

- 逆矩阵 (存在即唯一):

$$AB = I$$



• 矩阵的基本运算

■ 逆矩阵的性质

$$(AB)^{-1} = B^{-1}A^{-1}, \quad (A^T)^{-1} = (A^{-1})^T$$

■ 矩阵的秩：矩阵线性无关的行向量或列向量的最大数量，记 $\text{rank}(A)$

$$\text{rank}(A) \leq \min(n, m), \quad \text{rank}(A) = \text{rank}(A^T)$$

■ 矩阵的秩的性质

$$\text{rank}(A + B) \leq \text{rank}(A) + \text{rank}(B)$$

$$\text{rank}(AB) \leq \min(\text{rank}(A), \text{rank}(B))$$

■ 矩阵的初等变换

$$[A \ I]$$

$$[I, A^{-1}]$$

■ 矩阵的行列式：是一个在方块矩阵上计算得到的标量，记作 $\det(A)$



• 线性变换

■ 线性变换 (Linear Transformation) 的定义

亦称线性映射(Linear Mapping), 矩阵与向量的乘法可以解释为线性变换, 它将一个向量变成另外一个向量, 则对于任意的向量 $\mathbf{x}_1, \mathbf{y}_1 \in R^n$, 以及实数 k , 满足

- 可加性: $A(\mathbf{x}_1 + \mathbf{x}_2) = A\mathbf{x}_1 + A\mathbf{x}_2$
- 齐次性: $A(k\mathbf{x}_1) = kA\mathbf{x}_1$


➤ 几何中的旋转变换是一种线性变换

下面以二维平面的向量 $\mathbf{x} = (x_1, x_2)^T$, 其在极坐标下的坐标为 $\mathbf{x} = (r, \phi)^T$, 即

$$x_1 = r \cos \phi, \quad x_2 = r \sin \phi$$

将向量 $\mathbf{x}$ 逆时针旋转 θ 度后, 得到向量

$$\mathbf{x}' = (r, \phi + \theta)^T$$





• 线性变换


■ 线性变换 (Linear Transformation) 的定义

那么, x' 的直角坐标为:

$$\begin{aligned} x' &= [r \cos(\phi + \theta), r \sin(\phi + \theta)]^T \\ &= \begin{bmatrix} r \cos(\phi) \cos(\theta) - r \sin(\phi) \sin(\theta) \\ r \sin(\phi) \cos(\theta) + r \cos(\phi) \sin(\theta) \end{bmatrix} \\ &= \begin{bmatrix} x_1 \cos(\theta) - x_2 \sin(\theta) \\ x_1 \sin(\theta) + x_2 \cos(\theta) \end{bmatrix} \\ &= \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = Ax \end{aligned}$$

因此, 二维空间中逆时针旋转矩阵为:

$$A = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$





- 线性变换

- 线性变换 (Linear Transformation) 的定义

- 逆时针旋转 90 度

$$A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

- 几何中放缩也是线性变换

若二维平面存在向量 $\mathbf{x} = [x_1, x_2]^T$ ，若存在变换矩阵

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$$

则变换之后的向量为

$$\mathbf{y} = A\mathbf{x} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

相当于在 x_1 方向拉伸了 2 倍， x_2 方向拉伸了 3 倍



• 线性变换

■ 线性变换 (Linear Transformation) 的定义

➤ 针对 x 轴反射

$$A = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

➤ 在 y 轴的投影

$$A = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$$

➤ 水平错切

$$A = \begin{bmatrix} 1 & m \\ 0 & 1 \end{bmatrix}$$

➤ 挤压

$$A = \begin{bmatrix} k & 0 \\ 0 & 1/k \end{bmatrix}$$



• 线性变换

■ 线性变换 (Linear Transformation) 的定义

- ▶ 范例：对向量 $\mathbf{x} = [1, -1]^T$ 依次进行如下线性变换：先顺时针旋转45度，接着在 x 轴方向伸缩3倍， y 轴方向伸缩2倍，然后对 x 轴进行反射，最后以 $k = 2$ 进行挤压操作
- ▶ 解：顺时针旋转45度对应的变换矩阵

$$\mathbf{A}_1 = \begin{bmatrix} \cos 45 & \sin 45 \\ -\sin 45 & \cos 45 \end{bmatrix} = \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}$$

$$\mathbf{y}_1 = \mathbf{A}_1 \mathbf{x} = [\sqrt{2}, 0]^T$$

接着，在 x 轴方向伸缩 3 倍， y 轴方向伸缩 2 倍，即

$$\mathbf{y}_2 = \mathbf{A}_2 \mathbf{y}_1 = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} \sqrt{2} \\ 0 \end{bmatrix} = \begin{bmatrix} 3\sqrt{2} \\ 0 \end{bmatrix}$$



• 线性变换

■ 线性变换 (Linear Transformation) 的定义

- ▶ 范例：对向量 $\mathbf{x} = [1, -1]^T$ 依次进行如下线性变换：先顺时针旋转45度，接着在 x 轴方向伸缩3倍， y 轴方向伸缩2倍，然后对 x 轴进行反射，最后以 $k = 2$ 进行挤压操作
- ▶ 解：然后对 x 轴进行反射

$$\mathbf{y}_3 = \mathbf{A}_3 \mathbf{y}_2 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} 3\sqrt{2} \\ 0 \end{bmatrix} = \begin{bmatrix} 3\sqrt{2} \\ 0 \end{bmatrix}$$

最后以 $k = 2$ 进行挤压操作

$$\mathbf{y}_4 = \mathbf{A}_3 \mathbf{y}_3 = \begin{bmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{bmatrix} \begin{bmatrix} 3\sqrt{2} \\ 0 \end{bmatrix} = \begin{bmatrix} 6\sqrt{2} \\ 0 \end{bmatrix}$$



• 矩阵的迹

■ 矩阵的迹 (Trace) 的定义

- $n \times n$ 的矩阵 A 的迹是指 A 的主对角线 (从左上方至右下方的对角线) 上各个元素的总和。

$$\text{tr}(A) = a_{11} + a_{22} + \cdots + a_{nn}$$

- 例如

$$A = \begin{bmatrix} 3 & 5 & 1 \\ 0 & 9 & 2 \\ 7 & 6 & 4 \end{bmatrix} \quad \longrightarrow \quad \text{tr}(A) = 3 + 9 + 4 = 16$$

■ 矩阵的迹的性质

- $\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$, $\text{tr}(aA) = a \cdot \text{tr}(A)$,
- $\text{tr}(A) = \text{tr}(A^T)$
- $\text{tr}(ABC) = \text{tr}(BCA) = \text{tr}(CAB)$, $\text{tr}(ABC) \neq \text{tr}(ACB)$



• 矩阵的迹

■ 矩阵的迹在人工智能中应用

矩阵迹的一个典型应用场景是特征向量降维

- 维度灾难：维度的增多并未提升待观测数据的可区分性，反而带来更多的计算量
- 高维特征空间的低维嵌入：利用高维空间中的部分维度信息即可实现类似的分类精度，即通过某种变换将原高维空间中的特征向量转换为较低维度子空间中的特征向量，从而降低维度解决“维度灾难”
- 多维缩放（Multiple Dimensional Scaling, MDS）：保证待观测数据在变换前后空间内的距离评价保持一致的前提下，将高危数据进行降维

假设有 m 个待观测对象 x_i ，每个对象有 n 维特征，即 $x_i = [x_i^1, \dots, x_i^n]$ ，待观测对象之间的距离构成一个 m 阶方阵 D ， $D_{i,j} = \left(\sum_{k=1}^n (x_i^k - x_j^k)^2 \right)^{\frac{1}{2}}$ ，多维缩放降维后，距离矩阵 D 保持不变的



• 特征值与特征向量

- 特征值 (Eigenvalue) 与特征向量 (Eigenvector) 的定义
对于 $n \times n$ 方阶矩阵 A ，存在一个数 λ 及非 $\mathbf{0}$ 向量 $\mathbf{x}$ ，满足

$$A\mathbf{x} = \lambda\mathbf{x}$$

则称 λ 为矩阵的特征值， $\mathbf{x}$ 为特征值 λ 对应的特征向量

- 特征值与特征向量的解释

在线性变换 A 的作用下特征向量 $\mathbf{x}$ 的长度以 $|\lambda|$ 为比例进行缩放

- 特征值的绝对值是特征向量在矩阵的线性变换下的缩放比例
 - 若 $\lambda > 0$ ，经线性变换 A 之后特征向量的方向不变，按 $|\lambda|$ 尺度伸缩
 - 若 $\lambda < 0$ ，经线性变换 A 之后特征向量的方向相反，按 $|\lambda|$ 尺度伸缩
 - 若 $\lambda = 0$ ，经线性变换 A 之后特征向量收缩回原点
- 特征向量（标准化）指示拉伸的方向






• 特征值与特征向量

■ 特征值与特征向量的解释

➢ 例如：当蒙娜丽莎的图像左右翻转时

- ◆ 中间垂直的**红色向量**方向保持不变，向量长度不变，其特征值为1
- ◆ 水平方向的**黄色向量**方向完全反转，向量长度不变，其特征值为-1
- ◆ **橙色向量**在翻转后和原向量不在同一条直线上，因此不是特征向量





• 特征值与特征向量

■ 特征矩阵 (Characteristic Matrix) 与特征方程 (Characteristic Equation)

由方阵 A 的特征值与特征向量关系可以得到

$$(A - \lambda I_n)x = 0$$

$A - \lambda I_n$ 称为**特征矩阵**，上述齐次方程有**非 0 解**的条件是系数矩阵的行列式必须为 0，即满足

$$\det(A - \lambda I_n) = 0$$

上式以 λ 为未知数的一元 n 次方程，称为 A 的**特征方程**，方程左侧是 λ 的 n 次多项式，称为 A 的**特征多项式** (Characteristic Polynomial)，记作

$$p_A(\lambda) := \det(A - \lambda I_n)$$

- 求解这个特征多项式对应的特征方程可以得到所有的特征值，方程的根可能是复数，**特征值为复数时，特征向量也为复向量**
- 若 A 不可逆，0 是它的特征值；若可逆，则 0 不是它的特征值



• 特征值与特征向量

■ 特征多项式

对于矩阵

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

其特征方程为

$$\det(A - \lambda I_n) = \begin{vmatrix} a_{11} - \lambda & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} - \lambda & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} - \lambda \end{vmatrix} = 0$$

其特征多项式为

$$p_A(\lambda) = c_n \lambda^n + c_{n-1} \lambda^{n-1} + c_{n-2} \lambda^{n-2} + \cdots + c_1 \lambda + c_0$$



• 特征值与特征向量

■ 特征多项式

- ▶ 特例：根据对角行列式的计算公式，对角矩阵的特征值为其主对角线元素，对于如下对角矩阵

$$A = \begin{bmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{bmatrix}$$

其特征多项式为

$$\det(A - \lambda I_n) = (a_{11} - \lambda) \cdots (a_{nn} - \lambda)$$

显而易见，即对角矩阵的特征值为 a_{11} 、 a_{22} 、 $\cdots$ 、 a_{nn}

- ▶ 更一般的，当 A 为上三角矩阵（或下三角矩阵）时， $p_A(\lambda) := \prod_{i=1}^n (a_{ii} - \lambda)$ ，其中 a_{ii} 为主对角线上的元素



• 特征值与特征向量

■ 特征多项式与特征值

➤ 范例：上三角矩阵的特征值为其主对角线元素，对于如下矩阵

$$A = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 2 & 2 \\ 0 & 0 & 3 \end{bmatrix}$$

根据前面的结论，其特征多项式为

$$\begin{aligned} \det(A - \lambda I_n) &= \begin{vmatrix} 1 - \lambda & 1 & 1 \\ 0 & 2 - \lambda & 2 \\ 0 & 0 & 3 - \lambda \end{vmatrix} \\ &= (1 - \lambda)(2 - \lambda)(3 - \lambda) \end{aligned}$$

其特征值为1, 2, 3



• 特征值与特征向量

- 范例：对于如下矩阵

$$A = \begin{bmatrix} 1 & 2 \\ 0 & -1 \end{bmatrix}$$

- 其特征多项式为

$$\det(A - \lambda I_n) = -(1 - \lambda)(1 + \lambda)$$

对应的特征方程的根为 $\lambda_1 = 1$ 与 $\lambda_2 = -1$

- 将特征值 1 和 -1 代入，可得

$$(A - \lambda_1 I)x = \begin{bmatrix} 0 & 2 \\ 0 & -2 \end{bmatrix}x = \mathbf{0}, \quad (A - \lambda_2 I)x = \begin{bmatrix} 2 & 2 \\ 0 & 0 \end{bmatrix}x = \mathbf{0}$$

该齐次方程组的解为

$$x_1 = [1 \ 0]^T, \quad x_2 = [1 \ -1]^T$$

x_1 为特征值 1 对应的特征向量， x_2 为特征值 -1 对应的特征向量。



• 特征值与特征向量

■ 特征值的性质

➤ 如果矩阵 A 可逆且 λ 为它的特征值，则 λ^{-1} 是 A^{-1} 的特征值

证明： $Ax = \lambda x \xrightarrow{\text{同时左乘 } A^{-1}} A^{-1}Ax = \lambda A^{-1}x \xrightarrow{\text{同时乘 } \lambda^{-1}} A^{-1}x = \lambda^{-1}x$

➤ 如果 λ 为矩阵 A 的特征值，则 λ^n 是 A^n 的特征值

证明： $A^n x = A^{n-1}Ax = A^{n-1}\lambda x = \lambda A^{n-2}Ax = \lambda A^{n-2}\lambda x = \dots = \lambda^n x$

➤ 如果 λ 为矩阵 A 的特征值，则 $k\lambda$ 是 kA 的特征值

➤ 对于多项式 $f(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x$ ，如果 λ 为矩阵 A 的特征值，则 $f(\lambda)$ 是 $f(A)$ 的特征值

➤ 矩阵 A 与 A^T 有相同的特征值

➤ 实对称矩阵的特征值均为实数

➤ 矩阵所有特征值的和为矩阵的迹 $\sum_{i=1}^n \lambda_i = \text{tr}(A)$

➤ 矩阵所有特征值的积为矩阵的行列式 $\prod_{i=1}^n \lambda_i = \det A$



• 特征值与特征向量

■ 特征向量的性质

- 如果向量 $\mathbf{x}_1, \dots, \mathbf{x}_l$ 都是矩阵 $\mathbf{A}$ 关于同一个特征值 λ 的特征向量，则它们的系数非全 0 的线性组合 $\sum_{i=1}^l k_i \mathbf{x}_i$ 也是矩阵 $\mathbf{A}$ 关于 λ 的特征向量
证明：

$$\mathbf{A} \sum_{i=1}^l k_i \mathbf{x}_i = \sum_{i=1}^l k_i \mathbf{A} \mathbf{x}_i = \sum_{i=1}^l k_i \lambda \mathbf{x}_i = \lambda \sum_{i=1}^l k_i \mathbf{x}_i$$

- 任意矩阵属于不同特征值的特征向量 **线性无关**

证明：假设矩阵 $\mathbf{A}$ 的 l 个不同的特征值为 $\lambda_1, \dots, \lambda_l$ ，它们对应的特征向量为 $\mathbf{x}_1, \dots, \mathbf{x}_l$ ，下面用归纳法进行证明，

当 $l = 1$ 时结论成立，因为 $\mathbf{x}_1 \neq \mathbf{0}$ ，若 $k_1 \mathbf{x}_1 = \mathbf{0}$ ，则必定有 $k_1 = 0$



• 特征值与特征向量

■ 特征向量的性质

➤ 矩阵属于不同特征值的特征向量线性无关

接上证明:

假设当 $l = m$ 时结论成立, 当 $l = m + 1$ 时有

$$k_1 \mathbf{x}_1 + \cdots + k_m \mathbf{x}_m + k_{m+1} \mathbf{x}_{m+1} = \mathbf{0}$$

两边左乘 A , 有

$$A(k_1 \mathbf{x}_1 + \cdots + k_m \mathbf{x}_m + k_{m+1} \mathbf{x}_{m+1}) = \mathbf{0} \quad (1)$$

由于 $A\mathbf{x}_i = \lambda_i \mathbf{x}_i$, 因此

$$k_1 \lambda_1 \mathbf{x}_1 + \cdots + k_m \lambda_m \mathbf{x}_m + k_{m+1} \lambda_{m+1} \mathbf{x}_{m+1} = \mathbf{0} \quad (2)$$

将式(1)乘以 λ_{m+1} , 然后减去(2), 可得

$$k_1 (\lambda_{m+1} - \lambda_1) \mathbf{x}_1 + \cdots + k_m (\lambda_{m+1} - \lambda_m) \mathbf{x}_m = \mathbf{0}$$



• 特征值与特征向量

■ 特征向量的性质

➢ 矩阵属于不同特征值的特征向量线性无关

接上证明:

由于 $\mathbf{x}_1, \dots, \mathbf{x}_m$ 线性无关, 因此

$$k_1(\lambda_{m+1} - \lambda_i) = 0, \quad i = 1, \dots, m$$

而 $\lambda_{m+1} \neq \lambda_i, i = 1, \dots, m$, 因此 $k_i = 0, i = 1, \dots, m$, 将 $k_i = 0, i = 1, \dots, m$ 代入式(1)可得

$$k_{m+1}\mathbf{x}_{m+1} = \mathbf{0}$$

由于是特征向量, 所以 $\mathbf{x}_{m+1} \neq \mathbf{0}$, 因此 $k_{m+1} = 0$, 最终可证

$\mathbf{x}_1, \dots, \mathbf{x}_{m+1}$ 线性无关



• 特征值与特征向量

■ 特征向量的性质

➤ 实对称矩阵属于不同特征值的特征向量相互正交

证明：假设 A 为实对称矩阵， λ_1, λ_2 是它的两个不同的特征值， $\mathbf{x}_1, \mathbf{x}_2$ 分别为属于 λ_1, λ_2 的特征向量。则有

$$A\mathbf{x}_1 = \lambda_1\mathbf{x}_1, \quad A\mathbf{x}_2 = \lambda_2\mathbf{x}_2$$

上式的第一式两边左乘 $\mathbf{x}_2^T$ 可以得到

$$\mathbf{x}_2^T A\mathbf{x}_1 = \lambda_1 \mathbf{x}_2^T \mathbf{x}_1$$

由于 $\mathbf{x}_2^T A\mathbf{x}_1 = (A^T \mathbf{x}_2)^T \mathbf{x}_1 = (A\mathbf{x}_2)^T \mathbf{x}_1 = \lambda_2 \mathbf{x}_2^T \mathbf{x}_1$ ，因此有

$$\lambda_1 \mathbf{x}_2^T \mathbf{x}_1 = \lambda_2 \mathbf{x}_2^T \mathbf{x}_1$$

由于 $\lambda_1 \neq \lambda_2$ ，因此 $\mathbf{x}_2^T \mathbf{x}_1 = 0$ 。

* 机器学习中使用的矩阵一般为实对称矩阵，因此特征值均为实数，且不同特征值的特征向量两两正交



• 特征值与特征向量

■ 矩阵的谱 (Spectrum)

根据多项式分解定理，特征多项式 $p_A(\lambda) := \det(A - \lambda I_n)$ 可以写成

$$p_A(\lambda) = (\lambda - \lambda_1)^{n_1} (\lambda - \lambda_2)^{n_2} \cdots (\lambda - \lambda_m)^{n_m}$$

其中 n_i 称为特征值 λ_i 的代数重数 (Algebraic Multiplicity)，根据代数方程的理论，有

$$\sum_{i=1}^m n_i = n$$

所有 m 个不同的特征值构成的集合称为矩阵的谱，记为

$$\sigma(A) = \{\lambda_1, \cdots, \lambda_m\}$$

■ 矩阵的谱半径 (Spectral Radius)

定义为所有特征值模（若为实数，则绝对值）的最大值，记为

$$\rho(A) = \max\{||\lambda_1||, \cdots, ||\lambda_m||\}$$



• 特征值与特征向量

■ 特征子空间 (Characteristic Subspace)

与一个给定特征值 $\lambda_i \in \sigma(A)$ 相伴的所有特征向量与零向量集合作成 $\mathbb{C}^n$ 的一个子空间，该子空间是齐次线性方程组

$$(A - \lambda_i I_n)x = 0$$

的解集，也称为特征矩阵 $A - \lambda_i I_n$ 的零空间 (Null space)

➤ 也就是说，满足 $Ax = \lambda_i x$ 的所有向量 x 组成的集合称为矩阵 A 关于特征值 λ_i 的特征子空间，记为

$$S_{\lambda_i} = \{x \in \mathbb{C}^n | (A - \lambda_i I)x = 0\}$$

➤ 根据齐次线性方程组解的理论，特征子空间的维数为

$$p_i = n - \text{rank}(A - \lambda_i I)$$

➤ 根据维基百科，也有把这个特征子空间也直接称为特征空间 (Eigenspace)，它是一个线性子空间



• 特征值与特征向量

■ 特征子空间 (Characteristic Subspace)

➤ 范例：矩阵

$$A = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 4 \end{bmatrix}$$

的特征值为2和4，其中2对应的特征向量为形如

$$\mathbf{x}_1 = [a \quad b \quad 0]^T$$

的非零向量，而4对应的特征向量为形如

$$\mathbf{x}_2 = [0 \quad 0 \quad c]^T$$

则特征值 2 对应的特征空间是一个 $p_1 = 2$ 维空间，而4对应的特征空间是一个 $p_2 = 1$ 维空间

➤ 属于不同特征值的特征向量线性无关，矩阵所有线性无关的特征向量的数量为

$$\sum_{i=1}^m p_i \leq n$$



• 特征值与特征向量

■ 几何重数 (Geometric Multiplicity)

对于每个特征值 λ_i ，求解线性方程组

$$(A - \lambda_i I)x = 0$$

即可得到其对应的特征向量，方程组有 $1 \leq m_i \leq n_i$ 个线性无关的解，称 m_i 为 λ_i 的几何重数 (Geometric Multiplicity)

➤ 特征值 λ_i 的几何重数等于与特征值 λ_i 对应的特征子空间的维数即

$$m_i = p_i = n - \text{rank}(A - \lambda_i I)$$

➤ 特征值的几何重数 m_i 小于或者等于它的代数重数 n_i ，且

$$n - n_i \leq \text{rank}(A - \lambda_i I)$$

➤ 代数重数为 1，几何重数必定为 1

➤ A 可对角化的充分必要条件是 每个特征值的几何重数与代数重数相等



• 特征值与特征向量

- 范例：对于矩阵

$$A = \begin{bmatrix} -1 & 1 & 0 \\ -4 & 3 & 0 \\ 1 & 0 & 2 \end{bmatrix}$$

- 其特征多项式为

$$\det(A - \lambda I_n) = (2 - \lambda)(1 - \lambda)^2$$

解得，特征值为 $\lambda_1 = 2, \lambda_2 = 1$

- 因此，特征值对应的代数重数为 $n_1 = 1, n_2 = 2$,

- 将特征值 2 和 1 代入特征方程， $k \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \quad m=1$

$$(A - 2I)x = 0, \quad (A - I)x = 0$$

- 因此，分别可解得矩阵 A 关于特征值 2 和 1 的特征子空间的维度，即几何重数为

$$m_1 = 1, m_2 = 1$$

$$\begin{array}{ccc|l} -3 & 1 & 0 & -3x_1 + x_2 = 0 \\ -4 & 1 & 0 & -4x_1 + x_2 = 0 \\ 1 & 0 & 0 & x_1 = 0 \end{array}$$

$$\begin{array}{ccc|l} -2 & 1 & 0 & -2x_1 + x_2 = 0 \\ -4 & 2 & 0 & -4x_1 + 2x_2 = 0 \\ 1 & 0 & 1 & x_1 + x_3 = 0 \end{array}$$

$$x_1 = \frac{1}{2}x_2$$

$$x_1 = -x_3$$

$$k \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \quad m=1$$



• 矩阵的奇异值

■ 矩阵奇异值 (Singular Value) 的定义

对于 $m \times n$ 阶矩阵 A , $A^T A$ 的 $\min(m, n)$ 个非负特征值的算术平方根叫作 A 的奇异值

$$\omega(A) = \sqrt{\lambda(A^T A)}$$

➤ 范例：给定矩阵

$$A = \begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{bmatrix}$$

首先

$$A^T A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$



• 矩阵的奇异值

■ 矩阵奇异值 (Singular Value) 的定义

➤ 范例：进而求出 $\mathbf{A}^T \mathbf{A}$ 的特征值和特征向量

$$\lambda_1 = 3, \mathbf{x}_1 = [1/\sqrt{2} \quad 1/\sqrt{2}]^T; \lambda_2 = 1, \mathbf{x}_2 = [-1/\sqrt{2} \quad 1/\sqrt{2}]^T$$

因此，奇异值为 $\omega_1 = \sqrt{3}$ 和 $\omega_2 = 1$

■ 矩阵奇异值的性质

- 对于 $n \geq m$ ，若 $\mathbf{A}$ 是满秩的，当且仅当它的所有奇异值都是正数
- $\mathbf{A}$, $\mathbf{A}^T$, $\bar{\mathbf{A}}$ 有相同的奇异值
- 奇异值分解是线性代数和矩阵论中一种重要的矩阵分解法，适用于信号处理和统计学等领域
- 在图像处理领域，奇异值往往对应着矩阵中隐含的重要信息，且重要性和奇异值大小正相关



• 矩阵的范数

■ 矩阵范数的定义

$m \times n$ 维矩阵 A 的范数是一个从 $m \times n$ 线性空间到实数域的一个函数，记为 $\|A\|$ ，满足

- 非负性： $\|A\| \geq 0$ ， $\|A\| = 0$ 当且仅当 $A = 0$
- 齐次性： $\|aA\| = |a|\|A\|$
- 三角不等式： $\|A + B\| \leq \|A\| + \|B\|$
- 相容性： $\|AB\| \leq \|A\|\|B\|$

■ 矩阵范数的扩展（矩阵范数却不存在公认唯一的度量方式）

- 诱导范数 (Induced Norm)：通过向量的 L_p 范数来定义

$$\|A\|_p = \max_{\substack{x \neq 0 \\ x \in \mathbb{R}^n}} \frac{\|Ax\|_p}{\|x\|_p} = \max_{\substack{x \neq 0 \\ x \in \mathbb{R}^n}} \frac{\left(\sum_{i=1}^m \left| \sum_{j=1}^n a_{ij} x_j \right|^p \right)^{\frac{1}{p}}}{\left(\sum_{j=1}^n |x_j|^p \right)^{\frac{1}{p}}}$$



• 矩阵的范数

■ 矩阵范数的定义

其中,

- 当 $p = 1$:

最大绝对列和

$$||\mathbf{A}||_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

- 当 $p = 2$ (欧几里德范数, 谱范数)

$$||\mathbf{A}||_2 = \sqrt{\lambda_{\max}(\mathbf{A}^T \mathbf{A})} = \max_{i=1, \dots, n} \omega_i(\mathbf{A})$$

$||\mathbf{A}||_2$ 是半正定矩阵 $\mathbf{A}^T \mathbf{A}$ 的最大特征值的平方根或 $\mathbf{A}$ 最大的奇异值

- 当 $p = \infty$:

最大绝对行和

$$||\mathbf{A}||_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

对于 $m \times n$ 阶矩阵 $\mathbf{A}$, $\mathbf{A}^T \mathbf{A}$ 的 $\min(m, n)$ 个非负特征值的算术平方根叫作 $\mathbf{A}$ 的奇异值

$$\omega_i(\mathbf{A}) = \sqrt{\lambda_i(\mathbf{A}^T \mathbf{A})}$$



• 矩阵的范数

■ 矩阵范数的定义

➤ 范例：给定矩阵 $A = \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix}$ ，则

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| = \max\{7, 7\} = 7$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} = \sqrt{\max\{32, 18\}} = \sqrt{32}$$

$$\|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^m |a_{ij}| = \max\{8, 6\} = 8$$

➤ 范例：给定矩阵 $A = \begin{bmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$ ，则

$$\|A\|_1 = 2, \quad \|A\|_2 = \sqrt{5}, \quad \|A\|_{\infty} = 3$$

$$\begin{bmatrix} 4 & -3 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix}$$

$$= \begin{bmatrix} 25 & 7 \\ 7 & 25 \end{bmatrix}$$

$$(\lambda - 25)^2 - 7^2 = (\lambda - 32)(\lambda - 18)$$

$$\begin{bmatrix} 1 & 0 & 0 \\ 2 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

$$= \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$

$$A^T A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$

$$\lambda(A^T A) = 0, 5$$



• 矩阵的范数

■ 矩阵范数的扩展

➢ 任何诱导的矩阵范数都满足不等式

$$\|A\|_p \geq \rho(A)$$

其中 $\rho(A)$ 是 A 的谱半径, 即

$$\rho(A) := \max\{|\lambda_1|, \dots, |\lambda_m|\}$$

• 证明: 根据定义

$$\rho(A) = \max_{\lambda \in \sigma(A)} |\lambda(A)|$$

$$|\lambda(A)| \cdot \|x\|_p = \|\lambda(A)x\|_p = \|Ax\|_p \leq \|A\|_p \cdot \|x\|_p$$

因为 $x \neq 0$, $|\lambda(A)| \leq \|A\|_p$

$$\rho(A) \leq \|A\|_p$$

范数的相容性



• 矩阵的范数

■ 矩阵范数的扩展

➤ 对于矩阵 A

$$\|A\|_2 = \sqrt{\rho(A^T A)}$$

• 证明：因为 $(A^T A)^T = A A^T$ ，同时，有

$$\|Ax\|_2^2 = (Ax)^T (Ax) = x^T A^T A x \geq 0$$

因此， $A^T A$ 为对称正定矩阵，且

$$\|Ax\|_2^2 = x^T A^T A x \leq \lambda_{\max}(A^T A) \|x\|_2^2$$

所以

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} \leq (\lambda_{\max}(A^T A))^{\frac{1}{2}}$$



• 矩阵的范数

■ 矩阵范数的扩展

➢ 接上证明，若 $\mathbf{x}$ 为单位向量，则 $\|\mathbf{Ax}\|_2^2 = \lambda_{\max}(\mathbf{A}^T \mathbf{A})$ 且

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq 0} \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2} \geq \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2} = (\lambda_{\max}(\mathbf{A}^T \mathbf{A}))^{\frac{1}{2}}$$

➢ 弗罗贝尼乌斯 (Frobenius) 范数 (非诱导范数)

$$\|\mathbf{A}\|_F = \sqrt{\text{trace}(\mathbf{A}^T \mathbf{A})} = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$$

• F范数是谱范数的一个上界，即

$$\|\mathbf{A}\|_2 = \max_{\substack{\mathbf{x} \neq 0 \\ \mathbf{x} \in \mathbb{R}^n}} \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2} \leq \|\mathbf{A}\|_F$$

$$\|\mathbf{A}\|_F = \sqrt{\sum \lambda_i(\mathbf{A}^T \mathbf{A})} = \sqrt{\sum \sigma_i(\mathbf{A})}$$



• 矩阵的范数

■ 矩阵范数的扩展

➤ 极大值范数（非诱导范数）

$$||\mathbf{A}||_{\max} = \max_{i,j \in \{1, \dots, n\}} |a_{ij}|$$

■ 矩阵范数的性质

$$➤ ||\mathbf{A}||_2 \leq ||\mathbf{A}||_F \leq \sqrt{n} ||\mathbf{A}||_2$$

$$➤ ||\mathbf{A}||_{\max} \leq ||\mathbf{A}||_2 \leq \sqrt{mn} ||\mathbf{A}||_{\max}$$

$$➤ \frac{1}{\sqrt{n}} ||\mathbf{A}||_{\infty} \leq ||\mathbf{A}||_2 \leq \sqrt{m} ||\mathbf{A}||_{\infty}$$

$$➤ \frac{1}{\sqrt{m}} ||\mathbf{A}||_1 \leq ||\mathbf{A}||_2 \leq \sqrt{n} ||\mathbf{A}||_1$$

$$➤ ||\mathbf{A}||_2 \leq \sqrt{||\mathbf{A}||_1 ||\mathbf{A}||_{\infty}}$$

$$||\mathbf{A}||_{\max} \leq ||\mathbf{A}||_2 \leq ||\mathbf{A}||_F$$



• 正交矩阵

■ 正交矩阵 (Orthogonal Matrix) 的定义

对于给定 $n \times n$ 的实数矩阵 A , 满足

$$AA^T = A^T A = I$$

➤ 正交矩阵具有: $A^{-1} = A^T$

➤ 正交矩阵的乘积仍为正交矩阵: $(AB)^{-1} = B^{-1}A^{-1} = B^T A^T = (AB)^T$

➤ 正交矩阵的行列式值必定为1或-1

$$1 = \det(I) = \det(A^T A) = \det(A^T) \det(A) = (\det(A))^2 \rightarrow \det(A) = \pm 1$$

• 行列式值为+1的正交矩阵, 称为特殊正交矩阵, 它是一个旋转矩阵

• 行列式值为-1的正交矩阵, 称为瑕旋转矩阵(旋转加上镜射)

➤ 例子

• $\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 为恒等变换



• 正交矩阵

■ 正交矩阵 (Orthogonal Matrix) 的定义

➤ 例子

• $\begin{bmatrix} 0.96 & -0.28 \\ 0.28 & 0.96 \end{bmatrix}$ 旋转 16.26°

逆时针旋转 θ

$$\begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$

• $\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$ 针对 x 轴反射

• $\begin{bmatrix} 0 & -0.80 & -0.60 \\ 0.80 & -0.36 & 0.48 \\ 0.60 & 0.48 & 0.64 \end{bmatrix}$ 旋转反转: 轴 $(0, -0.6, 0.8)$, 角度 90°

• $\begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}$ 置换坐标轴



• 正交矩阵

■ 正交变换 (Orthogonal Transformation)

是线性变换的一种，对一个由空间投射到同一空间的线性变换，**如果转换前后的向量长度保持不变**，则称为正交变换

➢ 有向量 $\mathbf{x}$ 和正交矩阵 $\mathbf{A}$ ，则

$$\|\mathbf{Ax}\| = \sqrt{(\mathbf{Ax})^T (\mathbf{Ax})} = \sqrt{\mathbf{x}^T \mathbf{A}^T \mathbf{Ax}} = \sqrt{\mathbf{x}^T (\mathbf{A}^T \mathbf{A}) \mathbf{x}} = \sqrt{\mathbf{x}^T \mathbf{x}} = \|\mathbf{x}\|$$


即**变换后长度不变**

$$\|\mathbf{Ax}\|_2^2 = (\mathbf{Ax})^T (\mathbf{Ax}) = \mathbf{x}^T \mathbf{A}^T \mathbf{Ax} = \mathbf{x}^T (\mathbf{A}^T \mathbf{A}) \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|_2^2$$

➢ 向量 $\mathbf{x}, \mathbf{y}$ ，且 $\mathbf{A}$ 为正交矩阵，根据向量夹角公式

$$\cos\theta = \frac{\mathbf{x}^T \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|} = \frac{\langle \mathbf{Ax}, \mathbf{Ay} \rangle}{\|\mathbf{Ax}\| \|\mathbf{Ay}\|}$$

内积和长度均不变，因此**向量间夹角不变**





• 正交矩阵

■ 正交变换的性质

➢ 正交变换不会改变向量间的正交性，若 $\langle \mathbf{x}, \mathbf{y} \rangle = 0$ 且 $\mathbf{A}$ 为正交矩阵，则 $\langle \mathbf{Ax}, \mathbf{Ay} \rangle = 0$

➢ 若 $\mathbf{A}$ 为正交矩阵， $\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{Ax}, \mathbf{Ay} \rangle$

$$\langle \mathbf{Ax}, \mathbf{Ay} \rangle = \mathbf{x}^T \mathbf{A}^T \mathbf{Ay} = \mathbf{x}^T \mathbf{y} = \langle \mathbf{x}, \mathbf{y} \rangle$$

➢ 若矩阵 $\mathbf{A}$ 和矩阵 $\mathbf{B}$ 均为正交矩阵，则 $\mathbf{AB}$ 为正交矩阵

$$\|\mathbf{ABx}\| = \|\mathbf{A(Bx)}\| = \|\mathbf{Bx}\| = \|\mathbf{x}\|$$

即在 $\mathbf{AB}$ 下正交变换后长度不变

➢ 若矩阵 $\mathbf{A}$ 为正交矩阵，则 $\mathbf{A}^{-1}$ 为正交矩阵

■ 正交变换的应用

离散傅里叶变换、离散余弦变换、离散哈特利变换、离散沃尔什变换等都属于正交变换，对矩阵做旋转或是镜射也属于正交变换



• 矩阵的相似变换

■ 相似矩阵 (Similar Matrix) 的定义

是指存在相似关系的矩阵，相似关系是两个矩阵的一种等价关系；两个 $n \times n$ 矩阵 A 与 B 为相似矩阵，当且仅当存在一个 $n \times n$ 的可逆矩阵 P ，使得

$$P^{-1}AP = B$$

记为 $A \sim B$ ， P 被称为矩阵 A 与 B 之间的相似变换矩阵

➤ 例如

$$A = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}$$

➤ 相似矩阵的几何意义就是同一个线性变换在不同的基下的表达形式



• 矩阵的相似变换

■ 相似矩阵的性质

- 反身性：任意矩阵都与其自身相似，即 $A \sim A$ 。显然

$$I^{-1}AI = A$$

- 对称性：如果 A 和 B 相似，那么 B 也与 A 相似，即如果 $A \sim B$ ，则 $B \sim A$ ；由于

$$P^{-1}AP = B$$

上式两边同时左乘 P ，右乘 P^{-1} ，可以得到

$$A = PBP^{-1} = (P^{-1})^{-1}AP^{-1}$$

- 传递性：如果 A 和 B 相似， B 和 C 相似，那么 A 也和 C 相似，即如果 $A \sim B$ 且 $B \sim C$ ，则 $A \sim C$ ；由于 $A \sim B$ 且 $B \sim C$ ，因此有

$$P_1^{-1}AP_1 = B, \quad P_2^{-1}BP_2 = C$$

从而有

$$P_2^{-1}BP_2 = P_2^{-1}(P_1^{-1}AP_1)P_2 = (P_1P_2)^{-1}A(P_1P_2) = C$$



• 矩阵的相似变换

■ 相似矩阵的性质

- 相似矩阵拥有同样的特征值，尽管相应的特征向量一般不同，即相似变换保持矩阵的特征值不变

证明：假设 $A \sim B$ ，则存在可逆矩阵 P 使得 $P^{-1}AP = B$ ，因此

$$\det(B - \lambda I)$$

$$= \det(P^{-1}AP - \lambda I)$$

$$= \det(P^{-1}AP - \lambda P^{-1}IP)$$

$$= \det(P^{-1}(A - \lambda I)P)$$

$$= \det(P^{-1}) \det((A - \lambda I)) \det(P) = \det((A - \lambda I))$$

$$|AB| = |A||B|$$

- 可用于求解特征值，用相似变换将矩阵 A 变为对角矩阵或三角矩阵，特征值不变，对角矩阵或三角矩阵的主对角线元素即为 A 的特征值
- 若 $B = PAP^{-1}$ ，则 $\text{tr}(B) = \text{tr}(PAP^{-1}) = \text{tr}(P^{-1}PA) = \text{tr}(A)$



• 矩阵的相似变换

■ 相似矩阵的性质

- 两者的秩相等
- 两者的行列式值相等
- 两者的迹数相等
- 两者拥有同样的特征多项式
- 两者拥有同样的初等因子

■ 相似矩阵的判别方法

- 判断两个矩阵是否相似的**必要条件**:

- 判断特征根是否相等
- 判断行列式是否相等
- 判断迹是否相等
- 判断秩是否相等

- 两矩阵相似**充要条件**为它们的特征矩阵等价

对于实对称矩阵 A 和 B ，存在一个 $n \times n$ 的**可逆正交矩阵** P ，使得

$$P^{-1}AP = B$$

那么 A 和 B 就互为正交相似

两个 $m \times n$ 矩阵 A, B 等价当且仅当存在可逆的 $n \times n$ 方阵 P 和 $m \times m$ 方阵 Q 使得

$$A = QBP$$



• 矩阵的相似变换

■ 矩阵的正交相似变换

对于实对称矩阵，可以构造一个正交的相似变换将其对角化，因为实对称矩阵一定可以对角化，即 n 阶实对称矩阵有 n 个线性无关的特征向量

■ 矩阵正交相似变换的方法

- 实对称矩阵 A 属于不同特征值的特征向量是相互正交的，如果用格拉姆-施密特正交化将同一个特征值的所有特征向量正交化，然后将所有特征向量单位化，可以得到一组标准正交基 $p_1, \dots, p_n$
- 以 $p_1, \dots, p_n$ 为列构造相似变换矩阵 P ，则矩阵 P 是正交矩阵，可通过正交变换将矩阵转化为对角阵

$$P^T A P = \Lambda$$

因为正交矩阵满足 $P^T = P^{-1}$ ，因此这是一种更特殊的相似变换



• 矩阵的相似变换

■ 矩阵正交相似变换的方法

➤ 范例：对于下面的矩阵

$$A = \begin{bmatrix} 2 & -2 & 0 \\ -2 & 1 & -2 \\ 0 & -2 & 0 \end{bmatrix}$$

其特征多项式为

$$\det(A - \lambda I) = \begin{vmatrix} 2 - \lambda & -2 & 0 \\ -2 & 1 - \lambda & -2 \\ 0 & -2 & -\lambda \end{vmatrix} = (\lambda - 4)(\lambda - 1)(\lambda + 2)$$

因此其特征值为 $\lambda_1 = 4, \lambda_2 = 1, \lambda_3 = -2$

当 $\lambda = 4$ 时，有

$$(A - 4I)x = 0, \quad \text{解得 } \mathbf{u}_1 = [2 \quad -2 \quad 1]^T$$

当 $\lambda = 1$ 时，有

$$(A - 1I)x = 0, \quad \text{解得 } \mathbf{u}_2 = [-2 \quad -1 \quad 2]^T$$

$$\begin{aligned} & (2 - \lambda)(-\lambda + \lambda^2 - 4) \\ & + 2 \cdot 2\lambda \\ & = -2\lambda + 2\lambda^2 - 8 + \lambda^2 - \lambda^3 + 8\lambda \\ & = -\lambda^3 + 3\lambda^2 + 6\lambda - 8 \end{aligned}$$



• 矩阵的相似变换

■ 矩阵正交相似变换的方法

➤ 范例：接上

当 $\lambda = -2$ 时，有

$$(A + 2I)x = 0, \quad \text{解得 } \mathbf{u}_3 = [1 \quad 2 \quad 2]^T$$

不同特征值的特征向量正交，单位化 $\mathbf{p}_i = \mathbf{u}_i / \|\mathbf{u}_i\|$ ，得到正交矩阵

$$P = \begin{bmatrix} \frac{2}{3} & -\frac{2}{3} & \frac{1}{3} \\ \frac{2}{3} & \frac{1}{3} & \frac{2}{3} \\ \frac{1}{3} & \frac{2}{3} & \frac{2}{3} \end{bmatrix}$$

$$P^{-1}AP = \Lambda = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -2 \end{bmatrix}$$





• 矩阵的相似变换

■ 矩阵正交相似变换的方法

➤ 范例：对于下面的矩阵

$$A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

其特征多项式为

$$\det(A - \lambda I) = \begin{vmatrix} -\lambda & 1 & 1 \\ 1 & -\lambda & 1 \\ 1 & 1 & -\lambda \end{vmatrix} = -(\lambda - 2)(\lambda + 1)^2$$

因此其特征值为 2, -1, -1。

当 $\lambda = 2$ 时, 有

$$(A - 2I)x = 0, \quad \text{解得 } x_1 = [1 \ 1 \ 1]^T$$

当 $\lambda = -1$ 时, 有

$$(A + I)x = 0, \quad \text{解得 } x_2 = [-1 \ 1 \ 0]^T, \quad x_3 = [-1 \ 0 \ 1]^T$$

向量线性无关



• 矩阵的相似变换

■ 矩阵正交相似变换的方法

➢ 接上，进行格拉姆-施密特正交化

◆ 首先，令 $\mathbf{u}_1 = \mathbf{x}_1 = [1 \ 1 \ 1]^T$

$$\mathbf{u}_2 = \mathbf{x}_2 - \frac{\langle \mathbf{x}_2, \mathbf{u}_1 \rangle}{\langle \mathbf{u}_1, \mathbf{u}_1 \rangle} \mathbf{u}_1 = \mathbf{x}_2 - \text{proj}_{\mathbf{u}_1} \mathbf{x}_2 = [-1 \ 1 \ 0]^T$$

◆ 接着计算

$$\mathbf{u}_3 = \mathbf{x}_3 - \frac{\langle \mathbf{x}_3, \mathbf{u}_1 \rangle}{\langle \mathbf{u}_1, \mathbf{u}_1 \rangle} \mathbf{u}_1 - \frac{\langle \mathbf{x}_3, \mathbf{u}_2 \rangle}{\langle \mathbf{u}_2, \mathbf{u}_2 \rangle} \mathbf{u}_2 = [-1 \ -1 \ 2]^T$$

◆ 最后，进行正交单位化之后

$$\mathbf{p}_1 = \frac{1}{\sqrt{3}} [1 \ 1 \ 1]^T,$$

$$\mathbf{p}_2 = \frac{1}{\sqrt{2}} [-1 \ 1 \ 0]^T, \quad \mathbf{p}_3 = \frac{1}{\sqrt{6}} [-1 \ -1 \ 2]^T$$



• 矩阵的相似变换

■ 矩阵正交相似变换的方法

➤ 令 $\mathbf{P} = [\mathbf{p}_1 \quad \mathbf{p}_2 \quad \mathbf{p}_3] = \begin{bmatrix} \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{3}} & 0 & \frac{2}{\sqrt{6}} \end{bmatrix}$, 因此有

$$\mathbf{P}^{-1}\mathbf{A}\mathbf{P} = \mathbf{P}^T\mathbf{A}\mathbf{P} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \end{bmatrix}$$

■ 矩阵正交相似变换的性质

➤ 正交变换不改变矩阵的对称性, 即对称矩阵 $\mathbf{A}$ 的正交变换 $\mathbf{P}$ 后, 所得

$$\mathbf{B} = \mathbf{P}^T\mathbf{A}\mathbf{P}$$

仍然是对称矩阵

• 证明: $\mathbf{B}^T = (\mathbf{P}^T\mathbf{A}\mathbf{P})^T = \mathbf{P}^T\mathbf{A}^T(\mathbf{P}^T)^T = \mathbf{P}^T\mathbf{A}\mathbf{P} = \mathbf{B}$



• 矩阵的可对角化

■ 对角矩阵 (Diagonal Matrix) 的定义

主对角线之外的元素皆为 0 的矩阵，常记作

$$\text{diag}(a_{11}, a_{22}, \dots, a_{nn}) = \begin{bmatrix} a_{11} & 0 & 0 & 0 \\ 0 & a_{22} & 0 & 0 \\ 0 & 0 & a_{33} & 0 \\ 0 & 0 & 0 & a_{33} \end{bmatrix}$$

■ 对角矩阵 (Diagonal Matrix) 的定义

如果存在一个可逆矩阵 P ，使 $P^{-1}AP$ 的结果为对角矩阵，则称 P 矩阵将矩阵 A 对角化

- 对于一个矩阵来说，不一定存在将其对角化的矩阵，但是任意一个 $n \times n$ 矩阵如果存在 n 个线性无关的特征向量，则该矩阵可被对角化
- 如果存在一个可逆矩阵 P ，使 $P^{-1}AP$ 的结果为对角矩阵，则矩阵 P 的列是矩阵 A 的特征向量， $P^{-1}AP$ 的主对角元素为矩阵 A 的特征值



• 矩阵的可对角化

■ 可对角化矩阵 (Diagonalizable Matrices)

$n \times n$ 维方阵 A 如果与一个对角矩阵相似, 则称 A 为可对角化矩阵 (或称单纯矩阵)

■ 可对角矩阵的性质

设实数域矩阵 $A \in \mathbb{R}^{n \times n}$, A 的全部互异特征值为 $\lambda_1, \dots, \lambda_m$, 则以下命题等价

- 矩阵 A 可对角化
- 矩阵 A 有 n 个线性无关的特征向量
- $\sum_i^m \dim(S_{\lambda_i}) = n$, 其中

$$S_{\lambda_i} = \{x \in \mathbb{C}^n | (A - \lambda_i I)x = 0\}$$

为矩阵 A 关于特征值 λ_i 的特征子空间

- 矩阵 A 的每个特征值 λ_i 的代数重数 n_i 等于几何重数 m_i



• 矩阵的约旦对角化

■ 约旦块 (Jordan Block)

也译作若尔当块，主对角线上同为 $\lambda \in \mathbb{R}$ ， λ 的上面（次对角线）都有一个 1，其余元素都是 0 的 m 阶方阵

$$J_m(\lambda) := \begin{bmatrix} \lambda & 1 & & \\ & \lambda & \ddots & \\ & & \ddots & 1 \\ & & & \lambda \end{bmatrix} \in \mathbb{R}^{m \times m}$$

而称以约旦块为对角块的**准对角**阵为约旦型矩阵

$$J = \begin{bmatrix} J_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & J_m \end{bmatrix}$$





• 矩阵的约旦对角化

■ 约旦标准型 (Jordan Normal Form) 定理

约旦标准型的目标就是将更多的矩阵化简到一类只比对角矩阵稍微复杂的矩阵；特别是，对于实数矩阵 $A \in \mathbb{R}^{n \times n}$ 及其特征多项式

$$p_A(\lambda) = (\lambda - \lambda_1)^{n_1} (\lambda - \lambda_2)^{n_2} \cdots (\lambda - \lambda_m)^{n_m}$$

若其特征值都在域 $\mathbb{R}$ 中，就存在一个可逆矩阵 P ，使之相似于一个约旦标准型，即

$$A = PJP^{-1}$$

其中

$$J = \begin{bmatrix} J_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & J_m \end{bmatrix}$$

约旦矩阵



• 矩阵的约旦对角化

■ 约旦标准型 (Jordan Normal Form) 定理

其中

$$J = \begin{bmatrix} J_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & J_m \end{bmatrix} \quad \longrightarrow \quad J_i = \begin{bmatrix} J_{i1} & 0 & 0 & 0 \\ 0 & J_{i2} & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & J_{im_i} \end{bmatrix} \in \mathbb{R}^{n_i \times n_i}$$

每个特征值总共有 n_i 维, m_i 个约旦块

其中 n_i 为特征值 λ_i 的代数重数, m_i 是 λ_i 的几何重数, 且

$$J_{ij} = J_{l_{ij}}(\lambda_i) = \begin{bmatrix} \lambda_i & 1 & & \\ & \lambda_i & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_i \end{bmatrix} \in \mathbb{R}^{l_{ij} \times l_{ij}}$$

► 约旦标准型在不记约旦块的排列次序下是唯一的



• 矩阵的约旦对角化

■ 约旦标准型的性质

- 对于约旦标准型的代数重数 n_i 和几何重数 m_i , 有

$$n_1 + n_2 + \cdots + n_m = n$$

$$l_{i1} + l_{i2} + \cdots + l_{im_i} = n_i$$

$$1 \leq m_i \leq n_i$$

对于矩阵 J 的一个特征值 λ_i , 它的几何重数 m_i 就是属于特征值 λ_i 的约旦块的个数, 所有属于特征值 λ_i 的约旦块的维数之和是特征值 λ_i 的代数重数 n_i

- 若矩阵 A 的特征值各不相同 (无重根), 则系统的约旦标准型矩阵为主对角线为特征值的对角线矩阵
- A 相似于对角阵 $\longleftrightarrow l_{ij} = 1 \longleftrightarrow m_i = n_i$



• 矩阵的约旦对角化

■ 约旦标准型的构建方法

- 求出矩阵 $A \in \mathbb{R}^{n \times n}$ 全部的特征值 $\lambda_1, \dots, \lambda_m$, 假设有 m 个不同的特征值, 同时求出每个特征值 λ_i 的代数重数 n_i
- 计算特征值 λ_i 对应的约旦块的个数及阶数

$$r_0 = n, \quad n \text{ 为方阵 } A \text{ 的大小}$$

$$r_t = \text{rank}(A - \lambda_i I)^t, \quad t = 1, 2, \dots, k_i$$

k_i 即 $\text{rank}(A - \lambda_i I)^{k_i} = \text{rank}(A - \lambda_i I)^{k_i+1}$ 成立的最小正整数, 也就是 λ_i 对应的约旦块的最大阶数, 此外

$$\delta_t = r_{t-1} + r_{t+1} - 2r_t$$

δ_t 为 λ_i 对应的 t 阶约旦块的个数

- 将所获得的约旦块按任意次序排列成约旦矩阵



• 矩阵的约旦对角化

■ 约旦标准型的构建方法

➤ 例题1：对于矩阵

$$A = \begin{bmatrix} 2 & 6 & -15 \\ 1 & 1 & -5 \\ 1 & 2 & -6 \end{bmatrix}$$

解得：

$$|\lambda I - A| = \begin{vmatrix} \lambda - 2 & -6 & 15 \\ -1 & \lambda - 1 & 5 \\ -1 & -2 & \lambda + 6 \end{vmatrix} = (\lambda + 1)^3$$

所以只有一个特征值 $\lambda_1 = -1$ 代数重数为 $n_1 = 3$ ；对 $\lambda_1 = -1$ ，令

$$B = A - \lambda_1 I = A + I = \begin{bmatrix} 3 & 6 & -15 \\ 1 & 2 & -5 \\ 1 & 2 & -5 \end{bmatrix}, \quad B^2 = 0$$



$$r_1 = \text{rank}(B) = 1, r_2 = \text{rank}(B^2) = 0, r_3 = \text{rank}(B^2) = 0, \quad \rightarrow k_1 = 2$$



• 矩阵的约旦对角化

■ 约旦标准型的构建方法

► 接上例1，所以以 λ_1 为特征值，阶为1的约旦块的个数为

$$\delta_1 = r_0 + r_2 - 2r_1 = 3 + 0 - 2 \times 1 = 1$$

以 λ_1 为特征值，阶为2的约旦块的个数为

$$\delta_2 = r_1 + r_3 - 2r_2 = 1 + 0 - 2 \times 0 = 1$$

上述两个约旦块阶数之和为3，等于 λ_1 的代数重数，因而不存在以 λ_1 为特征值的其它约旦块；因矩阵 A 没有其它特征值，只有一个重数为3的特征值 $\lambda_1 = -1$ ，一阶二阶各一个，所以矩阵 A 的约旦标准型为

$$J = \begin{bmatrix} -1 & 0 & 0 \\ 0 & -1 & 1 \\ 0 & 0 & -1 \end{bmatrix}$$



• 矩阵的约旦对角化

■ 约旦标准型的构建方法

➢ 例2, 对于矩阵

$$A = \begin{bmatrix} 3 & -4 & 0 & 2 \\ 4 & -5 & -2 & 4 \\ 0 & 0 & 3 & -2 \\ 0 & 0 & 2 & -1 \end{bmatrix}$$

解得:

$$|\lambda I - A| = \begin{vmatrix} \lambda - 3 & 4 & 0 & -2 \\ -4 & \lambda + 5 & 2 & -4 \\ 0 & 0 & \lambda - 3 & 2 \\ 0 & 0 & -2 & \lambda + 1 \end{vmatrix} = (\lambda + 1)^2(\lambda - 1)^2$$

所以 A 有两个特征值 $\lambda_1 = -1$ 和 $\lambda_2 = 1$, 它们的代数重数分别为 $n_1 = 2, n_2 = 2$

• 当 $\lambda_1 = -1$ 时, 令



• 矩阵的约旦对角化

■ 约旦标准型的构建方法

➢ 接上，当 $\lambda_1 = -1$ 时，令

$$B_1 = A - \lambda_1 I = A + I = \begin{bmatrix} 4 & -4 & 0 & 2 \\ 4 & -4 & -2 & 4 \\ 0 & 0 & 4 & -2 \\ 0 & 0 & 2 & 0 \end{bmatrix} \Rightarrow r_1 = \text{rank } B_1 = 3$$

$$B_1^2 = \begin{bmatrix} 0 & 0 & 12 & -8 \\ 0 & 0 & 8 & -4 \\ 0 & 0 & 12 & -8 \\ 0 & 0 & 8 & -4 \end{bmatrix} \Rightarrow r_2 = \text{rank } B_1^2 = 2$$

$$B_1^3 = \begin{bmatrix} 0 & 0 & 32 & -24 \\ 0 & 0 & 24 & -16 \\ 0 & 0 & 32 & -24 \\ 0 & 0 & 24 & -16 \end{bmatrix} \Rightarrow r_3 = \text{rank } B_1^3 = 2$$



• 矩阵的约旦对角化

■ 约旦标准型的构建方法

➢ 接上，因此以 λ_1 为特征值，使 $\text{rank}(\mathbf{A} - \lambda_1 \mathbf{I})^{k_1} = \text{rank}(\mathbf{A} - \lambda_1 \mathbf{I})^{k_1+1}$ 成立的最小正整数为 $k_1 = 2$ ，即 λ_1 对应的约旦块的最大阶数为 2

$\therefore$ 以 λ_1 为特征值，阶为 1 的约旦块的个数为

$$\delta_1 = r_0 + r_2 - 2r_1 = 4 + 2 - 2 \times 3 = 0$$

$\therefore$ 以 λ_1 为特征值，阶为 2 的约旦块的个数为

$$\delta_2 = r_1 + r_3 - 2r_2 = 3 + 2 - 2 \times 2 = 1$$

上述约旦块总阶数等于 λ_1 的代数重数 $n_1 = 2$ ，即 λ_1 的约旦块求解完毕

• 当 $\lambda_2 = 1$ 时，令

$$\mathbf{B}_2 = \mathbf{A} - \lambda_2 \mathbf{I} = \mathbf{A} - \mathbf{I} = \begin{bmatrix} 2 & -4 & 0 & 2 \\ 4 & -6 & -2 & 4 \\ 0 & 0 & 2 & -2 \\ 0 & 0 & 2 & -2 \end{bmatrix} \quad \longrightarrow \quad r_1 = \text{rank } \mathbf{B}_2 = 3$$



• 矩阵的约旦对角化

■ 约旦标准型的构建方法

➤ 接上

$$\mathbf{B}_2^2 = \begin{bmatrix} -12 & -16 & 12 & -16 \\ -16 & 20 & 16 & 20 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$



$$r_2 = \text{rank } \mathbf{B}_2^2 = 2$$

$$\mathbf{B}_2^3 = \begin{bmatrix} 40 & -48 & -40 & 48 \\ 48 & -56 & -48 & 56 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$



$$r_3 = \text{rank } \mathbf{B}_2^3 = 2$$

因此以 λ_2 为特征值, 使 $\text{rank}(\mathbf{A} - \lambda_2 I)^{k_2} = \text{rank}(\mathbf{A} - \lambda_2 I)^{k_2+1}$ 成立的最小正整数为 $k_2 = 2$, 即 λ_2 对应的约旦块的最大阶数为 2

∴ 以 λ_2 为特征值, 阶为 1 的约旦块的个数为

$$\delta_1 = r_0 + r_2 - 2r_1 = 4 + 2 - 2 \times 3 = 0$$



• 矩阵的约旦对角化

■ 约旦标准型的构建方法

➤ 接上

$\therefore$ 以 λ_2 为特征值，阶为 2 的约旦块的个数为

$$\delta_2 = r_1 + r_3 - 2r_2 = 3 + 2 - 2 \times 2 = 1$$

上述第二个约旦块阶数为 2，等于 λ_2 的代数重数 n_2 ，至此 λ_2 的约旦块求解完毕

• 最终，以 $\lambda_1 = -1$ 和 $\lambda_2 = 1$ 为特征值的约旦块各是一个二阶的，所以矩阵 A 的约旦标准型为

$$J = \begin{bmatrix} -1 & 1 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$



• 矩阵的约旦对角化

■ 约旦标准型的构建方法

➤ 例3: 对于矩阵

$$A = \begin{bmatrix} 5 & 4 & 2 & 1 \\ 0 & 1 & -1 & -1 \\ -1 & -1 & 3 & 0 \\ 1 & 1 & -1 & 2 \end{bmatrix}$$

解得:

$$|\lambda I - A| = (\lambda - 1)(\lambda - 2)(\lambda - 4)^2$$

所以 A 有3个特征值 $\lambda_1 = 1, \lambda_2 = 2, \lambda_3 = 4$, 它们的代数重数分别为 $n_1 = 1, n_2 = 1, n_3 = 2$;

• 对于 $\lambda_1 = 1$ 时, 则

$$m_1 = 1$$

• 对于 $\lambda_2 = 2$ 时, 则

$$m_2 = 1$$



• 矩阵的约旦对角化

■ 约旦标准型的构建方法

➤ 例3

• 对于 $\lambda_3 = 4$,

$$A - 4I = \begin{bmatrix} 1 & 4 & 2 & 1 \\ 0 & -3 & -1 & -1 \\ -1 & -1 & -1 & 0 \\ 1 & 1 & -1 & -2 \end{bmatrix}$$
$$m_3 = 3 - \text{rank}(A - 4I) = 1$$

• 因此, 最终的标准型为

$$J = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 4 & 1 \\ 0 & 0 & 0 & 4 \end{bmatrix}$$



• 雅可比矩阵 (Jacobian Matrix)

■ 雅可比矩阵的定义

雅可比矩阵是由多个多元函数的梯度构成的矩阵，即对于向量 $\mathbf{x} \in \mathbb{R}^n$ 到向量 $\mathbf{y} \in \mathbb{R}^m$ 的映射为

$$\mathbf{y} = f(\mathbf{x})$$

其可写成分量形式，每个分量都是一个多元函数

$$y_1 = f_1(x_1, x_2, \dots, x_n), y_2 = f_2(x_1, x_2, \dots, x_n), \dots, y_m = f_m(x_1, x_2, \dots, x_n)$$

因此，雅可比矩阵是函数的一阶偏导数以一定方式排列成的矩阵，当其为方阵时，称为雅可比行列式

$$J_f = \frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial f_1}{\partial x} & \dots & \frac{\partial f_m}{\partial x} \end{bmatrix}^T = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \dots & \frac{\partial y_m}{\partial x_n} \end{bmatrix}$$

因此，这是一个 $m \times n$ 的矩阵，每一行为一个多元函数的梯度



- 雅可比矩阵 (Jacobian Matrix)

➤ 例如，向量函数

$$y_1 = x_1^2 + 2x_1x_2 + x_3, \quad y_2 = x_1 - x_2^2 + x_3^2$$

则雅可比矩阵为

$$J_f =$$

➤ 例如，向量函数 $y_1 = x_1, \quad y_2 = 5x_3, \quad y_3 = 4x_2^2, \quad y_4 = x_3 \sin x_1$

则雅可比

$$J_f =$$



• 雅可比矩阵 (Jacobian Matrix)

➤ 例如，向量函数

$$y_1 = x_1^2 + 2x_1x_2 + x_3, \quad y_2 = x_1 - x_2^2 + x_3^2$$

则雅可比矩阵为

$$J_f = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} & \frac{\partial y_1}{\partial x_3} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} & \frac{\partial y_2}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 2x_1 + 2x_2 & 2x_1 & 1 \\ 1 & -2x_2 & 2x_3 \end{bmatrix}$$

➤ 例如，向量函数 $y_1 = x_1, \quad y_2 = 5x_3, \quad y_3 = 4x_2^2, \quad y_4 = x_3 \sin x_1$

则雅可比

$$J_f = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 5 \\ 0 & 8x_2 & -2 \\ x_3 \cos x_1 & 0 & \sin x_1 \end{bmatrix}$$



• 雅可比矩阵 (Jacobian Matrix)

■ 线性向量函数雅可比矩阵

对于线性映射

$$\mathbf{y} = \mathbf{A}\mathbf{x}$$

其中 $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{y} \in \mathbb{R}^m$, $\mathbf{A} \in \mathbb{R}^{m \times n}$, 则其雅可比矩阵为

$$\mathbf{J}_f = \frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{A}$$

➤ 例如, 对于下列线性映射

$$\begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

则雅可比矩阵为

$$\mathbf{J}_f = \frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$



• 雅可比矩阵 (Jacobian Matrix)

■ 雅可比矩阵在多元函数换元中的应用

考虑极坐标变换，由极坐标到直角坐标系统的转换公式

$$x = r \cos \theta, y = r \sin \theta$$

$$\Rightarrow J_f = \frac{\partial(x, y)}{\partial(r, \theta)} = \begin{bmatrix} \frac{\partial x}{\partial r} & \frac{\partial x}{\partial \theta} \\ \frac{\partial y}{\partial r} & \frac{\partial y}{\partial \theta} \end{bmatrix} = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}$$

➤ 例如：由球坐标系到直角坐标系的转化由函数 $\mathbb{R}^+ \times [0, \pi) \times [0, 2\pi) \rightarrow \mathbb{R}^3$ 给出 $x = r \sin \theta \cos \varphi, y = r \sin \theta \sin \varphi, z = r \cos \theta$ ，则雅可比矩阵为

$$J_f = \begin{bmatrix} \frac{\partial x}{\partial r} & \frac{\partial x}{\partial \theta} & \frac{\partial x}{\partial \varphi} \\ \frac{\partial y}{\partial r} & \frac{\partial y}{\partial \theta} & \frac{\partial y}{\partial \varphi} \\ \frac{\partial z}{\partial r} & \frac{\partial z}{\partial \theta} & \frac{\partial z}{\partial \varphi} \end{bmatrix} = \begin{bmatrix} \sin \theta \cos \varphi & r \cos \theta \cos \varphi & -r \sin \theta \sin \varphi \\ \sin \theta \sin \varphi & r \cos \theta \sin \varphi & \sin \theta \cos \varphi \\ \cos \theta & -r \sin \theta & 0 \end{bmatrix}$$



• 雅可比矩阵 (Jacobian Matrix)

■ 雅可比矩阵行列式

若雅可比矩阵为方阵，则它的行列式称为雅可比行列式

➢ 例如，极坐标变换中

$$\det\left(\frac{\partial(x, y)}{\partial(r, \theta)}\right) = \begin{vmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{vmatrix} = r \cos^2 \theta + r \sin^2 \theta = r$$

➢ 例如，旋转变换中

$$\begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \rightarrow J_f = \frac{\partial(y_1, y_2)}{\partial(x_1, x_2)} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

$$\det(J_f) = \begin{vmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{vmatrix} = \cos^2 \theta + \sin^2 \theta = 1$$

■ 雅可比矩阵行列式的性质

若连续可微函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 在点 x 的雅可比行列式不等于零，那么它在该点附近有 f 的反函数 f^{-1}



• 雅可比矩阵 (Jacobian Matrix)

■ 雅可比矩阵行列式的性质

- 如果在某点 $\mathbf{x}$ 的雅可比矩阵行列式是正数，则 f 在 $\mathbf{x}$ 点保持定向；如果雅可比矩阵行列式是负数，则 f 在 $\mathbf{x}$ 点逆转定向；而雅可比矩阵行列式的绝对值，指示 f 在 $\mathbf{x}$ 点附近是放大或缩小体积

- 例如，设有函数 $f: \mathbb{R}^3 \rightarrow \mathbb{R}^3$ ，其分量为

$$y_1 = 5x_2, \quad y_2 = 4x_1^2 - 2 \sin x_2 x_3, \quad y_3 = x_2 x_3$$

$$\begin{vmatrix} 0 & 5 & 0 \\ 8x_1 & -2x_3 \cos(x_2 x_3) & -2x_2 \cos(x_2 x_3) \\ 0 & x_3 & x_2 \end{vmatrix} = -8x_1 \begin{vmatrix} 5 & 0 \\ x_3 & x_2 \end{vmatrix} = -40x_1 x_2$$

由雅可比矩阵行列式可知，当 x_1 和 x_2 同号时，逆转定向，该函数除了在处处具有反函数 $x_1 = 0$ 或 $x_2 = 0$ 的点



• 雅可比矩阵 (Jacobian Matrix)

■ 雅可比矩阵的性质

- 如果函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 在点 $\mathbf{x}$ 可微的话，在点 $\mathbf{x}$ 的雅可比矩阵即为该函数在该点的最佳线性逼近，也代表雅可比矩阵是单变数实数函数的微分在向量值多变数量函数的推广；因此，雅可比矩阵也被称作函数 f 在点 $\mathbf{x}$ 的微分或者导数
- 对于动力系统 $\dot{\mathbf{x}} = f(\mathbf{x})$ ，其中 $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ ，如果 $f(\mathbf{x}_0) = 0$ ，则 $\mathbf{x}_0$ 是一个临界点，动力系统接近临界点时的行为跟 $J_f(\mathbf{x}_0)$ 的特征值相关
- 一个可逆函数（存在反函数的函数）的雅可比矩阵的逆矩阵即为该函数的反函数的雅可比矩阵，即若函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 在点 $\mathbf{x} \in \mathbb{R}^n$ 的雅可比矩阵式连续可逆的，则 f 在点 $\mathbf{x}$ 的某一领域内也是可逆的，且有

$$\frac{\partial \mathbf{x}}{\partial \mathbf{y}} =: J_{f^{-1}}(f(\mathbf{x})) = J_f^{-1}(\mathbf{x}) := \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right)^{-1} \quad \longrightarrow \quad \det\left(\frac{\partial \mathbf{x}}{\partial \mathbf{y}}\right) = \det\left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}}\right)^{-1}$$



• 黑塞矩阵 (Hessian Matrix)

■ 黑塞矩阵 (Hessian Matrix) 的定义

黑塞矩阵由多元函数的二阶偏导数组成的矩阵，假设 $f(x_1, \dots, x_n)$ 的二阶偏导数都存在且在定义域内连续，那么函数 f 的黑塞矩阵

$$H_f = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

为一个 $n \times n$ 的方阵，由于多元函数的混合二阶偏导数与求导次序无关

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}$$

因此黑塞矩阵是一个对称矩阵，可记为 $\nabla^2 f(\mathbf{x})$



• 黑塞矩阵 (Hessian Matrix)

■ 黑塞矩阵 (Hessian Matrix) 的定义

➢ 黑塞矩阵是对梯度向量的每个分量再次求梯度形成行向量得到的，即

$$\nabla^2 f(\mathbf{x}) = \text{grad} \left(\text{grad}(f(\mathbf{x})) \right) = \begin{bmatrix} \text{grad}(\frac{\partial f}{\partial x_1}) \\ \vdots \\ \text{grad}(\frac{\partial f}{\partial x_n}) \end{bmatrix} = \begin{bmatrix} \frac{\partial}{\partial x_1} (\frac{\partial f}{\partial x_1}) & \cdots & \frac{\partial}{\partial x_n} (\frac{\partial f}{\partial x_1}) \\ \vdots & \ddots & \vdots \\ \frac{\partial}{\partial x_1} (\frac{\partial f}{\partial x_n}) & \cdots & \frac{\partial}{\partial x_n} (\frac{\partial f}{\partial x_n}) \end{bmatrix}$$

➢ 例如，对于多元函数

$$f(\mathbf{x}) = 2x_1^2 - x_1x_2 + x_2^2 - 3x_3^2$$

它的黑塞矩阵为

$$\mathbf{H}_f = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \frac{\partial^2 f}{\partial x_1 \partial x_3} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \frac{\partial^2 f}{\partial x_2 \partial x_3} \\ \frac{\partial^2 f}{\partial x_3 \partial x_1} & \frac{\partial^2 f}{\partial x_3 \partial x_2} & \frac{\partial^2 f}{\partial x_3^2} \end{bmatrix} = \begin{bmatrix} 4 & -1 & 0 \\ -1 & 2 & 0 \\ 0 & 0 & -6 \end{bmatrix}$$



• 黑塞矩阵 (Hessian Matrix)

■ 黑塞矩阵的性质

➤ 多元函数的极值性:

假设函数 $y = f(x_1, \dots, x_n)$ 在点 $(a_1, \dots, a_n)$ 的领域内有二阶连续偏导, 若有

$$\left. \frac{\partial f}{\partial x_j} \right|_{(a_1, \dots, a_n)} = 0, \quad j = 1, 2, \dots, n$$

$(a_1, \dots, a_n)$ 为函数 $y = f(x_1, \dots, x_n)$ 的驻点, 并且

- 当 $H_f(a_1, \dots, a_n)$ 为正定, 则 $f(x_1, \dots, x_n)$ 在 $(a_1, \dots, a_n)$ 处是极小值
- 当 $H_f(a_1, \dots, a_n)$ 为负定, 则 $f(x_1, \dots, x_n)$ 在 $(a_1, \dots, a_n)$ 处是极大值
- 当 $H_f(a_1, \dots, a_n)$ 为不定矩阵, 则 $(a_1, \dots, a_n)$ 不是极值点
- 当 H_f 为半正定矩阵或半负定矩阵, 则 $(a_1, \dots, a_n)$ 是“可疑”极值点, 但仍需进一步确认



• 黑塞矩阵 (Hessian Matrix)

■ 黑塞矩阵的性质

➤ 多元函数的极值性:

■ 范例：三元函数

$$f(x_1, x_2, x_3) = x_1^2 + x_2^2 + x_3^2 + 2x_1 + 4x_2 - 6x_3$$

$$\therefore \frac{\partial f}{\partial x_1} = 2x_1 + 2, \quad \frac{\partial f}{\partial x_2} = 2x_2 + 4, \quad \frac{\partial f}{\partial x_3} = 2x_3 - 6$$

$\therefore$ 三元函数的驻点为 $(-1, -2, 3)$

$$\therefore \frac{\partial^2 f}{\partial x_1^2} = 2, \quad \frac{\partial^2 f}{\partial x_2^2} = 2, \quad \frac{\partial^2 f}{\partial x_3^2} = 2, \quad \frac{\partial^2 f}{\partial x_1 \partial x_2} = 0, \quad \frac{\partial^2 f}{\partial x_1 \partial x_3} = 0, \quad \frac{\partial^2 f}{\partial x_2 \partial x_3} = 0$$



$$\mathbf{H}_f = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix} > 0$$

$\therefore$ 驻点 $(-1, -2, 3)$ 是极小值点，且极小值为 $f(-1, -2, 3) = -14$



• 黑塞矩阵 (Hessian Matrix)

■ 黑塞矩阵的性质

➤ 多元函数的凹凸性:

假设函数 $y = f(\mathbf{x})$ 二阶可导, $\mathbf{x} = [x_1, \dots, x_n]^T$

- 如果函数的黑塞矩阵是半正定, 则函数为 **凸函数**
- 如果黑塞矩阵是正定, 则函数为 **严格凸函数**
- 如果黑塞矩阵是半负定, 则函数为 **凹函数**
- 如果黑塞矩阵是负定, 则函数为 **严格凹函数**

➤ 例题

- $f(\mathbf{x}) = x_1^2 + x_2^2$, $\mathbf{H}_f = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$, 严格凸函数
- $f(\mathbf{x}) = -x_1^2 - x_2^2$, $\mathbf{H}_f = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix}$, 严格凹函数
- $f(\mathbf{x}) = (x_1 + x_1^2 + x_2^3)e^{-x_1^2 - x_2^2}$, $\mathbf{H}_f$ 非半正定/半负定, 非凹/凸函数



• 牛顿法 (Newton Method)

■ 牛顿法的定义

又被称为牛顿-拉弗森方法 (Newton-Raphson method)，它是一种在实数域和复数域上近似求解方程或非线性最优化问题的方法

➤ 基本思想：


利用迭代点处的一阶导数（梯度）和二阶导数（Hessen矩阵）对目标函数进行二次函数近似，然后把二次模型的极小点作为新的迭代点，并不断重复这一过程，直至求得满足精度的近似极小值

➤ 最优化问题

$$\min_{x \in \mathbb{R}^n} f(x)$$

- 梯度法： $x(k+1) = x(k) - \alpha \nabla f(x(k))$

- 牛顿法： $x(k+1) = x(k) - \alpha (\mathbf{H}_f^{-1}(x(k))) \nabla f(x(k))$



知乎 @Eureka



• 牛顿法 (Newton Method)

■ 牛顿法的性质

➢ 优点

- 牛顿法是二阶收敛，梯度下降是一阶收敛，牛顿法收敛性更快

➢ 劣势

- 牛顿法是一种迭代算法，每一步都需要求解目标函数的Hessian矩阵（二阶导数）的逆矩阵，计算比较复杂，存储空间量大
- 牛顿法是局部收敛的，当初始点选择不当时，往往导致不收敛
- 二阶Hessian矩阵必须可逆，否则算法进行困难
- 在小样本数据集的情况下，牛顿法对于二阶导数的估计噪声太大
- 目标函数非凸的时候，牛顿法容易受到鞍点或者最大值点的吸引

■ 拟牛顿法 (Quasi-Newton Method)

拟牛顿法是一种以牛顿法为基础设计的，不用二阶偏导数而构造出可以近似海塞矩阵（或海塞矩阵的逆）的正定对称阵



• 随机矩阵 (Stochastic Matrix)

■ 转移矩阵 (Transition Matrix) 的定义

概率矩阵(Probability Matrix)、替代矩阵(Substitution Matrix)、马尔可夫矩阵(Markov Matrix)或转移概率矩阵(Transition Probability Matrix), 是用来描述一个马尔可夫链的转变的矩阵, 它的每一项都是一个表示概率的非负实数

- 如果在一个时间步长内从状态 x_i 到状态 x_j 转移的概率为 $\Pr(x_j|x_i) = p_{ij}$, 则随机矩阵 P 的第 i 行, 第 j 列元素由 $p_{i,j}$ 给出

$$P = \begin{bmatrix} p_{11} & \cdots & p_{1n} \\ \vdots & \ddots & \vdots \\ p_{n1} & \cdots & p_{nn} \end{bmatrix}$$

- 右随机矩阵(Right stochastic matrix)是实方阵, 其中每一行求和为1
- 左随机矩阵(Left stochastic matrix)是实方阵, 其中每一列求和为1
- 双随机矩阵(Doubly Stochastic Matrix)是实方阵, 每个行和列求和均为1



• 随机矩阵 (Stochastic Matrix)

■ 随机矩阵的应用

用以表示概率/变化比率，而矩阵相乘的结果可预测未来事件发生的概率

- 模拟一个在迷宫中移动的老鼠：迷宫是一个包含九个房间的封闭空间并且有连接房间的门道；我们假设老鼠是一个“马尔科夫老鼠”，即老鼠从一个房间随机移动到另一个房间，老鼠到达下一个房间的可能性仅取决于它当前存在的房间（遗忘属性），而不取决于它如何获得到当前的房间，从1到2、4；从2到1、2、5；...从9到6、8，通过得到的信息可以创建随机矩阵，也即转换矩阵

$$P = \begin{bmatrix} 0 & 1/2 & 0 & 1/2 & 0 & 0 & 0 & 0 & 0 \\ 1/3 & 0 & 1/3 & 0 & 1/3 & 0 & 0 & 0 & 0 \\ 0 & 1/2 & 0 & 0 & 0 & 1/2 & 0 & 0 & 0 \\ 1/3 & 0 & 0 & 0 & 1/3 & 0 & 1/3 & 0 & 0 \\ 0 & 1/4 & 0 & 1/4 & 0 & 1/4 & 0 & 1/4 & 0 \\ 0 & 0 & 1/3 & 0 & 1/3 & 0 & 0 & 0 & 1/3 \\ 0 & 0 & 0 & 1/2 & 0 & 0 & 0 & 1/2 & 0 \\ 0 & 0 & 0 & 0 & 1/3 & 0 & 1/3 & 0 & 1/3 \\ 0 & 0 & 0 & 0 & 0 & 1/2 & 0 & 1/2 & 0 \end{bmatrix}$$

