



• 瑞利商 (Rayleigh Quotient)

■ 瑞利商 (Rayleigh Quotient) 的定义

$n \times n$ 实 **对称矩阵** A 和 **非 0** 向量 x 的瑞利商定义为如下比值

$$R(A, x) = \frac{x^T A x}{x^T x}$$

■ 瑞利商的性质

➢ 缩放不变性：对于任意的非 0 实数 k ，有

$$R(A, kx) = R(A, x)$$

即对向量缩放之后其瑞利商不变，因为

$$R(A, kx) = \frac{(kx)^T A (kx)}{(kx)^T (kx)} = \frac{k^2 x^T A x}{k^2 x^T x} = \frac{x^T A x}{x^T x}$$

➢ 瑞利商的最小值为矩阵的最小特征值，最大值为矩阵的最大特征值

$$\lambda_{\min}(A) \leq R(A, x) \leq \lambda_{\max}(A)$$

等号当且仅当 x 为相应的特征向量的时取得



• 瑞利商 (Rayleigh Quotient)

■ 瑞利商的性质


- 当向量 $\mathbf{x}$ 是标准正交基时，即满足 $\mathbf{x}^T \mathbf{x} = \mathbf{1}$ 时，瑞利商变为
对于任意的非 $\mathbf{0}$ 向量 $\mathbf{x}$ ，有

$$R(\mathbf{A}, \mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$$

- 约束优化问题：

$$\begin{aligned} \max_{\mathbf{x} \in \mathbb{R}^n} \quad & \mathbf{x}^T \mathbf{A} \mathbf{x} \\ \text{subject to} \quad & \|\mathbf{x}\|^2 = 1 \end{aligned}$$

即给定对称矩阵 $\mathbf{A}$ ，在单位圆 $\|\mathbf{x}\|^2 = 1$ 上找到向量 $\mathbf{x} \in \mathbb{R}^n$ 使得二次型 $\mathbf{x}^T \mathbf{A} \mathbf{x}$ 达到它的极值点





• 瑞利商 (Rayleigh Quotient)

■ 瑞利商的性质

- 瑞利商与特征值的关系：假设 λ_i 是 A 的第 i 个特征值， $\mathbf{x}_i$ 是其对应的特征向量，将他们代入瑞利商的定义可以得到

$$R(A, \mathbf{x}_i) = \frac{\mathbf{x}_i^T \mathbf{A} \mathbf{x}_i}{\mathbf{x}_i^T \mathbf{x}_i} = \frac{\mathbf{x}_i^T (\lambda_i \mathbf{x}_i)}{\mathbf{x}_i^T \mathbf{x}_i} = \frac{\lambda_i \mathbf{x}_i^T \mathbf{x}_i}{\mathbf{x}_i^T \mathbf{x}_i} = \lambda_i$$

∴ 瑞利商在 $\lambda_{\max}(A)$ 处取最大值， $\lambda_{\min}(A)$ 取最小值

- 广义瑞利商：实**对称矩阵** A 、**正定矩阵** B 、**非0**向量 $\mathbf{x}$ 的

$$R(A, B, \mathbf{x}) = \frac{\mathbf{x}^T \mathbf{A} \mathbf{x}}{\mathbf{x}^T \mathbf{B} \mathbf{x}}$$

➡ $R(A, B, \mathbf{x})$ 的最大值为 $\mathbf{B}^{-\frac{1}{2}} \mathbf{A} \mathbf{B}^{-\frac{1}{2}}$ 的最大特征值

- 瑞利商与谱范数：

$$\|A\|_2^2 = \max_{\mathbf{x} \neq 0} R(A^T A, \mathbf{x}) = \max_{\mathbf{x} \neq 0} \frac{\mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x}}{\mathbf{x}^T \mathbf{x}}$$



• 瑞利商 (Rayleigh Quotient)

■ 瑞利商的应用

- 主成分分析 (Principal Components Analysis, PCA)

$$\max_{x \neq 0} \frac{x^T \Sigma x}{x^T x}$$



最大投影方差

Σ 为协方差矩阵

- 线性判别分析 (Linear Discriminant Analysis, LDA)

$$\max_{x \neq 0} \frac{x^T S_b x}{x^T S_w x}$$



投影后希望同一种类别数据的投影点尽可能的接近，而不同类别的数据的类别中心之间的距离尽可能的大

S_b 为类间散度矩阵, S_w 类内散度矩阵

- 谱聚类 (Spectral Clustering)

$$\max_{x \neq 0} \frac{x^T L x}{x^T D x}$$

L 为拉普拉斯矩阵, D 为度矩阵



• 矩阵的条件数 (Condition Number)

■ 条件数 (Condition Number) 的定义

对于可逆矩阵 A ，条件数定义为它的范数与它的逆矩阵范数的乘积

$$\kappa(A) = \|A\| \cdot \|A^{-1}\|$$

这里的范数可以是任何一种范数，如果使用谱范数，则 $\|A\|$ 等于 A 最大奇异值， $\|A^{-1}\|$ 等于 A 最小奇异值的逆，即

$$\|A^{-1}\| = \max_{y \neq 0} \frac{\|A^{-1}y\|}{\|y\|} = \max_{x \neq 0} \frac{\|x\|}{\|Ax\|} = \frac{1}{\min_{x \neq 0} \frac{\|Ax\|}{\|x\|}}$$

∴ 对于谱范数的条件数等于矩阵的最大奇异值与最小奇异值的比值

$$\kappa(A) = \frac{\max\{\sigma_1, \dots, \sigma_n\}}{\min\{\sigma_1, \dots, \sigma_n\}}, \quad \text{其中 } \sigma_1, \dots, \sigma_n \text{ 为矩阵 } A \text{ 的奇异值}$$

• 若矩阵 A 为正规矩阵

$$AA^T = A^T A$$

$$\kappa(A) = \frac{\max\{|\lambda_1|, \dots, |\lambda_n|\}}{\min\{|\lambda_1|, \dots, |\lambda_n|\}}, \quad \text{其中 } \lambda_1, \dots, \lambda_n \text{ 为矩阵 } A \text{ 的特征值}$$



• 矩阵的条件数

■ 条件数（Condition Number）的定义

- 若矩阵 A 为正交矩阵

$$\kappa(A) = 1$$

■ 条件数的几何意义

条件数描述线性变换 Ax 中， A 对向量 x 的拉伸能力和压缩能力，即令向量发生形变的能力；条件数越大，向量在变换后越可能变化得越多

■ 条件数的应用

对于线性方程

$$Ax = y$$

A 是系数矩阵，一般由模型决定， x 是待求量， y 是观测值；若观测值的微小改动不会使方程的解 x 发生剧烈变化，就称该方程是稳定的，即稳定性衡量的是线性方程的抗噪声能力



• 矩阵的条件数

■ 条件数与稳定性

比如线性方程组

$$\begin{bmatrix} 5 & 7 \\ 7 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0.7 \\ 1 \end{bmatrix}$$

的解为 $\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.1 \end{bmatrix}$, 而



$$\begin{bmatrix} 5 & 7 \\ 7 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0.69 \\ 1.01 \end{bmatrix}$$

的解为 $\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -0.17 \\ 0.22 \end{bmatrix}$, 可见 $\mathbf{y}$ 很小的扰动就引起了 $\mathbf{x}$ 很大的变化, 这是由于矩阵 $\mathbf{A}$ 的条件数 $\kappa(\mathbf{A}) = 222.9955$ 较大决定的

► 条件数表示矩阵计算对于误差的敏感性, 它是误差分析中的一项通用工具

2-3

行列式





• 行列式的基本概念

■ 行列式 (Determinant) 的定义

行列式是对矩阵的一种运算，作用于方阵，将其映射成一个标量； n 阶方阵 A 的行列式记为 $|A|$ 或 $\det(A)$ ，称为 n 阶行列式，其计算公式为

$$|A| = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{vmatrix} = \sum_{j_1 j_2 \cdots j_n \in S_n} (-1)^{\tau(j_1 j_2 \cdots j_n)} \prod_{i=1}^n a_{i, j_i}$$

- 其中 $j_1 j_2 \cdots j_n$ 为正整数 $1, 2, \dots, n$ 的一个排列， S_n 是这 n 个正整数所有排列构成的集合，显然有 $n!$ 种排列
- $\tau(j_1 j_2 \cdots j_n)$ 为排列 $j_1 j_2 \cdots j_n$ 的逆序数，对于一个排列 $j_1 j_2 \cdots j_n$ ，如果 $m < n$ ，但 $j_m > j_n$ ，则称为一个逆序，排列中所有逆序的数量称为排列的逆序数

- 例如，对于3个正整数1,2,3，其所有排列的集合 S_n 为

$\{1, 2, 3\}, \{1, 3, 2\}, \{2, 1, 3\}, \{2, 3, 1\}, \{3, 1, 2\}, \{3, 2, 1\}$



• 行列式的基本概念

- 其中，排列 3,2,1 的所有逆序为 (3,2), (2,1), (3,1)，因此其逆序为 3；
排列 2,1,3 的所有逆序为 (2,1)，因此其逆序为 1

➤ 例如，3阶行列式的计算公式

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = (-1)^{\tau(1,2,3)} a_{11} a_{22} a_{33} + (-1)^{\tau(2,3,1)} a_{12} a_{23} a_{31} \\ + (-1)^{\tau(3,1,2)} a_{13} a_{21} a_{32} + (-1)^{\tau(3,2,1)} a_{13} a_{22} a_{31} \\ + (-1)^{\tau(1,3,2)} a_{11} a_{23} a_{32} + (-1)^{\tau(2,1,3)} a_{12} a_{21} a_{33} \\ = a_{11} a_{22} a_{33} + a_{12} a_{23} a_{31} + a_{13} a_{21} a_{32} - a_{13} a_{22} a_{31} \\ - a_{11} a_{23} a_{32} - a_{12} a_{21} a_{33}$$

➤ 例如，下面的3阶行列式值为

$$\begin{vmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 1 & 2 & 2 \end{vmatrix} = 1 \times 5 \times 2 + 2 \times 6 \times 1 + 3 \times 4 \times 2 - 3 \times 5 \times 1 - 1 \times 6 \times 2 - 2 \times 4 \times 2 = 3$$



• 行列式的基本概念

■ 拉普拉斯展开 (Laplacian Expansion) 的定义

行列式可以按照行或列进行递归展开，成为拉普拉斯展开

$$\begin{aligned}\det(A) &= a_{i1}A_{i1} + a_{i2}A_{i2} + \cdots + a_{in}A_{in} \\ &= a_{1j}A_{1j} + a_{2j}A_{2j} + \cdots + a_{nj}A_{nj}\end{aligned}$$

其中

$$A_{ij} = (-1)^{i+j} \begin{vmatrix} a_{11} & \cdots & a_{1,j-1} & a_{1,j+1} & \cdots & a_{1n} \\ \vdots & & \vdots & \vdots & & \vdots \\ a_{i-1,1} & \cdots & a_{i-1,j-1} & a_{i-1,j+1} & \cdots & a_{i-1,n} \\ a_{i+1,1} & \cdots & a_{i+1,j-1} & a_{i+1,j+1} & \cdots & a_{i+1,n} \\ \vdots & & \vdots & \vdots & & \vdots \\ a_{n1} & \cdots & a_{n,j-1} & a_{n,j+1} & \cdots & a_{nn} \end{vmatrix}$$

是去掉矩阵 A 的第 i 行和第 j 列之后的 $n-1$ 阶矩阵的行列式，并且带有符号 $(-1)^{i+j}$ ， $i+j$ 为行号和列号之和；称 A_{ij} 为 a_{ij} 的代数余子式，不带符号的子行列式则称为余子式



• 行列式的基本概念

■ 拉普拉斯展开 (Laplacian Expansion) 的定义

➢ 例如，下面的行列式可以按第一行展开为

$$\begin{vmatrix} 1 & 2 & 3 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{vmatrix} = 1 \times (-1)^{1+1} \times \begin{vmatrix} 0 & 1 \\ 1 & 0 \end{vmatrix} + 2 \times (-1)^{1+2} \times \begin{vmatrix} 1 & 1 \\ 1 & 0 \end{vmatrix} \\ + 3 \times (-1)^{1+3} \times \begin{vmatrix} 1 & 0 \\ 1 & 1 \end{vmatrix}$$

■ 拉普拉斯展开的性质

➢ 如果一个矩阵为**对角矩阵**，则其**行列式为矩阵主对角元素的乘积**，这是因为 $n!$ 个求和项中，除了全部由主对角线元素构成的项之外，其他项的乘积中都有0，即

$$\begin{vmatrix} a_{11} & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & a_{nn} \end{vmatrix} = \prod_{i=1}^n a_{ii}$$



- 行列式的基本概念

- 拉普拉斯展开的性质

- 上三角矩阵和下三角矩阵的行列式为其主对角线元素的乘积

$$\begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & a_{nn} \end{vmatrix} = \prod_{i=1}^n a_{ii} \quad \begin{vmatrix} a_{11} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix} = \prod_{i=1}^n a_{ii}$$

- 例如

$$\begin{vmatrix} 1 & 4 & 6 \\ 0 & 2 & 5 \\ 0 & 0 & 3 \end{vmatrix} = 1 \times 2 \times 3 = 6$$

- 行列式的性质

- 行列式具有多线性，可以按照某一行或列的线性组合拆分成两个行列式值和



• 行列式的基本概念

■ 行列式的性质

➢ 行列式多线性

$$\begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i-1,1} & \cdots & a_{i-1,n} \\ \alpha a_{i1} + \beta b_{i1} & \cdots & \alpha a_{in} + \beta b_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix} = \alpha \begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i-1,1} & \cdots & a_{i-1,n} \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix} + \beta \begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i-1,1} & \cdots & a_{i-1,n} \\ b_{i1} & \cdots & b_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix}$$

因为

$$\begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i-1,1} & \cdots & a_{i-1,n} \\ \alpha a_{i1} + \beta b_{i1} & \cdots & \alpha a_{in} + \beta b_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix} = \sum_{j_1 j_2 \cdots j_n} (-1)^{\tau(j_1 j_2 \cdots j_n)} a_{1j_1} \cdots (\alpha a_{ij_i} + \beta b_{ij_i}) \cdots a_{nj_n}$$

$$= \alpha \sum_{j_1 j_2 \cdots j_n} (-1)^{\tau(j_1 j_2 \cdots j_n)} a_{1j_1} \cdots a_{ij_i} \cdots a_{nj_n} + \beta \sum_{j_1 j_2 \cdots j_n} (-1)^{\tau(j_1 j_2 \cdots j_n)} a_{1j_1} \cdots b_{ij_i} \cdots a_{nj_n}$$



• 行列式的基本概念

■ 行列式的性质

➢ 接上

$$= \alpha \begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i-1,1} & \cdots & a_{i-1,n} \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix} + \beta \begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i-1,1} & \cdots & a_{i-1,n} \\ b_{i1} & \cdots & b_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix}$$

• 例如: $\begin{vmatrix} 1+2 & 2+3 & 3+4 \\ 1 & 0 & 0 \\ 0 & 1 & 1 \end{vmatrix} = \begin{vmatrix} 1 & 2 & 3 \\ 1 & 0 & 0 \\ 0 & 1 & 1 \end{vmatrix} + \begin{vmatrix} 2 & 3 & 4 \\ 1 & 0 & 0 \\ 0 & 1 & 1 \end{vmatrix}$

➢ 如果行列式的两行或列相等, 那么行列式的值为0, 即

$$\begin{vmatrix} a_{11} & \cdots & a_{1n} \\ a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix} = \begin{vmatrix} a_{11} & a_{11} & \cdots & a_{1n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n1} & \cdots & a_{nn} \end{vmatrix} = 0$$



• 行列式的基本概念

■ 行列式的性质

证明：假设行列式的第 i 行和第 k 行相等，则行列式的 $n!$ 个求和项可以分为两组，即

$$(-1)^{\tau(j_1 \cdots j_j \cdots j_k \cdots j_n)} a_{1j_1} \cdots a_{ij_i} \cdots a_{kj_k} \cdots a_{nj_n}$$

与

$$(-1)^{\tau(j_1 \cdots j_k \cdots j_j \cdots j_n)} a_{1j_1} \cdots a_{ij_k} \cdots a_{kji} \cdots a_{nj_n}$$

由于 $a_{ij_i} = a_{kji}$, $a_{kj_k} = a_{ij_k}$ 且排列 $j_1 \cdots j_j \cdots j_k \cdots j_n$ 与 $j_1 \cdots j_j \cdots j_k \cdots j_n$ 的逆序数的奇偶性相反（二者通过一次置换可以互相得到），因此这两项的符号相反，故行列式的值为0

• 例如：

$$\begin{vmatrix} 1 & 2 & 3 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{vmatrix} = 0$$



• 行列式的基本概念

■ 行列式的性质

- 根据这一结论可以构造出可逆矩阵的逆矩阵，对于矩阵

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{n1} \\ a_{21} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

假设 A_{ij} 是 a_{ij} 的代数余子式，利用他们构造如下的伴随矩阵

$$A^* = \begin{bmatrix} A_{11} & A_{12} & \cdots & A_{n1} \\ A_{21} & A_{22} & \cdots & A_{n2} \\ \vdots & \vdots & & \vdots \\ A_{n1} & A_{n2} & \cdots & A_{nn} \end{bmatrix}$$

根据拉普拉斯展开，第 i 行与其代数余子式的内积为行列式本身

$$|A| = a_{i1}A_{i1} + a_{i2}A_{i2} + \cdots + a_{in}A_{in}$$

第 i 行与第 $j, j \neq i$ 行的代数余子式的内积为0,这还是因为它是第 i 行与第 j 行相等的行列式的拉普拉斯展开，其值为0



• 行列式的基本概念

■ 行列式的性质

接上，即有 $0 = a_{i1}A_{i1} + a_{i2}A_{i2} + \cdots + a_{in}A_{in}, j \neq i$ ，因此有

$$AA^* = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{n1} \\ a_{21} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} A_{11} & A_{12} & \cdots & A_{n1} \\ A_{21} & A_{22} & \cdots & A_{n2} \\ \vdots & \vdots & & \vdots \\ A_{n1} & A_{n2} & \cdots & A_{nn} \end{pmatrix} = \begin{pmatrix} |A| & 0 & \cdots & 0 \\ 0 & |A| & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & |A| \end{pmatrix}$$

$$= |A|I$$

如果有 $|A| \neq 0$ ，则有

$$A \frac{1}{|A|} A^* = I$$

因此

$$A^{-1} = \frac{1}{|A|} A^*$$

这也证明了矩阵 A 可逆的充分必要条件是 $|A| \neq 0$



• 行列式的基本概念

■ 行列式的性质

➢ 如果把行列式的某一行元素都乘以 k ,则行列式变为之前的 k 倍,即

$$\begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ ka_{i1} & \cdots & ka_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix} = k \begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix}$$

➢ 如果一个行列式的两个行成比例关系,则其值为0。

$$\begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ ka_{i1} & \cdots & ka_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix} = k \begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix} = 0$$



• 行列式的基本概念

■ 行列式的性质

► 如果行列式的一个行加上另一个行的 k 倍，行列式的值不变，因为

$$\begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i1} + ka_{j1} & \cdots & a_{in} + ka_{jn} \\ \vdots & & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ a_{n1} & a_{n2} & a_{nn} \end{vmatrix} = \begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ a_{j1} & \cdots & a_{jn} \\ \vdots & & \vdots \\ a_{n1} & a_{n2} & a_{nn} \end{vmatrix} + k \begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix}$$

$$= \begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & & \vdots \\ a_{j1} & \cdots & a_{jn} \\ \vdots & & \vdots \\ a_{n1} & a_{n2} & a_{nn} \end{vmatrix}$$



• 行列式的基本概念

■ 行列式的性质

► 如果行列式的一个行加上另一个行的 k 倍，行列式的值不变

• 例如，下面两个行列式的值相等

$$\begin{vmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 4 & 5 & 6 \end{vmatrix} = \begin{vmatrix} 1+1 & 1+2 & 1+3 \\ 1 & 2 & 3 \\ 4 & 5 & 6 \end{vmatrix}$$

可以通过这种变换将矩阵化为三角阵，然后计算其行列式的值

► 如果行列式的一个行加上另一个行的 k 倍，行列式的值不变

$$\begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1n} & 0 & \cdots & 0 \\ a_{21} & a_{22} & \cdots & a_{2n} & \cdots & \cdots & \cdots \\ \vdots & \vdots & & \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} & 0 & \cdots & 0 \\ c_{11} & c_{12} & \cdots & c_{1n} & b_{11} & b_{12} & \cdots & b_{1m} \\ c_{21} & c_{22} & \cdots & c_{2n} & b_{21} & b_{22} & \cdots & b_{2m} \\ \vdots & \vdots & & \vdots & \vdots & & & \vdots \\ c_{m1} & c_{m2} & \cdots & c_{mn} & b_{m1} & b_{m2} & \cdots & b_{mm} \end{vmatrix} = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{vmatrix} \begin{vmatrix} b_{11} & b_{12} & \cdots & b_{1m} \\ b_{21} & b_{22} & \cdots & b_{2m} \\ \vdots & \vdots & & \vdots \\ b_{m1} & b_{m2} & \cdots & b_{mm} \end{vmatrix}$$

可根据拉普拉斯展开可以证明上面的结论成立



• 行列式的基本概念

■ 行列式的性质

- 如果矩阵 A 和 B 是尺寸相同的阶方阵，则有 $|AB| = |A||B|$ ，即矩阵乘积的行列式等于矩阵行列式的乘积
- 如果矩阵可逆，则其行列式不为0，且其矩阵的行列式等于行列式的逆，即

$$|A^{-1}| = |A|^{-1}$$

- 矩阵与标量惩罚的行列式为

$$|\alpha A| = \alpha^n |A|$$

- 矩阵转置之后行列式不变

$$|A| = |A^T|$$



- 正交矩阵的行列式为 ± 1 ，即如果 A 是正交矩阵，则有

$$|AA^T| = |A||A^T| = |A||A| = |I| = 1$$

因此 $|A| = \pm 1$

2-4

线性方程组





• 高斯消元法

■ 高斯消元法 (Gaussian Elimination Method) 的定义

即加减消元法，通过将一个方程减掉另一个方程的倍数消掉未知数，得到阶梯型方程组，然后依次解出每一个未知数

➤ 例如，对于如下的线性方程组

$$\begin{cases} 2x_1 + x_2 + x_3 = 1 \\ 6x_1 + 2x_2 + x_3 = -1 \\ -2x_1 + 2x_2 + x_3 = 7 \end{cases}$$

先消去方程2和方程3的第一个未知数。将方程2减去方程1的3倍，将方程3加上方程1，消掉方程2和方程3中的 x_1 ，得

$$\begin{cases} 2x_1 + x_2 + x_3 = 1 \\ -x_2 - 2x_3 = -4 \\ 3x_2 + 2x_3 = 8 \end{cases}$$

然后将方程3加上方程2的3倍，消掉方程3中的 x_2 ，得



• 高斯消元法

接上

$$\begin{cases} 2x_1 + x_2 + x_3 = 1 \\ -x_2 - 2x_3 = -4 \\ -4x_3 = -4 \end{cases}$$

- 根据上述方程组第3个方程可以解得 $x_3 = 1$
- 将 x_3 的值代入上述方程组第2个方程可以解得 $x_2 = 2$
- 再将 x_2 和 x_3 代入上述方程组第1个方程，可以解得 $x_1 = -1$
- 下面用矩阵的形式描述这一求解过程，如下所示

$$\begin{pmatrix} 2 & 1 & 1 & 1 \\ 6 & 2 & 1 & -1 \\ -2 & 2 & 1 & 7 \end{pmatrix} \xrightarrow{r_2 - 3 \times r_1, r_3 + r_1} \begin{pmatrix} 2 & 1 & 1 & 1 \\ 0 & -1 & -2 & -4 \\ 0 & 3 & 2 & 8 \end{pmatrix}$$
$$\xrightarrow{r_3 + 3 \times r_2} \begin{pmatrix} 2 & 1 & 1 & 1 \\ 0 & -1 & -2 & -4 \\ 0 & 0 & -4 & -4 \end{pmatrix}$$



• 高斯消元法

■ 高斯消元法的推广

对于任意的线性方程组，采用如下的初等行变换对其进行变形，方程组的解不变

- 交换两个方程的位置
- 用非0的常数乘以某方程的两端
- 将一个方程的常熟倍加到另一个方程上去。

采用这种初等变换，每次小调一个未知数，最后得到一个阶梯形方程组，即可求出方程的解

• 齐次方程组

■ 齐次方程组 (Homogeneous Linear Equations) 的定义

齐次方程组是常数项全部为0的线性方程组；对于任意的线性方程组，采用如下的初等行变换对其进行变形，可以写成如下形式



• 齐次方程组

- 齐次方程组 (Homogeneous Linear Equations) 的定义

$$Ax = 0$$

其中 $A \in R^{m \times n}$, $x \in R^n$; 将系数矩阵 A 按列分块为 $(a_1, \dots, a_n)$, 齐次方程可以写成

$$x_1 a_1 + \dots + x_n a_n = 0$$

- 以解向量 $x = (x_1 \dots x_n)^T$ 为组合系数, 向量组 $a_1, \dots, a_n$ 的线性组合为 0
- 显然 $x = 0$ 是方程组的解, 因此齐次方程一定有解
- 除 $x = 0$ 之外的解, 称为非 0 解

- 齐次方程组解的存在性

根据线性相关性的定义, 如果向量组 $a_1, \dots, a_n$ 线性无关, 则不存在一组不全为 0 的系数 x 使得其线性组合为 0; 如果向量组 $a_1, \dots, a_n$ 线性相关, 则存在一组不全为 0 的系数 x 使得其线性组合为 0, 即是方程组的非 0 解



• 齐次方程组

■ 齐次方程组解的存在性

前者对应于矩阵 A 的秩为 n , 后者秩小于 n

➤ 由此得到齐次方程组解的存在性判定条件, 分下面两种情况

- 如果 $r(A) = n$, 方程组只有0解
- 如果 $r(A) < n$, 方程组有非0解

➤ 方程组有非0解的充分必要条件是 $r(A) < n$

- 如果 A 是方阵

$$r(A) < n$$

- 等同于 A 不可逆
- 如果 $m < n$, 即方程的数量小于未知数的数量, 则有

$$r(A) \leq \min(m, n) \leq m < n$$

此时方程组必定有非0解



• 齐次方程组

■ 齐次方程组解的存在性

➤ 例如，对于线性方程组

$$\begin{cases} x_1 - x_2 + x_3 = 0 \\ -x_1 + x_2 + x_3 = 0 \\ x_1 + x_2 - x_3 = 0 \end{cases}$$

其系数矩阵的秩为

$$\text{rank} \left(\begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & 1 \\ 1 & 1 & -1 \end{bmatrix} \right) = 3$$

因此方程组有非0解

■ 解的性质与结构

➤ 如果 $x_1, \dots, x_l$ 都是方程组的解，他们的任意线性组合 $\sum_{i=1}^l k_i x_i$ 也是线性方程组的解



• 齐次方程组

■ 解的性质与结构

- 假设 $x_1, \dots, x_l$ 都是方程组的解，若这组解线性无关且方程组的任一解都可以由这组解线性表示，则称 $x_1, \dots, x_l$ 是方程组的一个基础解系
- 如果 $r(A) < n$ ，则存在基础解系，且基础解系中包含 $n - r(A)$ 个解

• 齐次线性方程组的解法

通常采用的是初等行变换法，对应高斯消元法；经过初等行变换将系数矩阵化为阶梯形矩阵之后，如果出现自由未知数，可以将它们设为特殊值，形成基础解系，然后得到方程组的通解

- 如果 $x_{r+1}, \dots, x_n$ 是自由未知数，通常将它们的值依次设为

$$(1 \ 0 \ \cdots \ 0) \quad (0 \ 1 \ \cdots \ 0) \quad \cdots \quad (0 \ 0 \ \cdots \ 1)$$

这是 R^{n-r} 空间一组最简单的标准正交基。然后根据它们的值解出其他的未知数



• 齐次线性方程组的解法

➤ 例如，对于方程组

$$\begin{cases} x_1 + 2x_2 + 2x_3 + x_4 = 0 \\ 2x_1 + x_2 - 2x_3 - 2x_4 = 0 \\ x_1 - x_2 - 4x_3 - 3x_4 = 0 \end{cases}$$

对其系数矩阵进行初等行变换

$$\begin{aligned} A = \begin{pmatrix} 1 & 2 & 2 & 1 \\ 2 & 1 & -2 & -2 \\ 1 & -1 & -4 & -3 \end{pmatrix} &\xrightarrow{r_2-2r_1, r_3-r_1} \begin{pmatrix} 1 & 2 & 2 & 1 \\ 0 & -3 & -6 & -4 \\ 0 & -3 & -6 & -4 \end{pmatrix} \\ &\xrightarrow{r_3-r_2, r_2 \times (-1/3)} \begin{pmatrix} 1 & 2 & 2 & 1 \\ 0 & 1 & 2 & 4/3 \\ 0 & 0 & 0 & 0 \end{pmatrix} \xrightarrow{r_1-2 \times r_2} \begin{pmatrix} 1 & 0 & -2 & -5/3 \\ 0 & 1 & 2 & 4/3 \\ 0 & 0 & 0 & 0 \end{pmatrix} \end{aligned}$$

由于 $r(A) = 2 < 4$ ，因此方程组有非0解，最后两个未知数为自由变量。令 $x_3 = 1$ ， $x_4 = 0$ ，得到基础解系的第一个解

$$x_1 = (2 \quad -2 \quad 1 \quad 0)^T$$



• 齐次线性方程组的解法

- 接上，令 $x_3 = 0$, $x_4 = 1$ ，得到基础解系的第二个解

$$x_2 = (5/3 \quad -4/3 \quad 0 \quad 1)^T$$

方程组的通解为

$$x = k_1 x_1 + k_2 x_2$$

其中 k_1, k_2 为任意常数

• 非齐次线性方程组

- 非齐次方程组 (Non-Homogeneous Linear Equations) 的定义

$$Ax = b$$

- 方程组的增广矩阵是系数矩阵和常数向量合并构成的矩阵

$$B = (A \quad b)$$

- 例如，对于线性方程组
$$\begin{cases} 2x_1 - 3x_2 + x_3 = 1 \\ 4x_1 - 2x_2 + x_3 = 2 \\ 3x_1 + 3x_2 + x_3 = 0 \end{cases}$$



• 非齐次线性方程组

- 非齐次方程组 (Non-Homogeneous Linear Equations) 的定义
接上, 其系数矩阵为

$$\begin{pmatrix} 2 & -3 & 1 \\ 4 & -2 & 1 \\ 3 & 3 & 1 \end{pmatrix}$$

增广矩阵为

$$\begin{pmatrix} 2 & -3 & 1 & 1 \\ 4 & -2 & 1 & 2 \\ 3 & 3 & 1 & 0 \end{pmatrix}$$

- 假设 $A \in R^{m \times n}$, $x \in R^n$, 系数矩阵按列分块为 $(a_1 \cdots a_n)$, 非齐次方程可以写成

$$x_1 a_1 + \cdots + x_n a_n = b$$

即以 x 为组合系数, 向量组 $a_1, \cdots, a_n$ 的线性组合为向量 b

- 如果 b 可以由 A 的列向量线性表示, 则方程组有解, 否则方程组无解



• 非齐次线性方程组

■ 非齐次方程组 (Non-Homogeneous Linear Equations) 的定义

➢ 用初等行变换将增广矩阵化为阶梯矩阵

$$\begin{pmatrix} 1 & \cdots & c_{1r} & c_{1,r+1} & \cdots & c_{1n} & d_1 \\ \vdots & & \vdots & \vdots & & \vdots & \vdots \\ 0 & \cdots & 1 & c_{r,r+1} & \cdots & c_{rn} & d_r \\ 0 & \cdots & 0 & 0 & \cdots & 0 & d_{r+1} \\ 0 & \cdots & 0 & 0 & \cdots & 0 & 0 \\ \vdots & & \vdots & \vdots & & \vdots & \vdots \\ 0 & \cdots & 0 & 0 & \cdots & 0 & 0 \end{pmatrix}$$

- 如果 $d_{r+1} \neq 0$ ，则意味着出现矛盾方程，方程无解；因此，系数矩阵的秩小于增广矩阵的秩，且

$$r(B) = r(A) + 1$$

- 若 $d_{r+1} = 0$ ，则方程组有解，即增广矩阵的秩与系数矩阵的秩相等



• 非齐次线性方程组

■ 非齐次方程组 (Non-Homogeneous Linear Equations) 的定义

➢ 非齐次方程组解的存在性判定条件

- 如果 $r(A) = r(B)$, 那么方程组的解存在; 特别的, 如果 $r(A) = n$, 那么方程组有唯一解; 如果 $r(A) < n$, 那么方程组有无穷多组解
- 如果 $r(A) < r(B)$, 那么方程组的解不存在

■ 非齐次方程组解的性质与结构

- 如果 $x_1, \dots, x_l$ 是非齐次方程组所对应的齐次方程的一组解, x^* 是非齐次方程的一个解, 则 $\sum_{i=1}^l k_i x_i + x^*$ 是非齐次方程的解
- 因为

$$A \left(\sum_{i=1}^l k_i x_i + x^* \right) = \sum_{i=1}^l k_i A x_i + A x^* = \sum_{i=1}^l k_i 0 + b = b$$



• 非齐次线性方程组

■ 非齐次方程组解的性质与结构

- 如果 $x_1, \dots, x_l$ 是齐次方程组的基础解系， x^* 是非齐次方程组的一个解，则非齐次方程组的解可以表示为 $\sum_{i=1}^l k_i x_i + x^*$

■ 非齐次方程组的解法

可以用初等行变换求解非齐次方程组，其解为对应的齐次方程组的通解加上它的一个特解，非齐次方程组的特解可以任意选取，通常令自由未知数的值全为0

例如，初等行变换解下面的非齐次线性方程组

$$\begin{cases} x_1 + 5x_2 - x_3 - x_4 = -1 \\ x_1 - 2x_2 + x_3 + 3x_4 = 3 \\ 3x_1 + 8x_2 - x_3 + x_4 = 1 \\ x_1 - 9x_2 + 3x_3 + 7x_4 = 7 \end{cases}$$

对其增广矩阵进行初等行变换



- 非齐次线性方程组

- 非齐次方程组的解法

接上

$$\begin{pmatrix} 1 & 5 & -1 & -1 & -1 \\ 1 & -2 & 1 & 3 & 3 \\ 3 & 8 & -1 & 1 & 1 \\ 1 & -9 & 3 & 7 & 7 \end{pmatrix} \longrightarrow \begin{pmatrix} 1 & 5 & -1 & -1 & -1 \\ 0 & -7 & 2 & 4 & 4 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix} \longrightarrow$$
$$\longrightarrow \begin{pmatrix} 1 & 5 & -1 & -1 & -1 \\ 0 & 1 & -2/7 & -4/7 & -4/7 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

易可知 x_3, x_4 是自由未知数



• 非齐次线性方程组

■ 非齐次方程组的解法

接上，令 $x_3 = x_4 = 0$ ，得到一个特解

$$x^* = \begin{pmatrix} 13/7 \\ -4/7 \\ 0 \\ 0 \end{pmatrix}$$

齐次方程组的基础解系为

$$x_1 = \begin{pmatrix} -3/7 \\ 2/7 \\ 1 \\ 0 \end{pmatrix}, x_2 = \begin{pmatrix} -13/7 \\ 4/7 \\ 0 \\ 0 \end{pmatrix}$$



因此方程的解为

$$x = x^* + k_1 x_1 + k_2 x_2$$

其中 k_1, k_2 为任意常数

2-5

二次型与正定二次型





• 正定矩阵与正半定矩阵

- 正定 (Positive Definite) 和 负定 (Negative Definite) 矩阵的定义

给定 $n \times n$ 的实对称矩阵 A ，若对于任意长度为 n 的非零向量 x ，不等式

$$x^T A x > (<) 0$$

恒成立，则矩阵 A 是一个正定（负定）矩阵

➤ 单位矩阵 I_n 是正定矩阵

➤ 实对称矩阵

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix} \quad \longrightarrow \quad \lambda_1 = 0.5858, \lambda_2 = 2, \lambda_3 = 3.4142$$

取向量 $x = [x_1, x_2, x_3]^T \in \mathbb{R}^3$ 为非零向量，则

$$x^T A x = x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2 > 0$$

因此，矩阵 A 是正定矩阵



• 正定矩阵与正半定矩阵

■ 正定矩阵与负定的性质

- 正定矩阵的特征值均为正，负定矩阵的特征值均为负
- 正定矩阵的行列式恒为正
- 两个正定矩阵的和是正定矩阵，两个负定矩阵的和是负定矩阵
- 正实数与正定矩阵的乘积是正定矩阵
- 正定矩阵的所有顺序主子式均为正，正定矩阵的所有主子式均为正
- 判别对称矩阵 A 的正定性有三种方法（除定义法外）
 - 求出 A 的所有特征值：若 A 的特征值均为正数，则 A 是正定的；若 A 的特征值均为负数，则 A 为负定的
 - 计算 A 的各阶顺序主子式：若 A 的各阶顺序主子式均大于零，则 A 是正定的；若 A 的各阶顺序主子式中，奇数阶主子式为负，偶数阶为正，则 A 为负定的

$$\prod_i \lambda_i(A) = \det(A)$$



• 正定矩阵与正半定矩阵

■ 正定矩阵与负定的性质

➤ 范例：给定矩阵

$$A = \begin{bmatrix} 6 & -3 & 1 \\ -3 & 2 & 0 \\ 1 & 0 & 4 \end{bmatrix}$$

对称矩阵 A 的三个顺序主子式依次为：

$$|6| = 6 > 0$$

$$\begin{vmatrix} 6 & -3 \\ -3 & 2 \end{vmatrix} = 3 > 0$$

$$\begin{vmatrix} 6 & -3 & 1 \\ -3 & 2 & 0 \\ 1 & 0 & 4 \end{vmatrix} = 10 > 0$$

因此，矩阵 A 是正定矩阵



矩阵的正负定性

• 正定矩阵与正半定矩阵

■ 正定矩阵与负定的性质

➤ 范例：给定矩阵

$$\lambda_1 = -1, \lambda_2 = -5 + 2\sqrt{6}, \lambda_3 = -5 - 2\sqrt{6}$$

$$A = \begin{bmatrix} -5 & -2 & 4 \\ -2 & -1 & 2 \\ 4 & 2 & -5 \end{bmatrix}$$

对称矩阵 A 的三个顺序主子式依次为：

$$|-5| = -5 < 0$$

$$\begin{vmatrix} -5 & -2 \\ -2 & -1 \end{vmatrix} = 1 > 0$$

$$\begin{vmatrix} -5 & -2 & 4 \\ -2 & -1 & 2 \\ 4 & 2 & -5 \end{vmatrix} = -1 < 0$$

因此，矩阵 A 是负定矩阵



• 正定矩阵与正半定矩阵

- 半正定(Positive Semi-Definite)和半负定(Negative Semi-Definite)的定义

给定 $n \times n$ 的实对称矩阵 A ，若对于任意长度为 n 的向量 x ，不等式

$$x^T A x \geq (\leq) 0$$

恒成立，则矩阵 A 是一个半正定（半负定）矩阵

► 实对称矩阵

$$A = \begin{bmatrix} 2 & 6 & 0 \\ 6 & 18 & 0 \\ 0 & 0 & 10 \end{bmatrix}$$



$$\lambda_1 = 0, \lambda_2 = 10, \lambda_3 = 20$$

因此，矩阵 A 是半正定矩阵；也可以取向量 $x = [x_1, x_2, x_3]^T \in \mathbb{R}^3$ 为非零向量，

$$x^T A x = 2(x_1 + 3x_2)^2 + 10x_3^2 \geq 0$$



• 正定矩阵与正半定矩阵

■ 半正定矩阵与半负定矩阵的性质

- 半正定矩阵的行列式是非负的
- 两个半正定矩阵的和是半正定的
- 非负实数与半正定矩阵的数乘矩阵是半正定的
- 半正定矩阵所有主子式均为非负的
- 半正定矩阵特征值均为非负的，半负定矩阵特征值均为非正的
- 存在 n 阶实矩阵 C ，使得半正定矩阵 $A = C^T C$

■ 不定矩阵 (Indefinite Matrix)

若一个实对称矩阵既非半正定也非半负定的，那么称其为不定矩阵

➢ 例如

$$A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 0 \end{bmatrix} \quad \longrightarrow \quad \lambda_1 = -0.7321, \lambda_2 = 2.7321, \lambda_3 = 0$$



• 二次型的基本概念

■ 二次型 (Quadratic Form) 的定义

由纯二次项构成的函数，即 n 个变量上的二次齐次多项式，包括

$$a_{11}x_1^2$$

$$a_{11}x_1^2 + a_{22}x_2^2 + a_{12}x_1x_2$$

$$a_{11}x_1^2 + a_{22}x_2^2 + a_{33}x_3^2 + a_{12}x_1x_2 + a_{13}x_1x_3 + a_{23}x_2x_3$$

此外，二次型可以写成矩阵形式

$$\mathbf{x}^T \mathbf{A} \mathbf{x}$$

其中 $\mathbf{A}$ 是 n 阶对称矩阵， $\mathbf{x}$ 是一个列向量，因此二次型展开为

$$\sum_{i=1}^n \sum_{j=1}^n a_{ij}x_i x_j$$

这里一般要求 $a_{ij} = a_{ji}$

$$a_{11}x_1^2 + a_{22}x_2^2 + a_{33}x_3^2 + a_{12}x_1x_2 + a_{13}x_1x_3 + a_{23}x_2x_3$$



• 二次型的基本概念

■ 二次型 (Quadratic Form) 的定义

➢ 例如，二次型多项式

$$2x_1^2 - 3x_1x_2 + x_2^2 + x_3^2$$

对应的矩阵为

$$\begin{bmatrix} 2 & -1.5 & 0 \\ -1.5 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

平方项 $a_{ii}x_i^2$ 的系数是矩阵的主对角线元素，交叉乘积项 $a_{ij}x_ix_j$ 的系数由 a_{ij} 与 a_{ji} 均分，实对称矩阵与二次型一一对应

➢ 例如，二次型函数

$$\begin{aligned} &x_1^2 - 2x_1x_2 + 3x_1x_3 - 2x_2^2 + 8x_2x_3 + 3x_3^2 \\ &x_1x_2 - x_1x_3 + 2x_2x_3 + x_4^2 \end{aligned}$$



• 正定二次型的基本概念

■ 正定 (Positive Definite) 二次型的定义

如果一个二次型对于任意非 **0** 向量 $\mathbf{x}$ 都有

$$\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$$

则称该二次型为正定二次型，矩阵 $\mathbf{A}$ 为正定矩阵

- 例如，二次型函数 $f(x_1, x_2, x_3) = x_1^2 + 2x_2^2 + x_3^2$ 为正定二次型，对应的矩阵为正定矩阵

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

■ 半正定 (Semi-Positive Definite) 二次型的定义

对于任意非 **0** 向量 $\mathbf{x}$ 都有

$$\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0$$

则该二次型为半正定二次型，矩阵 $\mathbf{A}$ 为半正定矩阵



• 正定二次型的基本概念

■ 半正定 (Semi-Positive Definite) 二次型的定义

- 例如，二次型函数 $f(x_1, x_2, x_3) = x_1^2 + 2x_2^2$ 为半正定二次型，对应的矩阵为半正定矩阵

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

如果令 $x_1 = 0, x_2 = 0, x_3 = 1$ ，二次型的值为0

■ 负定 (Negative Definite) 二次型的定义

对于任意非 **0** 向量 $\mathbf{x}$ 都有

$$\mathbf{x}^T \mathbf{A} \mathbf{x} < 0$$

则该二次型为负定二次型，矩阵 $\mathbf{A}$ 为负定矩阵

- 类似的可以定义半负定的概念
- 如果既不正定也不负定，则称为不定



• 正定二次型的基本概念

■ 负定 (Negative Definite) 二次型的定义

- 例如，二次型函数 $f(x_1, x_2, x_3) = -x_1^2 - 2x_2^2 - x_3^2$ 为负定二次型，对应的矩阵为负定矩阵

$$\begin{bmatrix} -1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & -1 \end{bmatrix}$$

■ 正定二次型的性质

- 正定矩阵的所有主对角线元素 $a_{ii} > 0, i = 1, \dots, n$

∵ 由于对于任意非 **0** 向量 $\mathbf{x}$ 都有 $\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$ ，因此可以构造一个第 i 个分量为1，其他分量均为0的向量

则有 $\mathbf{x}^T \mathbf{A} \mathbf{x} = a_{ii} > 0$



• 正定二次型的基本概念

■ 对称正定矩阵的证明方法

➤ 定义法

➤ 矩阵 A 的 n 个特征值 $\lambda_1, \dots, \lambda_n$ 均大于0

➤ 存在可逆矩阵 P 使得 $A = P^T P$

$\because$ 由于 P 可逆, 对于任意非 0 向量 x 有 $Px \neq 0$, 因此对于任意非 0 向量 x 都有 $x^T A x = x^T P^T P x = (Px)^T P x > 0$

➤ 矩阵 A 的所有顺序主子式均为正, 即对于 n 阶矩阵 A , 前 k ($1 \leq k \leq n$) 行前 k 列元素形成的行列式

$$\det[A]_{k \times k} = \begin{vmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \cdots & a_{kk} \end{vmatrix}$$

称为顺序主子式, 这是矩阵左上角的子方阵形成的行列式



• 正定二次型的基本概念

■ 对称负定矩阵的证明方法

- 矩阵 A 的 n 个特征值 $\lambda_1, \dots, \lambda_n$ 均小于0
- 存在可逆矩阵 P 使得

$$A = -P^T P$$

- 矩阵 A 的所有奇数阶顺序主子式均为负，偶数阶顺序主子式均为正
- 例题：对于下面的4阶矩阵

$$A = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{bmatrix}$$

- 其1阶顺序主子式为

$$|1| > 0$$



• 正定二次型的基本概念

■ 对称正定矩阵的证明方法

- 2阶顺序主子式为

$$\begin{vmatrix} 1 & 2 \\ 5 & 6 \end{vmatrix} < 0$$

- 3阶顺序主子式为

$$\begin{vmatrix} 1 & 2 & 3 \\ 5 & 6 & 7 \\ 9 & 10 & 11 \end{vmatrix} = 0$$

- 4阶顺序主子式为

$$\det(\mathbf{A}) = 0$$

矩阵 $\mathbf{A}$ 既非正定的，也非负定

- 矩阵 $\mathbf{A}$ 特征值为 36.2094, -2.2094, 0



• 标准二次型的基本概念

■ 标准二次型的定义

对于任意的 $i \neq j$, 二次型中项 $a_{ij}x_i x_j$ 的系数均为 0, 二次型由纯平方项构成, 可写成如下矩阵形式

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = d_1 x_1^2 + d_2 x_2^2 + \cdots + d_n x_n^2$$

正平方项的数量称为**正惯性指数**, 负平方项的数量称为**负惯性指数**

➤ 例如, 下列标准型

$$x_1^2 - 3x_2^2 + x_3^2$$

对应的矩阵为对角矩阵

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -3 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

其正惯性指数为 2, 负惯性指数为 1



• 标准二次型的基本概念

■ 标准二次型的正交转化

通过**正交相似变换** P 可以将二次型 $\mathbf{x}^T \mathbf{A} \mathbf{x}$ 化为标准型，类似于实对称矩阵的正交对角化相似变换；即对于二次型 $\mathbf{x}^T \mathbf{A} \mathbf{x}$ ，通过正交变换 P 将 A 化为对角矩阵

$$\mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^T$$

因此

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = \mathbf{x}^T \mathbf{P} \mathbf{\Lambda} \mathbf{P}^T \mathbf{x} = (\mathbf{P}^T \mathbf{x})^T \mathbf{\Lambda} (\mathbf{P}^T \mathbf{x})$$

- 如果令 $\mathbf{y} = \mathbf{P}^T \mathbf{x}$ 或者 $\mathbf{x} = \mathbf{P} \mathbf{y}$ ，则 $\mathbf{y}^T \mathbf{\Lambda} \mathbf{y}$ 是标准型，也就是说可通过将 $\mathbf{x}$ 换元为 $\mathbf{y}$ ，使得换元之后的二次型为标准型
- 对于任意非 $\mathbf{0}$ 向量 $\mathbf{x}$ ，由于 P 是正交矩阵

$$\mathbf{y} = \mathbf{P}^T \mathbf{x} \neq \mathbf{0}$$

因此，如果矩阵 A 的 n 个特征值 $\lambda_1, \dots, \lambda_n$ 均大于0，则矩阵 $\mathbf{\Lambda}$ 正定



- 标准二次型的基本概念

- 标准二次型的正交转化

- 例如，对应二次型 $x_1^2 + 5x_2^2 + 5x_3^2 + 2x_1x_2 - 4x_1x_3$ 的系数矩阵为



• 标准二次型的基本概念

■ 标准二次型的正交转化

➢ 例如，对应二次型 $x_1^2 + 5x_2^2 + 5x_3^2 + 2x_1x_2 - 4x_1x_3$ 的系数矩阵为

$$A = \begin{bmatrix} 1 & 1 & -2 \\ 1 & 5 & 0 \\ -2 & 0 & 5 \end{bmatrix}$$

其特征多项式为

$$\begin{aligned} \det(A - \lambda I) &= \begin{vmatrix} 1-\lambda & 1 & -2 \\ 1 & 5-\lambda & 0 \\ -2 & 0 & 5-\lambda \end{vmatrix} \xrightarrow{r_3+2r_2} \begin{vmatrix} 1-\lambda & 1 & -2 \\ 1 & 5-\lambda & 0 \\ 0 & 2(5-\lambda) & 5-\lambda \end{vmatrix} \\ &\xrightarrow{c_2-2\times c_3} \begin{vmatrix} 1-\lambda & 5 & -2 \\ 1 & 5-\lambda & 0 \\ 0 & 0 & 5-\lambda \end{vmatrix} = \lambda(5-\lambda)(\lambda-6) \end{aligned}$$

因此，特征值为 0, 5, 6



• 标准二次型的基本概念

■ 标准二次型的正交转化

➢ 例如，对于二次型 $x_1^2 + 5x_2^2 + 5x_3^2 + 2x_1x_2 - 4x_1x_3$

• 当 $\lambda=5$ 时，有

$$A - 5I = \begin{bmatrix} -4 & 1 & -2 \\ 1 & 0 & 0 \\ -2 & 0 & 0 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & -2 \\ 0 & 0 & 0 \end{bmatrix}$$

方程 $(A - 5I)x = 0$ 的解为 $x_1 = [0 \ 2 \ 1]^T$

• 当 $\lambda=6$ 时，有

$$A - 6I = \begin{bmatrix} -5 & 1 & -2 \\ 1 & -1 & 0 \\ -2 & 0 & -1 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 0 & 1/2 \\ 0 & 1 & 1/2 \\ 0 & 0 & 0 \end{bmatrix}$$

方程 $(A - 6I)x = 0$ 的解为 $x_2 = [1 \ 1 \ -2]^T$



• 标准二次型的基本概念

■ 标准二次型的正交转化

➢ 例如，对于二次型 $x_1^2 + 5x_2^2 + 5x_3^2 + 2x_1x_2 - 4x_1x_3$

• 当 $\lambda=0$ 时，有

$$A - 5I = \begin{bmatrix} 1 & 1 & -2 \\ 1 & 5 & 0 \\ -2 & 0 & 5 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 0 & -5/2 \\ 0 & 1 & 1/2 \\ 0 & 0 & 0 \end{bmatrix}$$

方程 $(A - 0I)x = 0$ 的解为 $x_3 = [5 \quad -1 \quad 2]^T$

由于二次型的系数矩阵是实对称矩阵，其不同特征值对应的特征向量相互正交，因此只需要将这些特征向量单位化即可

$$\alpha_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 0 \\ 2 \\ 1 \end{bmatrix}, \quad \alpha_2 = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}, \quad \alpha_3 = \frac{1}{\sqrt{30}} \begin{bmatrix} 5 \\ -1 \\ 2 \end{bmatrix}$$



• 标准二次型的基本概念

■ 标准二次型的正交转化

- 例如，对于二次型 $x_1^2 + 5x_2^2 + 5x_3^2 + 2x_1x_2 - 4x_1x_3$
接上，令



$$P = \begin{bmatrix} 0 & \frac{1}{\sqrt{6}} & \frac{5}{\sqrt{30}} \\ \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{30}} \\ \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{6}} & \frac{2}{\sqrt{30}} \end{bmatrix}$$

通过正交变换 $\mathbf{x} = \mathbf{P}\mathbf{y}$ 可将二次型化为如下的标准型

$$5y_1^2 + 6y_2^2$$

2-6

矩阵分解





• 矩阵分解 (Matrix Decomposition)

矩阵分解是矩阵分析的重要内容，是将一个矩阵分解为若干（通常为2个或3个）矩阵的乘积的过程；在求解线性方程组、计算逆矩阵、行列式以及特征值、多重积分换元等问题上，矩阵分解有着广泛的应用

- 在数值分析，矩阵分解常用来实现一些矩阵运算（降维）的快速算法
- 线性方程组法求解

$$Ax = b$$

- LU分解
- 奇异值分解
- QR分解
- 人工智能
 - 主成分分析
 - 极分解
 - 特征分解



• 特征值分解 (Eigenvalue Decomposition) 的定义

也称谱分解，对于 $n \times n$ 阶矩阵 A ，如果它有 n 个线性无关的特征向量（可对角化），则可以将其分解为如下 3 个矩阵的乘积

$$A = P \Lambda P^{-1}$$

其中 Λ 为对角矩阵，对角线元素为矩阵 A 的特征值

$$\Lambda = \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_n \end{bmatrix}$$

P 为 n 阶矩阵，它的列为 A 的特征向量，与对角矩阵中特征值的排列顺序一致

$$P = [p_1 \quad \cdots \quad p_n]$$

- n 阶矩阵可进行特征值分解的充分必要条件是它有 n 个线性无关的特征向量；通常情况下，这些特征向量 p_i 都是单位化的



特征值分解

- **特征值分解 (Eigenvalue Decomposition) 的定义**

‣ 例如，对于如下矩阵

$$A = \begin{bmatrix} 4 & 1 & 1 \\ 1 & 2 & 1 \\ 3 & 2 & 3 \end{bmatrix}$$



• 特征值分解 (Eigenvalue Decomposition) 的定义

➤ 例如，对于如下矩阵

$$A = \begin{bmatrix} 4 & 1 & 1 \\ 1 & 2 & 1 \\ 3 & 2 & 3 \end{bmatrix}$$

首先，可解得特征值为 $\lambda = 6, 2, 1$ ，且其对应的特征向量为

$$\mathbf{p}_1 = [5 \quad 3 \quad 7], \mathbf{p}_2 = [1 \quad -1 \quad 1], \mathbf{p}_3 = [0 \quad 1 \quad -1]$$

因此，矩阵

$$P = \begin{bmatrix} \frac{\mathbf{p}_1}{\|\mathbf{p}_1\|} & \frac{\mathbf{p}_2}{\|\mathbf{p}_2\|} & \frac{\mathbf{p}_3}{\|\mathbf{p}_3\|} \end{bmatrix} = \begin{bmatrix} 5/\sqrt{83} & 1/\sqrt{3} & 0 \\ 3/\sqrt{83} & -1/\sqrt{3} & 1/\sqrt{2} \\ 7/\sqrt{83} & 1/\sqrt{3} & -1/\sqrt{2} \end{bmatrix}$$

然后将该矩阵的列单位化，可以得到

$$\Lambda = P^{-1}AP = \begin{bmatrix} 6 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$



• 特征值分解的应用

- 特征值分解可以用于计算逆矩阵

如果矩阵 A 可以进行特征值分解，且其所有的特征值都非0，则

$$A = P\Lambda P^{-1}$$

其逆矩阵为

$$A^{-1} = (P\Lambda P^{-1})^{-1} = P\Lambda^{-1}P^{-1}$$

对角矩阵的逆矩阵容易计算，是主对角线所有元素的倒数

- 特征值分解还可以用于计算矩阵的多项式或者幂

对于如下多项式

$$f(x) = a_n x^n + a_{n-1} x^{n-1} + \cdots + a_1 x$$

如果矩阵 A 可以进行特征值分解，且 $A = P\Lambda P^{-1}$ ，则有

$$\begin{aligned} f(A) &= f(P\Lambda P^{-1}) = a_1 P\Lambda P^{-1} + a_2 P\Lambda P^{-1} P\Lambda P^{-1} + \cdots \\ &= P(a_1 \Lambda + a_2 \Lambda^2 + \cdots a_n \Lambda^n)P^{-1} = P f(\Lambda) P^{-1} \end{aligned}$$



• 特征值分解的应用

- 特征值分解还可以用于计算矩阵的多项式或者幂

对角矩阵的幂仍然是对角矩阵，是主对角线的元素分别求幂，因此有

$$f(\Lambda)_{ii} = f(\Lambda_{ii})$$

因此，借助于特征值分解，可以高效地计算出 $f(A)$ ，其中

$$A^n = P\Lambda^n P^{-1}$$

- 特别地，如果 A 是实对称矩阵，可对其特征向量进行正交化，从而特征值分解为

$$A = P\Lambda P^T$$

其中 P 是正交矩阵，它的列是 A 的正交化特征向量， Λ 同样为 A 的所有特征值构成的对角矩阵

* 实对称矩阵一定可以正交相似对角化，施密特-格拉姆正交化



• 奇异值分解 (Singular Value Decomposition, SVD) 的定义

假设任意矩阵 $A \in \mathbb{R}^{m \times n}$ ，如果存在 m 阶正交矩阵 U 和 n 阶正交矩阵 V ，使得

$$A = U \Sigma V^T$$

成立，其中 Σ 为如下形式的 $m \times n$ 矩阵

$$\Sigma = \begin{bmatrix} \Sigma_r & \mathbf{0}_{r \times (n-r)} \\ \mathbf{0}_{(m-r) \times r} & \mathbf{0}_{(m-r) \times (n-r)} \end{bmatrix}$$

且 $\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$ 是对角矩阵，对角线上的元素是矩阵 A 的奇异值，一般习惯从大到小排列

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$$

该过程称为矩阵 A 的奇异值分解

- U 的列称为矩阵 A 的左奇异向量，也是 AA^T 的特征向量
- V 的行称为矩阵 A 的右奇异向量，也是 $A^T A$ 的特征向量



• 奇异值分解 (Singular Value Decomposition, SVD) 的定义

- 矩阵 AA^T 和 $A^T A$ 都是对称半正定矩阵，且这两个矩阵的特征值都是非负的(有相同的非0特征值)，且 AA^T 与 $A^T A$ 有相同的非0特征值

证明：假设 $\lambda \neq 0$ 是 AA^T 的特征值， $\mathbf{x}$ 是对应的特征向量，则有

$$AA^T \mathbf{x} = \lambda \mathbf{x}$$

1) 在上式两边同时左乘 A^T 可以得到

$$A^T AA^T \mathbf{x} = A^T \lambda \mathbf{x}$$



$$A^T A(A^T \mathbf{x}) = \lambda(A^T \mathbf{x})$$

另一方面，在 $AA^T \mathbf{x} = \lambda \mathbf{x}$ 两边同时左乘 $\mathbf{x}^T$ ，由于 $\lambda \neq 0, \mathbf{x} \neq 0$

$$\mathbf{x}^T AA^T \mathbf{x} = (A^T \mathbf{x})^T A^T \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x} > 0$$

则 $A^T \mathbf{x} \neq 0$

因此，可证得 λ 是 $A^T A$ 的特征值， $A^T \mathbf{x}$ 是对应的特征向量



• 奇异值分解 (Singular Value Decomposition, SVD) 的定义

- 2) 同样, 如果 $\lambda \neq 0$ 是 $A^T A$ 的特征值, $\mathbf{x}$ 是对应的特征向量, 可 $A\mathbf{x} \neq 0$, 且 λ 是 AA^T 的特征值, $A\mathbf{x}$ 是对应的特征向量
- 值得注意: AA^T 的 0 特征值不一定是 $A^T A$ 的 0 特征值

- 例如: 矩阵 $A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$

$$AA^T = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

AA^T 的特征值为 $\lambda_1 = 1, \lambda_2 = 1, \lambda_3 = 0$, 而

$$A^T A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

AA^T 的特征值为 $\lambda_1 = 1, \lambda_2 = 1$, 但 0 是 AA^T 的特征值非 $A^T A$ 的特征值



• 奇异值分解 (Singular Value Decomposition, SVD) 的定义

■ 奇异值分解步骤

- 计算 AA^T ，对其进行特征分解，计算出 U
- 计算 $A^T A$ ，对其进行特征分解，计算出 V
- 将第一或第二步求出的非零特征值从大到小排列后开根号的，计算出 Σ_r ，并求出

$$\Sigma = \begin{bmatrix} \Sigma_r & \mathbf{0}_{r \times (n-r)} \\ \mathbf{0}_{(m-r) \times r} & \mathbf{0}_{(m-r) \times (n-r)} \end{bmatrix}$$

- 得到矩阵的奇异值分解

$$A = U \Sigma V^T$$

- 例子：对于矩阵

$$A = \begin{bmatrix} -1 & 3 \\ 3 & 1 \\ 1 & 1 \end{bmatrix}$$



• 奇异值分解 (Singular Value Decomposition, SVD) 的定义

➤ 例子：对矩阵 $A = \begin{bmatrix} -1 & 3 \\ 3 & 1 \\ 1 & 1 \end{bmatrix}$ 进行奇异值分解

• 计算 $AA^T = \begin{bmatrix} 10 & 0 & 2 \\ 0 & 10 & 4 \\ 2 & 4 & 2 \end{bmatrix}$, $A^T A = \begin{bmatrix} 11 & 1 \\ 1 & 11 \end{bmatrix}$, 其中 AA^T 的特征值为

$\lambda_1 = 12, \lambda_2 = 10, \lambda_3 = 0$, $A^T A$ 的特征值为 $\lambda_1 = 12, \lambda_2 = 10$; 因此 A 的非0奇异值为 $\sigma_1 = \sqrt{12}, \sigma_2 = \sqrt{10}$

• 计算 AA^T 与 $A^T A$ 的特征向量并单位化, 最后得到奇异值分解的结果

$$A = \begin{bmatrix} -1 & 3 \\ 3 & 1 \\ 1 & 1 \end{bmatrix} = U \Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{6}} & -\frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{30}} \\ 2 & 1 & 2 \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{5}} & -\frac{1}{\sqrt{30}} \\ 1 & 0 & 5 \\ \frac{1}{\sqrt{6}} & 0 & \frac{1}{\sqrt{30}} \end{bmatrix} \begin{bmatrix} \sqrt{12} & 0 \\ 0 & \sqrt{10} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}^T$$



• 奇异值分解的几何意义

根据式 $A = U\Sigma V^T$ ，向量 x 左乘任意矩阵 A 所实现的线性变换可以分解为3次变换 $Ax = U\Sigma V^T x$

- 首先是 x 左乘正交矩阵 V^T 所代表的旋转变换
- 接下来是 $V^T x$ 左乘矩阵 Σ 所代表的拉伸变换
- 最后 $\Sigma V^T x$ 是左乘正交矩阵 U 所代表的旋转变换

• 奇异值分解的应用

奇异值分解揭示了矩阵的本质特征，对分析矩阵的性质有重要的价值

- 矩阵的谱范数与其奇异值之间的关系
- 矩阵的条件数与它的奇异值之间的关系
- 常用奇异值和奇异向量对人工神经网络权重矩阵的理论分析中
- 在图像压缩与推荐系统中，奇异值分解也有应用



• 楚列斯基(Cholesky)分解的定义

对于 n 阶**对称半正定**矩阵 A ，楚列斯基分解将其分解为 n 阶下三角矩阵 L 以及其转置 L^T 的乘积

$$A = LL^T$$

➤ 如果 A 是**实对称正定**矩阵，则其楚列斯基分解唯一

➤ 例如

$$\begin{bmatrix} 4 & 12 & -16 \\ 12 & 37 & -43 \\ -16 & -43 & 98 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 0 \\ 6 & 1 & 0 \\ -8 & 5 & 3 \end{bmatrix} \begin{bmatrix} 2 & 6 & -8 \\ 0 & 1 & 5 \\ 0 & 0 & 3 \end{bmatrix}$$

• 楚列斯基(Cholesky)分解计算公式的推导

以三阶矩阵为例

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = LL^T = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \begin{bmatrix} l_{11} & l_{12} & l_{13} \\ 0 & l_{22} & l_{23} \\ 0 & 0 & l_{33} \end{bmatrix}$$



• 楚列斯基(Cholesky)分解计算公式的推导

$$LL^T = \begin{bmatrix} l_{11}^2 & l_{21}l_{11} & l_{31}l_{11} \\ l_{21}l_{11} & l_{21}^2 + l_{22}^2 & l_{31}l_{21} + l_{32}l_{22} \\ l_{31}l_{11} & l_{31}l_{21} + l_{32}l_{22} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{bmatrix}$$

- 首先得到主对角的第一个元素

$$l_{11} = \sqrt{a_{11}}$$

- 根据 l_{11} 得到第2行的所有元素

$$l_{21} = \frac{a_{21}}{l_{11}}, \quad l_{22} = \sqrt{a_{22} - l_{21}^2}$$

- 接着第3行的元素

$$l_{31} = \frac{a_{31}}{l_{11}}, \quad l_{32} = \frac{a_{32} - l_{31}l_{21}}{l_{22}}, \quad l_{33} = \sqrt{a_{33} - (l_{31}^2 + l_{32}^2)}$$

- 以此类推，计算出所有值



• 楚列斯基(Cholesky)分解计算公式的推导

➤ 对于 n 阶矩阵，楚列斯基分解的计算公式为

$$l_{ii} = \left(a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2 \right)^{\frac{1}{2}}, \quad l_{ji} = \frac{1}{l_{ii}} \left(a_{ji} - \sum_{k=1}^{i-1} l_{ik} l_{jk} \right), j = i + 1, \dots, n$$

• 楚列斯基(Cholesky)分解求解线性方程组

对于线性方程组 $Ax = b$ ，若 A 是对称正定矩阵，可分解为 LL^T ，则有

$$LL^T x = b$$

如果令 $L^T x = y$ 则可先求解 $Ly = b$ ，得 y ，然后求解 $L^T x = y$ ，得到 x

- 两个方程组的系数矩阵分别为下三角和上三角矩阵，均可高效的求解
- 在实际应用中，如果系数矩阵 A 不变，而常数向量 b 会改变，则预先将 A 进行楚列斯基分解，每次对于不同的 b 均可高效的求解
- 楚列斯基分解还可用于检查矩阵的正定性：对一个矩阵进行楚列斯基分解，若分解失败，则说明矩阵不是半正定矩阵；否则为半正定矩阵



• 正交三角 (Quadrature Rectangle, QR) 分解的定义

将矩阵分解为正交矩阵与上三角矩阵的乘积

- 对于任意的 n 阶方阵 A , QR分解将其分解为一个 n 阶正交矩阵 Q 与一个 n 阶上三角矩阵 R 的乘积, 即 $A = QR$
- 若 A 矩阵可逆且矩阵 R 的主对角元为正, 则QR分解唯一
- 若 A 有 $m(m \leq n)$ 个线性无关的列, 则 Q 的前 m 个列构成 A 的列空间的标准正交基
- 例如 $A = \begin{bmatrix} 7 & 2 \\ 2 & 4 \end{bmatrix} = QR = \begin{bmatrix} 0.962 & -0.275 \\ 0.275 & 0.962 \end{bmatrix} \begin{bmatrix} 7.28 & 3.02 \\ 0 & 3.30 \end{bmatrix}$
- 对于任意的 $m \times n$ ($m > n$) 阶非方阵 A , 将其分解为一个 m 阶正交矩阵与如下形式的 $m \times n$ 阶矩阵 R 的乘积

$$A = QR = Q \begin{bmatrix} R_n \\ \mathbf{0}_{(m-n) \times n} \end{bmatrix}$$

其中 R_n 是 n 阶上三角矩阵, $\mathbf{0}$ 是一个 $(m - n) \times n$ 的零矩阵



• 正交三角 (Quadrature Rectangle, QR) 分解的定义

- 对于任意的 $m \times n$ ($m < n$) 阶非方阵 A ，将其分解为一个 m 阶正交矩阵与如下形式的 $m \times n$ 阶矩阵 R 的乘积

$$A = QR = Q[R_m \quad F_{m \times (n-m)}]$$

其中 Q 是一个 m 阶正交矩阵， R_m 是 m 阶上三角矩阵， $F_{m \times (n-m)}$ 是一个 $m \times (n-m)$ 的矩阵

• QR分解的实现

3种实现方式：格拉姆-施密特正交化、豪斯霍尔德变换、吉文斯旋转

- 格拉姆-斯密特正交化：考虑 A 为 n 阶方阵的情况，将矩阵 A 按列分块

$$A = [a_1 \quad \cdots \quad a_n]$$

假设这些列向量线性无关。首先将它的列正交化

$$u_1 = a_1, u_2 = a_2 - \frac{a_2^T u_1}{u_1^T u_1} u_1, u_3 = a_3 - \frac{a_3^T u_1}{u_1^T u_1} u_1 - \frac{a_3^T u_2}{u_2^T u_2} u_2, \cdots,$$



• QR分解的实现

➤ 格拉姆-斯密特正交化:

$$\mathbf{u}_n = \mathbf{a}_n - \sum_{i=1}^{n-1} \frac{\mathbf{a}_n^T \mathbf{u}_i}{\mathbf{u}_i^T \mathbf{u}_i} \mathbf{u}_i$$

然后进行单位化

$$\mathbf{e}_i = \frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}, \quad i = 1, \dots, n$$

$\mathbf{A}$ 的各个列向量在标准成交基下的坐标为其在各个基向量上的投影, 由于在进行格拉姆-施密特正交化时 $\mathbf{e}_i$ 只与 $\mathbf{a}_1, \dots, \mathbf{a}_i$ 有关, 因此 $\mathbf{a}_i$ 在 $\mathbf{e}_{i+1}, \dots, \mathbf{e}_n$ 方向的投影均为 0, 有

$$\mathbf{a}_1 = \mathbf{a}_1^T \mathbf{e}_1 \mathbf{e}_1, \mathbf{a}_2 = \mathbf{a}_2^T \mathbf{e}_1 \mathbf{e}_1 + \mathbf{a}_2^T \mathbf{e}_2 \mathbf{e}_2, \mathbf{a}_3 = \mathbf{a}_3^T \mathbf{e}_1 \mathbf{e}_1 + \mathbf{a}_3^T \mathbf{e}_2 \mathbf{e}_2 + \mathbf{a}_3^T \mathbf{e}_3 \mathbf{e}_3$$

...

$$\mathbf{a}_n = \sum_{i=1}^n \mathbf{a}_n^T \mathbf{e}_i \mathbf{e}_i$$



• QR分解的实现

➤ 格拉姆-斯密特正交化

接上，写成矩阵形式为

$$[a_1 \quad \cdots \quad a_n] = [e_1 \quad \cdots \quad e_n] \begin{bmatrix} a_1^T e_1 & a_2^T e_1 & a_3^T e_1 & \cdots \\ 0 & a_2^T e_2 & a_3^T e_2 & \cdots \\ 0 & 0 & a_3^T e_3 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

令 $Q = [e_1 \quad \cdots \quad e_n]$ ，以及

$$R = \begin{bmatrix} a_1^T e_1 & a_2^T e_1 & a_3^T e_1 & \cdots \\ 0 & a_2^T e_2 & a_3^T e_2 & \cdots \\ 0 & 0 & a_3^T e_3 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

Q 的列是用 A 的列构造的标准正交基， R 的第 i 列为 A 的第 i 列在前 i 个基向量方向的投影，至此QR分解完成



• QR分解的实现

➤ 格拉姆-斯密特正交化

• 例如，对于如下矩阵

$$A = \begin{bmatrix} 12 & -51 & 4 \\ 6 & 167 & -68 \\ -4 & 24 & -41 \end{bmatrix}$$

首先对它的列向量进行正交化，得到如下矩阵

$$U = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \mathbf{u}_3] = \begin{bmatrix} 12 & -69 & -58/5 \\ 6 & 158 & 6/5 \\ -4 & 30 & -33 \end{bmatrix}$$

然后将该矩阵的列单位化，可以得到

$$Q = \left[\frac{\mathbf{u}_1}{\|\mathbf{u}_1\|} \quad \frac{\mathbf{u}_2}{\|\mathbf{u}_2\|} \quad \frac{\mathbf{u}_3}{\|\mathbf{u}_3\|} \right] = \begin{bmatrix} 6/7 & -69/175 & -58/175 \\ 3/7 & 158/175 & 6/175 \\ -2/7 & 6/35 & -33/35 \end{bmatrix}$$

由此可以得到上三角矩阵 $R = Q^T A = \begin{bmatrix} 14 & 21 & -14 \\ 0 & 175 & -70 \\ 0 & 0 & 35 \end{bmatrix}$



• QR分解的实现

➤ 豪斯霍尔德变换:

- 首先, 用矩阵 A 的第1列构造第1个豪斯霍尔德矩阵 P_1

$$P_1 = \begin{bmatrix} p_{11} & p_{12} & \cdots & p_{1n} \\ p_{21} & p_{22} & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{n1} & p_{n2} & \cdots & p_{nn} \end{bmatrix}$$

左乘该矩阵将 A 的第1列后面的 $n-1$ 个元素全部零化, 得到

$$P_1 A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ 0 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

- 接着, 构造第2个豪斯霍尔德矩阵 P_2 , 为如下形式

$$P_2 = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & p_{22} & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & p_{n2} & \cdots & p_{nn} \end{bmatrix}$$



• QR分解的实现

➤ 豪斯霍尔德变换:

其中 $\begin{bmatrix} p_{22} & \cdots & p_{2n} \\ \vdots & \ddots & \vdots \\ p_{n2} & \cdots & p_{nn} \end{bmatrix}$, 使用 $P_1 A$ 的第2列后面的 $n-1$ 个元素构造; 将 $P_1 A$ 左乘 P_2 , 可以将第2列后面的 $n-2$ 个元素全部零化

$$P_2 P_1 A = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ 0 & a_{22} & a_{23} & \cdots & a_{2n} \\ 0 & 0 & a_{33} & \cdots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & a_{n3} & \cdots & a_{nn} \end{bmatrix}$$

• 然后, 构造第3个豪斯霍尔德 P_3 , 为如下形式

$$P_3 = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & p_{33} & \cdots & p_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & p_{n3} & \cdots & p_{nn} \end{bmatrix}$$

其中红色区域内的矩阵块, 使用 $P_2 P_1 A$ 的第3列后面的 $n-2$ 个元素构成



• QR分解的实现

➤ 豪斯霍尔德变换:

将 $P_2 P_1 A$ 左乘 P_3 , 可以将其第3列后面的 $n - 3$ 个元素化为零

$$P_3 P_2 P_1 A = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ 0 & a_{22} & a_{23} & \cdots & a_{2n} \\ 0 & 0 & a_{33} & \cdots & a_{3n} \\ 0 & 0 & 0 & \cdots & a_{4n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & a_{n3} & \cdots & a_{nn} \end{bmatrix}$$

• 以此类推, 经过 $n - 1$ 次豪斯霍尔德变换, 可以将 A 化为上三角矩阵

$$P_{n-1} \cdots P_2 P_1 A = R$$

令

$$Q = (P_{n-1} \cdots P_2 P_1)^{-1} = P_1^{-1} P_2^{-1} \cdots P_{n-1}^{-1} = P_1 P_2 \cdots P_{n-1}$$

因对于 $\forall i = 1, \dots, n - 1$ 的 P_i 都是正交矩阵, 因此 Q 也是一个正交矩阵

• 最终, QR 分解的完成



欢迎大家交流和讨论!

刘昌鑫

E-mail: changxinl@ecust.edu.cn